




POC Electio-Analytics

POC Electio-Analytics

Formateur :
ASSIÉ Frédéric

Rédigé par :

AMAZOUZ Anas
YOULA Moussa

LE ROUX Dunvaël
EL HOUZI Abdelmounaïm

*Années 2025-2026
École EPSI – EISI I1*

Table des matières

Introduction	4
I. Présentation générale de l'entreprise et de l'équipe	5
A) Présentation générale de l'entreprise	5
B) Présentation générale de l'équipe en charge du projet	5
II. Présentation du projet : POC Big Data Analysis	7
A) Contraintes techniques et organisationnelles	8
B) Objectifs techniques et organisationnels	8
C) Livrables attendus	8
D) Planning et ressources	9
E) Critères de réussite	10
F) Environnement technique et outils	10
G) Structure du dépôt GitHub et organisation des scripts	11
III. Analyse métier et stratégie data	12
A) Choix du périmètre géographique	12
B) Critères et répartition des classes politiques	13
C) Sources de données	18
IV. Architecture data et Pipeline ETL	21
A) Architecture globale	21
B) Justification ETL/ELT	21
C) Cartographie des flux de données	22
D) Schéma récapitulatif de l'analyse exploratoire des données (EDA)	23
V. Modélisation des données	24
A) Modèle Conceptuel de Données	24
B) Modèle logique de données (MLD)	25
C) Modèle Physique de Données (MPD)	25
D) Stockage des données	28
VI. Les variables et leur intérêt	32
VII. Pipeline de données ETL	35
A) Extraction et analyse exploratoire des données (EDA)	35
B) Transformation des données	48
Sélection et renommage des colonnes utiles	48
Traitement des valeurs manquantes	57
Harmonisation	73

Normalisation	75
Suppression des doublons	77
C) Feature engineering	85
D) Validation et cohérence des données	92
VIII. Modélisation Machine Learning	100
A) Types de modèle	100
B) Paramètres d'entraînement	101
IX. Évaluation des modèles	103
A) Vérifications et tests des modèles	103
B) Choix du meilleur modèle	105
X. Visualisation	107
A) Dashboard	107
B) Cartes	112
XI. Gouvernance, sécurité et RGPD	114
XII. Limites du projet	117
XIII. Recommandations	119
XIV. Conclusion	122
XV. Réponses aux questions	123
XVI. Liste des compétences mises en valeur par le projet	125
Remerciements	126
Références/Sources	127
A) Datasets d'entraînement et de prédiction	127
B) Tutoriels et documentations	127
Glossaire	128

Introduction

Ce rapport de projet MSPR¹ décrit les spécifications et les exigences pour la création d'une preuve de concept² (POC) pour la start-up fictive Electio-Analytics créée en 2017 par Jean-Edouard de la Motte-Rouge. L'objectif est de prédire le parti gagnant du premier tour des élections présidentielles de la France (hors DOM-TOM³), si celles-ci se tenaient aujourd'hui (en 2026).

Plus précisément, le projet vise à construire un modèle prédictif supervisé, entraîné à l'aide de jeux de données d'entraînement et de tests.

Ce projet s'inscrit dans un cheminement logique :

- L'entreprise Electio-Analytics a besoin de mettre en place une capacité de prévision des tendances électorales en se basant sur un certain nombre d'indicateurs.
- AMAZOUZ Anas, EL HOUZI Abdelmounaïm, LE ROUX Dunvaël et YOULA Moussa, étudiants à l'École d'Ingénierie de Montpellier (EPSI), sont engagés par une société de service pour établir cette POC.



¹ Mise en situation professionnelle – Cf Glossaire

² Preuve de concept – Cf Glossaire

³ Départements d'Outre-Mer et Territoires d'Outre-Mer – Cf Glossaire

I. Présentation générale de l'entreprise et de l'équipe

A) Présentation générale de l'entreprise

Electio-Analytics est une start-up française fictive créée en 2017 par Jean-Édouard de la Motte-Rouge. Au cœur de ses activités, Electio-Analytics se spécialise dans le conseil stratégique dédié aux campagnes électorales auprès de ses clients (candidats, partis politiques et cabinets de conseil). Elle se démarque par ses analyses prospectives précises grâce à l'exploitation de données publiques et privées.

L'équipe d'Electio-Analytics est composée de plusieurs profils complémentaires contribuant au bon fonctionnement et au développement de l'entreprise :

- Un expert en analyse politique, titulaire d'un doctorat en science politique et disposant d'une expérience de terrain acquise lors de plusieurs scrutins nationaux
- Un business développer diplômé d'un master en marketing digital, chargé du développement commercial et disposant d'un réseau de contacts auprès de partis politiques et d'organismes de financement
- Une assistante administrative, spécialisée dans la gestion administrative et la coordination des activités de l'entreprise

Le business développer s'occupe de la prospection, de l'élaboration d'offres et de la recherche de subventions, tandis que l'assistante assure la coordination du projet et le suivi administratif.

Chaque membre de l'équipe occupe un rôle spécifique au sein de la structure. Le business développer est responsable des activités de prospection, de l'élaboration des offres commerciales ainsi que de la recherche de subventions et de financements. L'assistante assure quant à elle le suivi administratif des projets, la coordination des différentes tâches et l'organisation opérationnelle de l'activité.

Cette répartition des responsabilités permet à l'entreprise de maintenir une organisation efficace et adaptée aux besoins de ses clients.

B) Présentation générale de l'équipe en charge du projet

Nom	Qualité	Rôle
AMAZOUZ Anas	Auteur des livrables, Alternant « Expert en informatique et Système d'Informations - Infra : Spé Cloud »	Réalisateur du projet
EL HOUZI Abdelmounaïm	Auteur des livrables, Alternant « Expert en informatique et Système d'Informations - Infra : Spé Cloud »	Réalisateur du projet
LE ROUX Dunvaël	Autrice des livrables, Alternante « Expert en informatique et Système d'Informations - Infra : Spé Cloud »	Réalisatrice du projet
YOULA Moussa	Auteur des livrables, Alternant « Expert en informatique et Système d'Informations - Infra : Spé Cloud »	Réalisateur du projet
ASSIÉ Frédéric	Auteur de la MSPR Big Data Analysis, Responsable du suivi des groupes de la MSRP Big Data Analysis	Responsable de la validation du cahier des charges et du projet

Electio-Analytics	Client	Initiateur du projet
-------------------	--------	----------------------

Utilisateur final du projet :

- ◆ Electio-Analytics



II. Présentation du projet : POC Big Data Analysis

Ce projet de Proof Of Concept (POC) Big Data vise à analyser l'influence conjointe de facteurs démographiques, socio-économiques, territoriaux et criminels sur les comportements électoraux en France, dans le but d'identifier le bloc politique susceptible d'obtenir une majorité en cas d'élection présidentielle immédiate.

Le projet repose sur l'exploitation de jeux de données publics provenant principalement de l'INSEE⁴ et de data.gouv.fr. Les données collectées sont nettoyées, harmonisées, transformées, puis intégrées dans une architecture ETL⁵ développée avec Python et Pandas, avant d'être utilisées par plusieurs modèles de Machine Learning⁶.

Le périmètre géographique, les indicateurs utilisés, les solutions logicielles ainsi que les choix techniques ont été définis, justifiés et validés par le groupe projet en fonction des objectifs de la MSPR.

Les différentes phases du projet et les traitements effectués sont tracés, documentés et consignés dans ce rapport afin de garantir la reproductibilité, la cohérence et la traçabilité du pipeline de données.

Les jeux de données d'entraînement et de prédiction ont été entièrement réalisés par le groupe à partir :

- De la collecte des datasets
- Du nettoyage et de l'harmonisation des données
- De la fusion des différentes sources
- De la création des dataframes
- Des vérifications de cohérence et de qualité des données
- De l'intégration dans une base relationnelle SQLite

Plusieurs modèles supervisés de Machine Learning ont été entraînés et comparés afin de sélectionner le plus pertinent pour répondre à la problématique de classification⁷ électorale. Ces modèles ont ensuite été évalués à l'aide de plusieurs métriques de performance.

Les prédictions et résultats obtenus sont présentés sous forme de visualisations et de tableaux de bord permettant :

- D'analyser l'importance des variables
- D'identifier certaines corrélations entre indicateurs
- D'interpréter les tendances électorales
- D'étudier l'influence de différents critères territoriaux et socio-économiques sur les comportements électoraux

Les principales technologies utilisées dans le cadre du projet sont Python, Pandas, Power BI Microsoft, Visual Studio Code, GitHub, SQLite, DB Browser for SQLite. Les jeux de données proviennent de datagouv.fr et de l'INSEE.

Le projet a été conçu dans une logique de reproductibilité, d'automatisation et d'analyse décisionnelle, afin de proposer une architecture Big Data cohérente, légère et adaptée à un contexte de Proof of Concept.



⁴ Institut National de la Statistique et des Études Économiques Cf Glossaire

⁵ Extract, Transform, Load – Cf Glossaire

⁶ Apprentissage automatisé – Cf Glossaire

⁷ Cf Glossaire

A) Contraintes techniques et organisationnelles

Pour la réalisation du projet, plusieurs contraintes techniques et organisationnelles ont dû être prises en compte afin d'assurer le bon déroulement des différentes phases de développement et d'analyse.

Contraintes techniques	Contraintes organisationnelles
✓ Gestion des données (RGPD8), transformation et nettoyage ✓ Utilisation de Python et Pandas ✓ Stockage des données ✓ Mise en place et configuration d'un ETL ✓ Développement et déploiement des scripts ✓ Utilisation de Power BI Microsoft	✓ Réduire les coûts ✓ Respecter les délais ✓ Développement en groupe

Enfin, le développement du projet en groupe a impliqué une coordination de l'équipe. Cette collaboration a nécessité une répartition claire des tâches, une communication régulière ainsi qu'une gestion collaborative des différentes phases de conception, de développement et d'analyse.

B) Objectifs techniques et organisationnels

Dans le cadre de ce projet, plusieurs objectifs techniques et organisationnels ont été définis afin de garantir la qualité des analyses réalisées, la fiabilité des traitements de données ainsi que le bon déroulement du projet.

Objectifs techniques	Objectifs organisationnels
✓ Définir le principe d'apprentissage⁹ supervisé ✓ Définir et justifier les indicateurs, la zone géographique, les sources des données et leur taille ✓ Réaliser un schéma de traitement des données (flux de données) ✓ Gérer le stockage des données avec SQLite ✓ Mise en place d'un pipeline de traitement automatisé, fiable et traçable pour garantir la qualité des données et la reproductibilité du processus ✓ Mise en place de l'anonymisation des données (suppression des données à caractère personnelles permettant d'identifier directement ou indirectement un individu) ✓ Mise en place d'un ETL ✓ Gestion des données avec un langage et des outils adaptés (Python, Pandas...) ✓ Comparer et tester les différents modèles de ML (indices de précision, ...) ✓ Réaliser des visualisations claires des résultats de prédiction (Power BI)	✓ Réduire les coûts : utilisation de technologies gratuites/open-source ✓ Mise en place d'un calendrier de projet + méthodologie Agile (Trello) ✓ Assurer la reprise et la gestion du projet auprès du client : documentations et livrables

C) Livrables attendus

A la fin du projet, l'équipe devra fournir :

- ✓ Le dossier de synthèse
- ✓ Les jeux de données nettoyés
- ✓ Le code source commenté

8 Règlement Général de la Protection des Données – Cf Glossaire

9 Cf Glossaire

- ✓ Le fichier de visualisation des données (Power BI Microsoft)
- ✓ Les rapports de tests de fiabilité du modèle de ML
- ✓ La documentation du projet de la mise en place du projet
- ✓ La documentation utilisée pour la réalisation du projet (documentations des solutions logicielles et outils, tutoriels...)

Livrables	Dates	Informations complémentaires
1er livrable	01/02/2026	Début des travaux : compréhension du projet, définition des objectifs et des technologies à utiliser, planification et répartition des tâches, définition des critères et de la zone géographique, recherche des jeux de données.
2ème livrable	01/04/2026	Nettoyage et transformation des données (ETL), développement et déploiement du script d'entraînement du ML, comparaison des différents modèles de ML et de leur pertinence, vérification de la fiabilité du ML choisi.
3ème livrable	15/04/2026	ML terminé, recherche des jeux de données de test, nettoyage et transformation,
4ème livrable	20/05/2026	Finalisation des livrables (dossier de synthèse, jeux de données, code commenté...).

D) Planning et ressources

Conformément à la méthodologie Agile, une répartition des tâches a été établie pour chaque étape du projet et des responsabilités a été établie pour chaque étape du projet, garantissant une organisation cohérente des ressources et un suivi rigoureux de l'avancement des travaux.

Pour favoriser la collaboration entre les membres de l'équipe, un serveur Discord dédié au projet a été créé. Celui-ci a permis :

- De communiquer à distance via des échanges écrits, des appels vocaux et des visioconférences
- De partager les progrès du projet ainsi que les livrables
- D'organiser les différentes phases de travail
- De centraliser les ressources, scripts, jeux de données et documentations
- De disposer de canaux spécifiques dédiés aux divers aspects du projet (nettoyage des données, analyse exploratoire, apprentissage automatique, visualisation des données, livrables et suivi du projet)

L'architecture du serveur Discord a également contribué à améliorer la traçabilité des échanges, la répartition des tâches et la coordination de l'équipe tout au long du développement du POC Electio-Analytics.

E) Critères de réussite

Le projet sera considéré comme réussi si les conditions suivantes sont complétées :

- ✓ Les POC est fonctionnel et terminé
- ✓ Les jeux de données sont nettoyés et transformés par un ETL correctement configuré
- ✓ Le modèle de ML est pertinent, correctement entraîné et réutilisable
- ✓ Les données sont anonymisées et respectent les principes du RGPD
- ✓ La visualisation des données est claire et répond à la problématique
- ✓ Le code est commenté et lisible
- ✓ La documentation du projet est complète et permet de comprendre l'architecture du POC, les technologies et outils utilisés, les scripts créés, le processus d'entraînement et de test du ML ainsi que le choix du modèle le plus approprié

F) Environnement technique et outils

Afin de se conformer aux contraintes, aux objectifs et pour s'assurer la meilleure compatibilité possible, nous avons choisi de développer ce projet avec des standards mondialement reconnus.



Power BI Microsoft : Solution d'analyse des données d'informatique décisionnelle de Microsoft. La solution permet la visualisation de données personnalisée et interactive à l'aide d'une interface d'édition de rapports et de tableaux de bord.



Python : Langage de programmation interprété, multiparadigme et multiplateformes. Il favorise la programmation impérative structurée, fonctionnelle et orientée objet.



Pandas : Bibliothèque écrite pour le langage de programmation Python permettant la manipulation et l'analyse de données. Elle propose en particulier des structures de données et des opérations de manipulation de tableaux numériques et de séries temporelles.



SQLite : Système de gestion de base de données relationnelle (SGBDR) embarqué, léger et multiplateforme ne nécessitant aucun serveur dédié. SQLite permet le stockage structuré des données sous forme de tables relationnelles accessibles via le langage SQL.



DB Browser for SQLite : Outil graphique open source permettant de visualiser, créer, modifier et administrer des bases de données SQLite via une interface simplifiée. Il facilite l'exploration des tables, l'exécution de requêtes SQL et la vérification des données stockées dans la base relationnelle du projet.



Looping : Logiciel de modélisation conceptuelle de données entièrement gratuit et libre d'utilisation. Il permet d'organiser et de structurer des données via des diagrammes et de générer automatiquement le modèle logique (MLD) ainsi que les scripts SQL pour créer les tables de la base de données.



datagouv.fr : Plateforme de diffusion de données publiques (open data) de l'État français, développée par la direction interministérielle du Numérique (DINUM).



Excel : Logiciel tableur développé par Microsoft qui permet de créer, organiser et analyser des données sous forme de feuilles de calcul structurées en lignes et colonnes.



INSEE : Organisme français créé en 1946 qui a pour rôle de collecter, produire, analyser et diffuser des informations sur l'économie et la société françaises.



Visual Studio Code : Éditeur de code extensible développé par Microsoft pour Windows, Linux et MacOS.



GitHub : Plateforme de contrôle de version et de collaboration. Elle permet à plusieurs développeurs de travailler ensemble sur des projets tout en hébergeant et en révisant le code, en gérant des projets, et en construisant des logiciels aux côtés de millions d'autres développeurs.

G) Structure du dépôt GitHub et organisation des scripts

Le dépôt GitHub a servi de plateforme centralisée pour regrouper l'intégralité des scripts, des datasets épurés, des documentations et des ressources liées au projet. Il a facilité la collaboration entre les membres de l'équipe, permis un suivi rigoureux des modifications et assuré la traçabilité des différentes étapes de développement du POC Election Analytics.



III. Analyse métier et stratégie data

A) Choix du périmètre géographique

Engagés par Electio-Analytics, nous avons choisi d'étudier les comportements électoraux en France afin de déterminer le bloc politique le plus susceptible d'obtenir la majorité en cas d'élection présidentielle immédiate.

Pour répondre à cette problématique le projet s'est appuyé sur :

- Les résultats du premier tour des élections présidentielles françaises
- Un périmètre limité à la France métropolitaine, hors DOM-TOM
- Des jeux de données structurés au niveau communal

Pourquoi ce choix ?

1- Les élections présidentielles françaises constituent un événement politique d'une ampleur majeure, générant un volume conséquent de données électorales, démographiques et socio-économiques. Leur forte médiatisation ainsi que le taux de participation généralement élevé assurent des données particulièrement pertinentes pour l'analyse et le Machine Learning.

2 - Concernant le périmètre géographique, nous avons opté pour une limitation à la France métropolitaine. Nous souhaitions initialement intégrer les DOM-TOM afin d'obtenir une vision plus exhaustive du territoire. Cependant, nous avons été confrontés à des difficultés liées à la disponibilité et à la qualité des données :

- Absence de certains jeux de données correspondant à nos critères
- Données incomplètes ou inexploitable
- Manque d'harmonisation entre certaines sources

Ces contraintes nous ont empêché d'exploiter les données des DOM-TOM de façon cohérente et qualitative dans le cadre de notre POC.

3 – Nous avons également décidé de travailler à l'échelle communale plutôt qu'au niveau régional ou départemental. Ce niveau de granularité présente plusieurs avantages :

- Une précision accrue des analyses
- Une représentation plus fine des comportements électoraux
- Une amélioration potentielle des performances des modèles de Machine Learning
- Une identification plus exacte des disparités territoriales

La France comportant plus de 35 000 communes, cette approche nous permet d'obtenir des données détaillées et variées facilitant l'analyse des corrélations entre les différents indicateurs employés dans le projet.

Bien que ce niveau d'analyse soit plus complexe à traiter en raison du volume important de données à traiter, il permet une meilleure représentation des réalités locales et des spécificités territoriales.

Enfin, chaque territoire possède des caractéristiques propres liées à son histoire, sa culture, ses dynamiques économiques et ses habitudes électorales. L'analyse au niveau communal permet ainsi de mesurer l'impact de ces spécificités locales sur les résultats électoraux et d'évaluer leur pertinence dans la prédiction des comportements politiques.

B) Critères et répartition des classes politiques

Choix des critères et justifications

Nous avons choisi les critères suivants pour notre matrice de X :

- **revenu_median**

Justification : Le revenu médian est un indicateur synthétique du niveau de vie moyen des résidents d'une commune. Les disparités de revenus sont susceptibles d'influencer les comportements électoraux, en particulier sur des thématiques telles que le pouvoir d'achat, la fiscalité, les aides sociales ou les politiques économiques. Cette variable permet non seulement de quantifier les écarts socio-économiques entre territoires, mais aussi d'analyser leur corrélation avec les orientations politiques locales. Elle offre ainsi une base pour comprendre comment les inégalités économiques façonnent les préférences électorales.

- **taux_chomage**

Justification : Le taux de chômage reflète la situation économique et professionnelle d'un territoire donné. Un niveau de chômage élevé peut accroître les préoccupations des électeurs en matière d'emploi, de sécurité économique ou de politiques sociales. Par conséquent, cette variable permet d'étudier l'impact de la conjoncture de l'emploi sur les résultats électoraux. Elle contribue également à identifier d'éventuelles corrélations entre la précarité économique et l'orientation politique des électeurs, fournissant ainsi des indications sur les déterminants socio-économiques du vote.

- **categorie_sociale**

Justification : La catégorie sociale permet d'analyser la structure socio-professionnelle d'un territoire. Cette variable facilite l'étude des relations entre les profils sociaux, les niveaux de revenus, les conditions d'emploi et les comportements électoraux à l'échelle communale. Elle permet également de mieux comprendre les dynamiques sociales et politiques locales ainsi que les disparités entre territoires urbains et ruraux.

- **population**

Justification : La population totale permet d'évaluer l'importance démographique d'une commune. Cette variable est fondamentale pour analyser les différences de comportements électoraux entre les communes fortement peuplées, souvent caractérisées par une diversité sociale et culturelle accrue, et les territoires plus ruraux ou faiblement habités, où les dynamiques de vote peuvent être influencées par des enjeux locaux spécifiques. Elle sert ainsi de base pour des comparaisons intercommunales et pour l'étude des effets de taille sur les tendances politiques.

- **densite**

Justification : La densité de population mesure la concentration des habitants sur une superficie donnée. Les zones urbaines densément peuplées présentent fréquemment des comportements électoraux distincts de ceux des territoires ruraux ou périurbains. Cette variable est donc utile pour identifier les oppositions entre espaces urbains, périurbains et ruraux, et pour analyser comment ces différences de peuplement influencent les tendances politiques. Elle permet de contextualiser les données démographiques et de mettre en lumière les spécificités locales.

- **superficie_km2**

Justification : La superficie d'une commune permet de contextualiser les données démographiques et territoriales, notamment en lien avec la densité de population. Les communes étendues géographiquement peuvent faire face à des problématiques distinctes en matière d'accès aux services publics, de mobilité ou d'aménagement du territoire. Ces facteurs sont susceptibles d'influencer les comportements électoraux, par exemple en favorisant des préoccupations liées à l'isolement ou à la gestion des infrastructures. Cette variable enrichit donc l'analyse en intégrant une dimension spatiale.

- **pct_senior**

Justification : Le pourcentage de seniors (personnes âgées) permet d'étudier l'impact du vieillissement de la population sur les comportements électoraux. Les populations plus âgées peuvent avoir des priorités différentes, notamment en matière de retraite, de sécurité, de santé ou de stabilité politique. Cette variable aide à identifier les corrélations entre la structure démographique d'une commune et les tendances électorales observées, offrant ainsi un éclairage sur les préférences des classes d'âge avancées.

- **pct_jeunes**

Justification : Le pourcentage de jeunes permet d'évaluer la part des populations les plus jeunes dans une commune. Les jeunes électeurs présentent souvent des comportements politiques distincts, influencés par des préoccupations liées à l'éducation, à l'emploi, au changement climatique ou aux évolutions sociétales. Cette variable est donc pertinente pour analyser l'influence générationnelle sur les résultats électoraux, en mettant en évidence les divergences potentielles entre les cohortes d'âge.

- **age_median**

Justification : L'âge médian offre une représentation synthétique de l'équilibre générationnel d'un territoire. Cette variable complète les indicateurs démographiques en permettant d'étudier l'influence globale de l'âge moyen des habitants sur les comportements électoraux et les préférences politiques locales. Elle constitue un outil pour appréhender les tendances démographiques et leurs implications électorales, en complément des pourcentages de jeunes et de seniors.

- **taux_immigration**

Justification : Le taux d'immigration mesure la proportion de populations immigrées présentes sur un territoire. Cette variable peut influencer les débats politiques liés à l'intégration, à la diversité culturelle, à l'emploi ou à la sécurité. Elle permet d'étudier les corrélations éventuelles entre les dynamiques migratoires et les tendances électorales, en offrant une perspective sur la manière dont la composition ethnoculturelle d'une commune peut affecter les orientations politiques.

- **nb_associations**

Justification : Le nombre de créations d'associations constitue un indicateur du dynamisme social et associatif d'un territoire. Une forte activité associative reflète généralement un engagement citoyen important, une vie locale active et un tissu social développé. Cette variable peut donc être pertinente pour analyser certaines orientations politiques, notamment celles liées à la participation civique, ainsi que pour étudier les niveaux de participation électorale. Elle offre un aperçu de la vitalité de la société civile locale.

- **nb_creation_entreprises**

Justification : Le nombre de créations d'entreprises permet d'évaluer le dynamisme économique et entrepreneurial d'un territoire. Une activité économique soutenue peut influencer les préoccupations des électeurs concernant la fiscalité, l'emploi, l'investissement ou les politiques économiques. Cette variable permet d'analyser les liens entre la vitalité économique d'une commune et les comportements électoraux, en mettant en lumière comment les opportunités entrepreneuriales peuvent façonner les préférences politiques.

- **criminalite**

Justification : Le taux de criminalité permet d'étudier l'impact des problématiques de sécurité sur les comportements électoraux. Les variations du niveau de criminalité peuvent influencer les préoccupations des électeurs en matière de sécurité publique, de politiques pénales ou de rôle des forces de l'ordre. Cette variable aide ainsi à analyser les corrélations entre le sentiment d'insécurité et les tendances politiques, en offrant une base pour comprendre comment les enjeux sécuritaires affectent les choix électoraux.

Ces variables ont été choisies dans le but d'améliorer la pertinence statistique ainsi que la faculté du modèle à détecter des associations significatives entre les caractéristiques socio-économiques des territoires et les tendances électorales.



Répartition en blocs politiques

Nous avons établi cinq blocs politiques dans lesquels nous avons réparti les candidats qui se présentaient aux élections présidentielles de 2022.

Pour cela, nous avons vérifié le parti politique associé à chaque candidat au moment des élections présidentielles de 2022 afin de rester le plus fidèle à la situation politique de 2022 et de ne pas inclure de biais.

Candidats	Bloc politique				
	Extrême droite	Droite	Centre	Gauche	Extrême gauche
Marine LE PEN	✓	-	-	-	-
Eric ZEMMOUR	✓	-	-	-	-
Valérie PECRESSE	-	✓	-	-	-
Nicolas DUPONT-AIGNAN	-	-	✓	-	-
Emmanuel MACRON	-	-	✓	-	-
Jean LASSALE	-	-	✓	-	-
Jean-Luc MELANCHON	-	-	-	✓	-
Yannick JADOT	-	-	-	✓	-
Anne HIDALGO	-	-	-	✓	-
Fabien ROUSSEL	-	-	-	✓	-
Nathalie ARTHAUD	-	-	-	-	✓
Philippe POUTOU	-	-	-	-	✓

Choix des étiquettes de la répartition des classes politiques

- “**centre**” rassemble les candidats dont les positions se situent entre la gauche et la droite classiques. Elle sert à repérer les zones favorables à des orientations modérées, libérales ou centristes, et à suivre leur transformation au fil du temps.

- **“droite”** inclut les candidats associés à des politiques conservatrices, libérales ou sécuritaires. Cette classification permet d’examiner les territoires où les enjeux économiques, sécuritaires ou liés aux valeurs traditionnelles sont davantage prépondérants.
- **“gauche”** regroupe les candidats prônant principalement des politiques sociales, écologiques ou redistributives. Cette variable permet d’identifier les zones plus réceptives aux questions sociales, environnementales et aux mécanismes de redistribution publique.
- **“extrême-droite”** rassemble les candidats adoptant des positions radicales sur la sécurité, l’immigration ou l’identité nationale. Cette catégorie sert à analyser les territoires où ces thèmes semblent influencer fortement les choix électoraux.
- **“extrême-gauche”** réunit les candidats défendant des politiques fortement centrées sur l’anticapitalisme, la redistribution des richesses ou les mouvements sociaux. Cette variable permet de localiser les zones où l’électorat manifeste une contestation marquée des modèles économiques et politiques établi.

L’agrégation des candidats en coalitions politiques permet d’éviter un déséquilibre trop important entre les classes et de contrôler la granularité de la prédiction.



C) Sources de données

Année 2022

Nom	Critère + lien	Format	Date	Informations supplémentaires
Code officiel géographique au 1er janvier 2022	Référentiel des codes communes de France de 2022 de l'INSEE	.csv	17/05/22	-
Table de passage annuelle 2025	Tables de passage des communes	.xlsx	19/03/26	Utilisé pour avoir les "conversions" des codes INSEE de 2003 à 2025
Base niveau communes en 2021 - y compris arrondissements municipaux	Revenus médians	.csv ou .xlsx ?	29/01/24	-
NAT2 – Population de 15 ans ou plus par sexe, type d'activité et nationalité	Taux de chômage	.csv ou .xlsx ?	26/06/25	-
Évolution et structure de la population en 2022 - Commune - France hors Mayotte	Catégorie sociale	.csv ou .xlsx ?	26/06/25	-
Liste des communes de France 2022 et de leurs codes associés au format CSV	Densité de population	.csv	21/02/25	-
Population selon le sexe et l'âge quinquennal de 1968 à 2022 (1990 à 2022 pour les DOM)	Démographie	.zip	04/12/25	-
NAT2 – Population de 15 ans ou plus par sexe, type d'activité et nationalité	Taux immigration	.csv ?	26/06/25	-
rna-2024.xlsx	Nombre de création d'association	.xls ? Ou .xlsx	19/04/24	-
Créations d'entreprises au niveau communal et supra communal par secteur d'activité (A10) et forme légale	Nombre de création d'entreprise	.csv	14/04/26	-
Base statistique communale de la délinquance enregistrée par la police et la gendarmerie nationales	Criminalité	.csv	27/03/26	-
Élection présidentielle des 10 et 24 avril 2022 - Résultats définitifs du 1er tour	Résultats du 1er tour des élections présidentielles	.csv	14/04/26	Ancien dataset pour la variable Y, remplacé.

Résultats par candidats	Résultats du 1er tour des élections présidentielles 2022	.csv	05/04/26	Transformé en .parquet
-------------------------	--	------	----------	------------------------

Année 2024

Nom	Critère	Format	Date	Informations supplémentaires
Code officiel géographique au 1er janvier 2024	Référentiel des codes communes de France de 2024 de l'INSEE	.csv	20/02/24	-
Table de passage annuelle 2025	Tables de passage des communes	.xlsx	19/03/26	Utilisé pour avoir les "conversions" des codes INSEE de 2003 à 2025
Base niveau communes en 2021 - y compris arrondissements municipaux	Revenus médians	.csv ou .xlsx ?	29/01/24	Estimation pour 2024
Évolution et structure de la population en 2022 - Commune - France hors Mayotte	Catégorie sociale	.csv ou .xlsx ?	26/06/25	-
Inscrits à France Travail - Données communales (trimestrielles, brutes)	Taux de chômage	.csv	29/04/26	-
Évolution et structure de la population en 2022 - Commune - France hors Mayotte	Catégorie sociale	.csv ou .xlsx ?	26/06/25	Estimation pour 2024
Communes et villes de France en CSV, Excel, Json, Parquet et Feather – Liste des communes de France 2025 et de leurs codes associés au format csv	Densité de population	.csv	21/02/25	-
Population selon le sexe et l'âge quinquennal de 1968 à 2022 (1990 à 2022 pour les DOM)	Démographie	.zip	04/12/25	Estimation pour 2024
NAT2 – Population de 15 ans ou plus par sexe, type d'activité et nationalité	Taux immigration	.csv ?	26/06/25	Estimation pour 2024
rna-2024.xlsx	Nombre de création d'association	.xls ? Ou xlsx	19/04/24	-
Créations d'entreprises au niveau communal et supra communal par secteur d'activité (A10) et forme légale	Nombre de création d'entreprise	.csv	14/04/26	-

Base statistique communale de la délinquance enregistrée par la police et la gendarmerie nationales	Criminalité	.csv	27/03/26	-
---	-----------------------------	------	----------	---

Estimations et calculs pour 2024

Afin de réaliser les estimations et calculs pour les jeux de données 2024 n'existant pas, les jeux de données suivants ont été utilisé :

Nom	Appliqué au(x) jeu(x) de données + Lien	Format	Date
Indicateurs sur les revenus et la pauvreté au niveau local en 2023 → Revenus et pauvreté des ménages en 2023 - Tous les niveaux géographiques	Revenus médians	.csv	05/05/26
Nombre de décès annuels par commune de 2008 à 2024	Démographie, Taux d'immigration et Catégorie sociale	.csv	21/11/25
Nombre de naissances annuelles par commune de 2008 à 2024	Démographie, Taux d'immigration et Catégorie sociale	.csv	21/11/25
Populations de référence en 2023	Démographie, Taux d'immigration et Catégorie sociale	.csv	18/12/25
Base statistique communale de la délinquance enregistrée par la police et la gendarmerie nationales	Démographie	.csv	27/03/26

Au cours de la phase initiale du projet, nous avons envisagé plusieurs critères additionnels en raison de leur pertinence potentielle pour l'analyse électorale. Nous avons notamment mené des recherches préliminaires afin d'identifier les jeux de données correspondant à ces variables. Toutefois, les données les plus récentes, nécessaires à la constitution du dataset de prédiction 2024 n'étaient pas disponibles au moment du projet.


Afin de préserver la cohérence temporelle et la fiabilité des prédictions, nous avons décidé de ne pas inclure ces critères dans le pipeline final. Néanmoins, si ces données venaient à être publiées ultérieurement, leur intégration constituerait une amélioration pertinente dans le cadre d'une mise en production ou d'une évolution future du projet.

Critères concernés :

- [Niveau d'études](#) : Présent dans Diplômes et formation → 5/02/26
- [Foncier](#) : Présent dans Logements ordinaires en 2022 → 16/10/25
- [Taux d'abstention](#) : Présent dans Election présidentielle des 10 et 24 avril 2022 - Résultats définitifs du 1er tour → 14/04/22
- Taux d'inflation : dataset non cherché, critère "optionnel"

IV. Architecture data et Pipeline ETL

A) Architecture globale



Cette architecture globale présente les couches fondamentales du pipeline de données déployé dans le cadre du projet Electio-Analytics. Elle présente le parcours des données, depuis leur collecte auprès de sources publiques jusqu'à leur utilisation par les modèles de Machine Learning et leur restitution dans un tableau de bord décisionnel Power BI.

B) Justification ETL/ELT

Pourquoi un ETL et non un ELT¹⁰ ?

Le projet Electio-Analytics s'appuie sur une architecture ETL (Extract, Transform, Load), conformément au cahier des charges de la MSPR et aux exigences fonctionnelles du projet. Les données sont d'abord collectées à partir de différentes sources publiques (INSEE, data.gouv.fr, fichiers CSV/XLSX), puis nettoyées, harmonisées et transformées avec l'aide de Python et Pandas avant d'être chargées dans une base SQLite structurée utilisée par les scripts de Machine Learning.

Cette méthodologie permet de contrôler la qualité des données avant leur stockage et leur utilisation à des fins analytique. Les étapes de transformation comprennent notamment :

- La gestion des valeurs manquantes
- La suppression des doublons
- L'harmonisation des formats
- La normalisation des colonnes
- La gestion des codes INSEE
- La fusion et la cohérence des jeux de données

Le choix d'un ETL est particulièrement adapté au contexte du projet, car les traitements de données sont effectués principalement via Python et Pandas, en dehors de la base de données. SQLite est employé comme solution de stockage légère et structurée, et non comme moteur de transformation massif contrairement à ce que permettrait une architecture ELT moderne.

À l'inverse, une architecture ELT (Extract, Load, Transform) aurait consisté à charger les données brutes directement dans la base avant d'appliquer les transformations via SQL ou des traitements Big Data. Ce type d'architecture est davantage utilisé dans des environnements de production à grande échelle, reposant sur des technologies telles que PostgreSQL, Snowflake, BigQuery, Hadoop ou Spark. Dans le contexte de notre projet, une architecture ELT aurait introduit une complexité technique superflue sans réel bénéfice fonctionnel significatif. L'architecture ETL retenue permet au contraire :


- De simplifier les traitements
- D'améliorer la lisibilité du pipeline
- De faciliter le débogage des jeux de données
- De garantir la reproductibilité des traitements
- De conserver une architecture légère adaptée à un contexte de Proof of Concept (POC)

¹⁰ Extract, Load, Transform – Cf Glossaire

Ce choix assure ainsi la qualité, la cohérence et la reproductibilité des données tout en conservant une architecture claire, maintenable et adaptée aux objectifs pédagogiques et techniques du projet Electio-Analytics.

C) Cartographie des flux de données

Flux de traitement des données – Electio-Analytics




Légende :

- **Sources de données** : Recherche des jeux de données publics utilisés dans le cadre du projet (open data, fichiers CSV/XLSX, données électorales, socio-économiques et démographiques).
- **Analyse exploratoire des données – EDA** : Phase d'analyse préliminaire permettant d'identifier la structure des jeux de données, les valeurs manquantes, les incohérences, les corrélations et la qualité globale des données.
- **Pipeline ETL – Python / Pandas** : Processus automatisé d'extraction, de transformation et de chargement des données. Cette étape comprend le nettoyage, la normalisation, la suppression des doublons, la gestion des valeurs manquantes et l'harmonisation des formats.
 - **Extraction** : Collecte des fichiers CSV/XLSX, récupération des datasets et analyse exploratoire des données (EDA). L'EDA permet d'identifier la structure des jeux de données, les valeurs manquantes, les incohérences, les corrélations et la qualité globale des données.
 - **Transformation** : Nettoyage des données, gestion des valeurs manquantes, suppression des doublons, harmonisation des formats et normalisation des colonnes.
 - **Chargement** : Intégration des datasets nettoyés dans une base relationnelle SQLite et création des tables SQL utilisées par le Machine Learning.
- **Base de données relationnelle SQLite** : Système de stockage structuré utilisé pour centraliser les datasets nettoyés et normalisés avant leur exploitation par les modèles de Machine Learning.
- **Modélisation Machine Learning – Python / Scikit-learn** : Phase d'entraînement, d'évaluation et de prédiction des modèles supervisés afin d'anticiper les tendances électorales à partir des données préparées.
- **Visualisation des données – Power BI** : Création de visualisations interactives et de tableaux de bord décisionnels permettant l'analyse et l'interprétation des résultats du modèle.

Le pipeline de traitement des données a été réalisé dans une logique de reproductibilité, de traçabilité et d'automatisation en vue de satisfaire les exigences d'analyse décisionnelle du projet Electio-Analytics.

D) Schéma récapitulatif de l'analyse exploratoire des données (EDA)

Analyse exploratoire des données (EDA)



Légende : Processus d'analyse exploratoire et de validation des données avant intégration dans le pipeline ETL et les modèles de Machine Learning.



V. Modélisation des données

A) Modèle Conceptuel de Données


Afin de structurer les données utilisées dans le cadre de notre projet, nous avons réalisé un Modèle Conceptuel de Données¹¹ (MCD) avec l'outil looping.

Le modèle conçu s'articule autour de plusieurs entités principales :

- **COMMUNE** : contient les informations administratives et géographiques des communes étudiées
- **INDICATEUR_SOCIO_ECO** : contient les indicateurs socio-économiques, démographiques et territoriaux utilisés comme variables explicatives du modèle de Machine Learning, notamment les revenus médians, le taux de chômage, les catégories sociales, la densité de population, les données migratoires ainsi que les indicateurs de dynamisme local
- **ELECTION** : contient les informations relatives aux élections analysées, telles que l'année de l'élection, le type d'élection, le tour et la date électorale
- **CRIMINALITE** : contient les données liées à la sécurité et à la délinquance observées dans les communes, notamment les cambriolages, violences, trafics de stupéfiants, vols et dégradations
- **RESULTAT_ELECTION** : contient les résultats électoraux par commune et par élection, incluant les scores des différents blocs politiques ainsi que le bloc politique majoritaire utilisé comme variable cible dans le modèle de Machine Learning

Les relations entre ces différentes entités permettent de relier les données territoriales aux comportements électoraux afin de faciliter les analyses statistiques et les traitements de Machine Learning.

Modèle conceptuel de données (MCD)



¹¹ Cf Glossaire

B) Modèle logique de données (MLD)

Modèle logique de données (MLD)


Après avoir réalisé un MCD, nous avons conçu un Modèle Logique de Données¹² (MLD) afin de structurer les informations du projet sous forme relationnelle. Cette étape nous a permis de transformer les différentes entités identifiées dans le MCD en tables exploitables dans la base de données du projet.

Le schéma ci-dessous est la représentation détaillée des tables qui seront créées dans une base de données relationnelle.

À partir du MCD, le MLD transforme les entités et relations en tables, avec :

- Des clés primaires (PK) pour identifier chaque enregistrement
- Des clés étrangères (FK) pour relier les tables entre elles

Ce modèle logique constitue ainsi une étape intermédiaire entre la modélisation métier et l'implémentation technique de la base de données utilisée dans le pipeline ETL et les traitements de Machine Learning.



C) Modèle Physique de Données (MPD)

À partir du Modèle Logique de Données¹³ (MLD), nous avons ensuite mis en place le Modèle Physique de Données (MPD), correspondant à l'implémentation réelle de la base de données utilisée dans le projet. Cette phase a consisté à adapter la structure logique aux contraintes techniques de stockage et d'exploitation des données dans SQLite.

¹² Cf Glossaire

¹³ Cf Glossaire

Contrairement au MCD, qui se concentre sur la logique métier, le MPD prend en compte :

- Les types de données des colonnes
- Les clés primaires et étrangères
- Les contraintes d'intégrité
- L'optimisation du stockage des données
- Les performances des requêtes

Dans le cadre du projet Electio-Analytics, le MPD a été implémenté à l'aide de SQLite afin de disposer d'une solution légère, simple à déployer et adaptée aux besoins du Proof of Concept (POC).

Architecture décisionnelle : modèle étoile

Notre projet s'appuie sur une architecture décisionnelle inspirée des modèles en étoile afin de faciliter l'analyse des données électorales et l'exploitation des indicateurs utilisés dans le Machine Learning.

Le modèle en étoile se repose sur :

- Une table de faits centrale
- Plusieurs tables de dimensions reliées à cette table principale

Dans notre projet, la table centrale correspond au dataframe consolidé est *training_data*. Cette table regroupe l'ensemble des variables utilisées pour l'apprentissage des modèles de Machine Learning des données socioéconomiques, démographiques, de criminalité et des informations électorales.

Autour de cette table principale gravitent plusieurs dimensions logiques issues du MCD : COMMUNE, INDICATEUR_SOCIO_ECO, CRIMINALITE, RESULTAT_ELECTION, ELECTION.

Pourquoi ce modèle ?

Le modèle en étoile présente plusieurs avantages particulièrement adaptés à notre projet :

Simplicité de lecture et de compréhension

Le schéma est facile à comprendre et à manipuler, ce qui facilite :

- L'exploration des données
- L'analyse statistique
- Les requêtes SQL
- La préparation des données pour le Machine Learning

Optimisation des analyses décisionnelles

Le modèle en étoile est largement utilisé dans les systèmes décisionnels et les data warehouses¹⁴ (DWH) car il permet d'effectuer rapidement des analyses multidimensionnelles.

Dans notre cas, il facilite :

- L'analyse des comportements électoraux
- La comparaison des blocs politiques
- L'étude des relations entre criminalité, économie et résultats électoraux



¹⁴ Entrepôt de données – Cf Glossaire

Centralisation des données pour le Machine Learning

Le dataframe *training_data* agit comme une table de faits centralisée contenant toutes les variables nécessaires à l'entraînement des modèles.

Cette centralisation permet :

- D'éviter les jointures complexes pendant l'entraînement
- D'améliorer les performances
- De simplifier le pipeline de Machine Learning

Meilleure performance des requêtes SQL

Le modèle en étoile réduit le nombre de relations nécessaires entre les tables, ce qui améliore :

- La rapidité des requêtes
- La lisibilité des analyses SQL
- L'exploitation dans SQLite

Architecture adaptée au POC

Dans le cadre d'un Proof of Concept (POC), le modèle en étoile offre un bon compromis entre :

- Simplicité
- Performance
- Maintenabilité

Il permet de construire rapidement une architecture exploitable avant une éventuelle industrialisation plus complexe.

Tables de faits et tables de dimensions

Dans une logique décisionnelle, les données ont été organisées selon deux catégories principales :

Tables de faits	Tables de dimensions
Nombre de voix	Informations géographiques
Taux de participation	Informations temporelles
Taux d'absentions	Caractéristiques des candidats
Pourcentage des votes	Indicateurs socio-économiques
RESULTAT_ELECTION	COMMUNE, CANDIDAT, ELECTION, INDICATEUR_COMMUNE

Légende :

- En **Rouge** : table principale de faits du projet
- En **Orange** : tables principales de dimensions

Les tables de faits contiennent les mesures quantitatives utilisées pour les analyses. Les tables de dimensions apportent le contexte nécessaire à l'interprétation des données.

Cette organisation permet de structurer efficacement les données utilisées dans les traitements analytiques et les modèles de Machine Learning.

D) Stockage des données

Choix de la solution de stockage

Dans le cadre du projet Electio-Analytics, nous avons opté pour SQLite pour le stockage des données, privilégiant une solution légère et facile à déployer par rapport à PostgreSQL.

Tableau comparatif SQLite / PostgreSQL :

SQLite	PostgreSQL
Fonctionne sans serveur	Nécessite un serveur dédié
Stockage dans un fichier local unique (.db)	Base de données gérée par un processus serveur
Installation et déploiement simples	Installation et administration plus complexes
Très léger en ressources	Plus lourd mais plus robuste
Adapté aux projets légers et POC	Adapté aux environnements de production
Intégration simple avec Python et Pandas	Intégration plus complète pour architectures avancées
Utilisation locale et mono-utilisateur	Gestions multi-utilisateurs
Maintenance réduite	Administration et supervision nécessaires
Mise en place rapide	Configuration plus avancée
Idéal pour le stockage structuré de petits/moyens datasets	Idéal pour de gros volumes de données et applications distribuées

Ce choix est optimal pour un Proof of Concept (POC), où les besoins se limitent au stockage structuré des datasets, à leur utilisation dans les scripts d'entraînement et de prédiction, et à la reproductibilité du pipeline, sans nécessiter d'architecture multi-utilisateur ou d'infrastructure serveur.

Les jeux de données préalablement nettoyés sont intégrés dans une base SQLite, où ils sont organisés en deux tables spécifiques : une table **training_data** dédiée à l'apprentissage du modèle, et une table **prediction_data** réservée aux opérations de prédiction. Les scripts Python de machine Learning exploitent ces tables via Pandas, assurant ainsi un pipeline de traitement des données structuré, clair et reproductible.

Implémentation de SQLite

Dans le cadre du projet Electio-Analytics, nous avons intégré SQLite afin de centraliser les datasets nettoyés et préparés pour le Machine Learning au sein d'une base de données relationnelle légère et structurée.

À l'issue des phases de nettoyage, d'harmonisation, de transformation et de fusion des différentes sources de données effectuées avec Python et Pandas, les dataframes finaux sont exportés automatiquement vers une base SQLite.

Les données issues des fichiers CSV sont d'abord fusionnées dans un dataframe principal (*df_final*) correspondant au jeu de données final destiné au Machine Learning.

SQLite a été utilisé comme base de données locale afin de stocker le dataframe final issu des traitements de nettoyage et de fusion des différentes sources de données.

Les données nettoyées ont d'abord été chargées avec Python et pandas depuis plusieurs fichiers CSV. Elles ont ensuite été fusionnées dans un dataframe unique appelé *df_final*, correspondant au dataset final utilisé pour le Machine Learning.

Ce dataframe est ensuite stocké dans des tables SQL dédiées :

- *training_data* pour l'entraînement et l'évaluation des modèles
- *prediction_data* pour les opérations de prédiction

Cette approche permet :

- De centraliser les datasets nettoyés
- De structurer les données sous forme de tables relationnelles
- De faciliter les contrôles et les traitements
- D'améliorer la lisibilité et la reproductibilité du pipeline ETL
- De simplifier l'exploitation des données par les scripts Python dédiés au Machine Learning

Les captures d'écran ci-dessous illustrent l'intégration des données dans DB Browser for SQLite ainsi que plusieurs requêtes SQL utilisées pour vérifier et analyser les données stockées dans la base relationnelle.

Le script *Train_dataframe.py* permet de générer automatiquement la base de données SQLite *Train_dataframe.db* à l'aide de la bibliothèque *sqlite3*.

The screenshot shows the DB Browser for SQLite interface. The 'training_data' table is selected in the left sidebar. The main window displays the table's structure and data. The table has 13 columns: commune, localisation, classe_politique, taux_chomage, population, superficie_km2, densite, pct_jeunes, pct_seniors, age_median, taux_immigration, and nb_associa. The data is displayed in a table with 3 rows.

	commune	localisation	classe_politique	taux_chomage	population	superficie_km2	densite	pct_jeunes	pct_seniors	age_median	taux_immigration	nb_associa
1	01004	Amberieu-en-Bugey	extreme_droite	13.34	14134	24	570.5	31.46	18.51	37.5	9.34	
2	01004	Amberieu-en-Bugey	gauche	1.47	256	9	27.1	29.09	23.64	42.5	0.46	
3	01004	Amberieu-en-Bugey	extreme_droite	6.64	779	16	48.7	27.43	17.14	47.5	1.29	

Cette table regroupe les variables socio-économiques, démographiques, criminelles et électorales utilisées pour entraîner les modèles de Machine Learning.

A partir de *training_data*, on peut créer les tables du MCD :

```
CREATE TABLE CRIMINALITE AS
SELECT
    code_insee,
    annee,
    taux_cambrjolages_logement,
    taux_degradations AS taux_degradation,
    taux_trafic_stupefiants,
    taux_usage_stupefiants,
    taux_violences_intrafamiliales,
    taux_violences_sexuelles,
    taux_vols_avec_armes,
    taux_vols_violents_sans_arme,
    taux_vols_vehicule
FROM training_data;
```

Structure de la base de données									
Parcourir les données									
Éditer les pragmas									
Exécuter le SQL									
Table : CRIMINALITE									
	code_insee	annee	taux_cambriolages_logement	taux_degradation	taux_trafic_stupefiants	taux_usage_stupefiants	taux_violences_intrafamiliales	taux_violences_sexuelles	taux_vols_avec_arme
	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre
1	01001	2022	7.062842	3.9266484	0.0	0.0	2.0455127	1.2248166	0
2	01002	2022	7.062842	3.9266484	0.0	0.0	0.0	0.0	0
3	01004	2022	5.6437863	9.9009901	0.90009	4.50045	4.7576186	5.4648322	0.11267
4	01005	2022	17.3732655	5.2164841	0.0	1.0507524	2.0455127	1.2248166	0
5	01006	2022	7.062842	3.9266484	0.0	0.0	2.0455127	0.0	0
6	01007	2022	15.3584689	3.8896747	0.3516844	1.0507524	2.0455127	1.2248166	0

DB Browser for SQLite

Nous avons utilisé DB Browser for SQLite afin de visualiser, administrer et vérifier le contenu de la base SQLite du projet via une interface graphique. Cet outil nous a notamment permis :

- D'explorer les tables SQL
- De contrôler les données stockées
- De vérifier la cohérence des colonnes
- D'exécuter des requêtes SQL
- De valider l'intégration correcte des jeux de données dans la base relationnelle

Il facilite également les phases de débogage, de contrôle qualité et de vérification des transformations effectuées dans le pipeline ETL.

Utilisation du logiciel

Nous avons employé DB Browser for SQLite pour bénéficier d'une interface graphique intuitive facilitant l'interaction avec la base de données SQLite, sans recourir exclusivement aux requêtes SQL en ligne de commande. Cet outil nous a permis :

- De vérifier les données insérées dans les tables
- De contrôler les types des colonnes
- D'examiner rapidement les jeux de données
- De réaliser des vérifications de cohérence
- De simplifier les phases de débogage du pipeline ETL et Machine Learning

Visualisation du dataframe dans DB Browser for SQLite

Les jeux de données nettoyés et normalisés sont conservés dans la base SQLite sous la forme de tables relationnelles structurées.

La capture d'écran ci-dessous illustre un exemple de visualisation des tables SQL dans DB Browser for SQLite, après l'intégration des données issues du projet.

DB Browser for SQLite - D:\Projet MSPR Data2\ei1_i1_mspr_data\data_cleaned\Train_dataframe.db									
Fichier Édition Vue Outils Aide									
Nouvelle base de données Ouvrir une base de données Enregistrer les modifications Annuler les modifications Annuler Ouvrir un projet Enregistrer le projet Attacher une base de données									
Structure de la base de données Parcourir les données Éditer les pragmas Exécuter le SQL									
SQL 1*									
67									
68	ROUND (AVG(taux_violences_sexuelles), 2)								
69	AS violences_sexuelles_moyennes,								
70									
71	ROUND(AVG(taux_vols_avec_arme), 2)								
	classe_politique	chomage_moyen	revenu_median_moyen	population_moyenne	superficie_moyenne	densite_population_moyenne	pct_jeunes_moyen	pct_seniors_moyen	age_median_moyen
1	extreme_droite	9.12	22828.85	1165.36	14.32	97.96	26.09	22.92	46.23
2	centre	7.68	24127.18	1760.97	16.04	179.22	24.45	25.47	48.3
3	gauche	10.88	22090.79	5359.41	17.48	467.11	23.86	25.29	48.1
4	droite	6.75	21560.0	123.55	9.55	10.2	23.89	24.82	47.05

Requêtes SQL

Plusieurs requêtes SQL ont été exécutées pour valider le contenu des tables ainsi que la cohérence des données persistées dans SQLite.

Exemples de requêtes appliquées :

```
SELECT
    classe_politique,
    -- =====
    -- ECONOMIE
    -- =====
    ROUND(AVG(taux_chomage), 2)
        AS chomage_moyen,

    ROUND(AVG(revenu_median_final), 2)
        AS revenu_median_moyen,

    -- =====
    -- SOCIAL
    -- =====
    ROUND(AVG(pourcentage_ouvriers), 2)
        AS ouvriers_moyen,

    ROUND(AVG(pourcentage_cadres), 2)
        AS cadres_moyen,

    ROUND(AVG(pourcentage_employes), 2)
        AS employes_moyen,

    -- =====
    -- DEMOGRAPHIE
    -- =====
    ROUND(AVG(population), 2)
        AS population_moyenne,

    ROUND(AVG(densite), 2)
        AS densite_population_moyenne,

    ROUND(AVG(pct_jeunes), 2)
        AS pct_jeunes_moyen,

    ROUND(AVG(pct_seniors), 2)
        AS pct_seniors_moyen,

    ROUND(AVG(age_median), 2)
        AS age_median_moyen,

    -- =====
    -- IMMIGRATION
    -- =====
    ROUND(AVG(taux_immigration), 2)
        AS immigration_moyenne
```

Cette requête SQL permet d'effectuer une analyse agrégée des indicateurs socio-économiques, démographiques et territoriaux en fonction du bloc politique majoritaire des communes.

L'objectif est d'identifier les tendances moyennes associées aux différentes orientations politiques afin d'étudier les relations potentielles entre les caractéristiques d'un territoire et les résultats électoraux.

classe_politique	chomage_moyen	revenu_median_moyen	ouvriers_moyen	cadres_moyen	employes_moyen	agri_moyen	population_moyenne	densite_population_moyenne	pct_jeunes_moyen
1 extreme_droite	9.12	22828.85	39.59	14.96	38.7	6.76	1165.36	97.96	26.09
2 centre	7.68	24127.18	32.23	21.58	36.79	9.4	1760.97	179.22	24.45
3 gauche	10.88	22090.79	31.47	21.21	38.03	9.3	5359.41	467.11	23.86
4 droite	6.75	21560.0	30.27	11.95	31.77	26.01	123.55	10.2	23.89

pct_seniors_moyen	age_median_moyen	immigration_moyenne	associations_moyennes	entreprises_moyennes	nb_communes
22.92	46.23	2.94	0.51	14.81	20957
25.47	48.3	3.44	0.84	24.68	9566
25.29	48.1	5.8	2.71	97.47	4021
24.82	47.05	5.09	0.18	1.82	22

VI. Les variables et leur intérêt

Liste des indicateurs par critère et explication

Nous avons analysé et choisi chaque variable pour chaque critère de la matrice X. Cette approche nous a permis d'éviter de générer trop de bruit pour le modèle mais également de cibler les indicateurs qui nous semblaient les plus pertinent et impactant dans la corrélation des critères.

Variable commune à tous les datasets

- **CODEGEO_2022" et "CODEGEO_2024"**

Justification : La variable CODEGEO est fondée sur les référentiels officiels des communes françaises, tels que publiés par l'INSEE pour les millésimes 2022 et 2024. Cet identifiant unique permet d'identifier sans ambiguïté chaque commune et de lier les données entre les différents jeux de données mobilisés dans le cadre du projet. Son utilisation garantit la cohérence des traitements géographiques, notamment lors des opérations de jointure entre datasets hétérogènes. En outre, cette variable constitue un outil essentiel pour la réalisation d'analyses spatiales, le ciblage politique à l'échelle locale, ainsi que l'étude des dynamiques et des tendances électorales observées au niveau communal.

Tableau récapitulatif variables par critère :

Critère	Variable	Type	Volumétrie brute	Intérêt
Revenus médians	pauvre	Catégorielle binaire		Identifier les communes aux revenus faibles et étudier l'impact de la précarité et des inégalités économiques sur les comportements électoraux
	moyen			Analyser les comportements électoraux des classes moyennes face aux enjeux économiques et sociaux
	riche			Étudier l'influence du niveau de vie et du dynamisme économique sur les préférences politiques locales
	revenus_median_final	Numérique		Analyser l'impact du niveau de vie, du pouvoir d'achat et des inégalités socio-économiques sur les comportements électoraux
Taux de chômage	taux_chomage	Numérique		Étudier l'impact de la situation économique, de l'emploi et de la précarité sur les orientations électorales
Catégorie sociale	pourcentage_ouvriers	Numérique (%)		Analyser l'influence des catégories populaires et industrielles sur les comportements électoraux
	pourcentage_cadres			Étudier l'impact des populations qualifiées et favorisées sur les tendances politiques locales
	pourcentage_employes			Représenter les comportements électoraux des classes salariales intermédiaires
	pourcentage_agri			Identifier les territoires ruraux et l'influence des enjeux agricoles sur les préférences politiques

	population			Étudier l'impact de la population sur les comportements électoraux locaux
Densité de population	superficie_km2	Numérique		Contextualiser les caractéristiques territoriales et l'aménagement des communes
	densite			Étudier les différences de comportements électoraux entre espaces urbains, périurbains et ruraux
Démographie	pct_jeunes	Numérique (%)		Analyser l'influence des populations jeunes sur les comportements électoraux
	pct_seniors			Étudier l'impact du vieillissement de la population sur les tendances politiques locales
	age_median	Numérique		Fournir une vision globale de la structure générationnelle d'un territoire
Taux d'immigration	taux_immigration	Numérique (%)		Étudier l'impact des dynamiques migratoires et de la diversité culturelle sur les comportements électoraux
Nombre de créations d'associations	nb_associations	Numérique		Mesurer le dynamisme social et l'engagement citoyen local
Nombre de créations d'entreprises	nb_entreprises	Numérique		Évaluer le dynamisme économique et entrepreneurial d'un territoire
Criminalité	diff	Catégorielle binaire		Identifier les communes dont les données de criminalité sont exploitables dans l'analyse
	non_diff			Identifier les communes soumises au secret statistique
	taux_degradation	Numérique (%)		Étudier l'impact des problématiques de sécurité et de dégradation sur les comportements électoraux
	taux_cambriolages_logement			Analyser l'influence du sentiment d'insécurité résidentielle
	taux_violences_intrafamiliales			Étudier certaines fragilités sociales influençant les comportements électoraux
	taux_violences_sexuelles			Étudier certaines problématiques de sécurité et de cohésion sociale
	taux_trafic_stupefiants			Étudier l'impact du trafic de stupéfiants sur les problématiques de sécurité locales
	taux_usages_stupefiants			Analyser certaines problématiques sociales et sanitaires locales
	taux_vols_violents_sans_arme			Évaluer certaines problématiques de délinquance et de sécurité publique
	taux_vols_avec_armes			Étudier l'impact de la délinquance sur le sentiment d'insécurité
	taux_vols_vehicule			Analyser l'impact des vols de véhicules sur les comportements électoraux
Résultats du 1er tour des	droite			Représente le pourcentage de votes obtenu par le bloc de droite afin d'identifier les territoires sensibles aux thématiques économiques, sécuritaires et conservatrices
	gauche			Permet d'étudier les communes davantage orientées vers des enjeux sociaux, écologiques et redistributifs

élections présidentielles 2022	centre	Numérique (%)		Permet d'identifier les territoires favorables aux orientations modérées, libérales et centristes
	extreme_droite			Permet d'analyser les territoires où les problématiques liées à la sécurité, à l'immigration et à l'identité nationale influencent fortement les comportements électoraux
	extreme_gauche			Permet d'identifier les territoires sensibles aux discours anticapitalistes, sociaux et contestataires
Résultats du 1er tour des élections présidentielles 2022	bloc_politique_majoritaire	Catégorielle multiclasses		Correspond au bloc politique majoritaire de chaque commune à prédire par le modèle de Machine Learning

Légende des rôles :

- En **vert** : Feature¹⁵ (X)
- En **bleu** : Target (Y)
- En **rouge** : Variable cible finale (Y)



¹⁵ Cf Glossaire

VII. Pipeline de données ETL

A) Extraction et analyse exploratoire des données (EDA)

Lecture des jeux de données bruts

Dans le cadre de l'analyse exploratoire des données (EDA), l'examen des jeux de données bruts a été conduit selon deux étapes distinctes :

- Une première phase de lecture permettant d'identifier la structure globale des datasets
- Une seconde phase d'analyse et de vérification des données

La première étape avait pour but d'extraire les informations essentielles de chaque jeu de données, en vue de préparer les opérations de nettoyage, d'harmonisation et de transformation exécutées au sein du pipeline ETL.

Pour chaque dataset, plusieurs éléments ont été analysés :

- Les dimensions du jeu de données (shape)
- Un aperçu des premières lignes (head)
- Les types de données des colonnes (info)
- Les noms et la structure des colonnes
- Ainsi que la cohérence globale des données

Cette phase permet :

- De mieux comprendre la structure des données
- D'identifier les colonnes exploitables
- De repérer d'éventuelles incohérences
- De préparer les futures étapes de transformation et de fusion des datasets

EDA pré-cleaning du dataset - **00_insee_code_referentiel.csv**

- *Lecture du dataset*

```
# CONFIGURATION

# Chemin vers le fichier brut du référentiel INSEE 2022
FILE_RAW = "data_raw/2022_raw/0_code_insee_2022/communes_2022.csv"

# LECTURE DU DATASET BRUT

# Lecture du fichier CSV brut :
# - sep="," : séparateur du fichier
# - dtype=str : permet de conserver les codes INSEE avec leurs zéros
# - encoding="utf-8" : gestion correcte des accents
df = pd.read_csv(
    FILE_RAW,
    sep=",",
    dtype=str,
    encoding="utf-8"
)
```

Nous avons configuré le paramètre `dtype=str` afin d'éviter que pandas convertisse automatiquement les valeurs des colonnes lors du chargement du fichier. Ainsi, les données sont lues comme des chaînes de caractères et non

interprétées comme des valeurs numériques, ce qui permet notamment de conserver l'intégrité des codes INSEE et leurs zéros significatifs.

- *Affichage de la structure globale*

```
# INFOS GÉNÉRALES

# Affichage des dimensions :
# nombre de lignes et de colonnes
print("\n--- DIMENSIONS DU DATASET ---")
print(df.shape)

# Aperçu des premières lignes du dataset
print("\n--- APERÇU DES DONNÉES ---")
print(df.head())

# Affichage des types des colonnes :
# utile pour détecter les incohérences de format
print("\n--- TYPES DES COLONNES ---")
print(df.info())

# Liste des colonnes disponibles dans le dataset
print("\n--- NOMS DES COLONNES ---")
print(df.columns)
```

L'analyse des informations générales permet de vérifier la structure du référentiel INSEE avant toute phase de nettoyage ou de transformation des données.

- *Résultats du code*

```
--- DIMENSIONS DU DATASET ---
(37601, 12)

--- APERÇU DES DONNÉES ---
```

	TYPECOM	COM	REG	DEP	CTCD	ARR	TNCC	NCC	NCCENR	LIBELLE	CAN	COMPARENT
0	COM	01001	84	01	01D	012	5	ABERGEMENT CLEMENCIAT	Abergement-Clémenciat	L'Abergement-Clémenciat	0108	NaN
1	COM	01002	84	01	01D	011	5	ABERGEMENT DE VAREY	Abergement-de-Varey	L'Abergement-de-Varey	0101	NaN
2	COM	01004	84	01	01D	011	1	AMBERIEU EN BUGEY	Ambérieu-en-Bugey	Ambérieu-en-Bugey	0101	NaN
3	COM	01005	84	01	01D	012	1	AMBERIEUX EN DOMBES	Ambérieux-en-Dombes	Ambérieux-en-Dombes	0122	NaN
4	COM	01006	84	01	01D	011	1	AMBLEON	Ambléon	Ambléon	0104	NaN

Le dataset contient 37 601 lignes et 12 colonnes, ce qui correspond au volume attendu pour le référentiel des communes françaises. L'aperçu des premières lignes permet de contrôler visuellement le bon chargement du fichier ainsi que la cohérence des données présentes dans les différentes colonnes.



```

--- TYPES DES COLONNES ---
<class 'pandas.DataFrame'>
RangeIndex: 37601 entries, 0 to 37600
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  -
0   TYPECOM     37601 non-null   str
1   COM         37601 non-null   str
2   REG         35000 non-null   str
3   DEP         35000 non-null   str
4   CTCD        35000 non-null   str
5   ARR         34983 non-null   str
6   TNCC        37601 non-null   str
7   NCC         37601 non-null   str
8   NCCENR      37601 non-null   str
9   LIBELLE     37601 non-null   str
10  CAN         34855 non-null   str
11  COMPARENT   2646 non-null    str
dtypes: str(12)
memory usage: 5.6 MB
None

--- NOMS DES COLONNES ---
Index(['TYPECOM', 'COM', 'REG', 'DEP', 'CTCD', 'ARR', 'TNCC', 'NCC', 'NCCENR',
      'LIBELLE', 'CAN', 'COMPARENT'],
      dtype='str')

```

La liste des colonnes permet également d'identifier les champs disponibles dans le référentiel brut, comme :

- Le type de commune (TYPECOM)
- Le code INSEE (COM)
- Le département (DEP)
- La région (REG)
- Le libellé de la commune (LIBELLE)

Cette première étape d'EDA permet donc de valider l'intégrité structurelle du dataset avant les contrôles de qualité et les opérations de nettoyage.

À la suite de l'analyse exploratoire réalisée sur le fichier brut, plusieurs opérations de nettoyage et de normalisation ont été appliquées afin de produire un référentiel exploitable pour les futures jointures du projet.

EDA pré-cleaning du dataset - 01_revenus_2022.csv

L'analyse exploratoire du dataset des revenus médians communaux a permis d'identifier plusieurs problématiques de qualité de données avant traitement.

```

PS C:\Users\amamazouz\OneDrive - EDIPOLES\Bureau\MSPR DATA\eisi_i1_mspr_data> py '.\1. 2022_EDA_PRE_Cleaning\01_EDA_BRUT_revenus_2022.py'

--- DIMENSIONS DU DATASET ---
(34929, 732)

--- APERÇU DES DONNÉES ---
  CODGEO  NBMEN21  NBPERS21  NBUC21   Q121   Q221   Q321   Q3_Q1   ...  OPR6PBEN21  OPR6PPEN21  OPR6PPAT21  OPR6PPSOC21  OPR6PPFAM21  OPR6PPMINI21  OPR6PPLOGT21  OPR6PPIMPOT21
0  01001      346      895    590,8     s  25820     s     s  ...      s         s         s         s         s         s         s         s
1  01002      115      266    181,0     s  24480     s     s  ...      s         s         s         s         s         s         s         s
2  01004     6855     15092  10398,2  15800  21660  28430  12630  ...      s         s         s         s         s         s         s         s
3  01005       800      2028   1329,7  20010  24610  31180  11170  ...      s         s         s         s         s         s         s         s
4  01006        51       107    76,6     s  24210     s     s  ...      s         s         s         s         s         s         s         s

```

Le dataset brut contenait :

- 34 929 lignes
- 732 colonnes
- Plusieurs valeurs non exploitables dans les colonnes de revenus

En effet, certaines communes du dataset Revenus médians, possèdent des valeurs absentes remplacées par la mention "s". Ces absences concernent principalement des communes caractérisées par :

- Un faible nombre d'habitants
- Un nombre limité de déclarations
- Des revenus significativement atypiques

Dans ces cas, les données sont délibérément occultées ou non diffusées afin de prévenir toute identification, directe ou indirecte, des individus par recoupement d'informations.

EDA pré-cleaning du dataset - 02_Taux_chomage_2022.csv

L'analyse exploratoire du dataset chômage a permis d'identifier la structure du fichier brut fourni par l'INSEE.

Le dataset contient :

- 34 858 lignes
- 26 colonnes
- Des indicateurs liés à l'emploi et au chômage selon : le sexe, la nationalité et le statut d'activité

```
# INFOS GÉNÉRALES

print("\n--- DIMENSIONS DU DATASET ---")
print(df.shape)

print("\n--- APERÇU DES DONNÉES ---")
print(df.head())

print("\n--- TYPES DES COLONNES ---")
print(df.info())

print("\n--- NOMS DES COLONNES ---")
print(df.columns)
```

```
--- DIMENSIONS DU DATASET ---
(34858, 26)

--- APERÇU DES DONNÉES ---
  CODGEO  LIBGEO  INATC1_SEXE1_TACTR11  INATC1_SEXE1_TACTR12  INATC1_SEXE1_TACTR21  ...  INATC2_SEXE2_TACTR12  INATC2_SEXE2_TACTR21  I
0  01001  L'Abergement-Clémenciat         213             11             95  ...              0              0
1  01002  L'Abergement-de-Varey           71              1             29  ...              0              0
2  01004  Ambérieu-en-Bugey      3111.26859791787      327.844212949624      1317.86234736408  ...     107.827652191957     68.2145639007716
3  01005  Ambérieux-en-Dombes      484.706702232599      21.8454536077272      198.69924253316  ...     1.07568220668936     2.36171852836686
4  01006  Ambléon                    26              2             19  ...              0              1
```

Les principales colonnes identifiées dans le dataset correspondent notamment : à l'emploi des hommes et des femmes de nationalité française et étrangère ainsi qu'aux chômeurs hommes et femmes de nationalité française et étrangère.



```

--- NOMS DES COLONNES ---
Index(['CODGEO', 'LIBGEO', 'INATC1_SEXE1_TACTR11', 'INATC1_SEXE1_TACTR12',
      'INATC1_SEXE1_TACTR21', 'INATC1_SEXE1_TACTR22', 'INATC1_SEXE1_TACTR24',
      'INATC1_SEXE1_TACTR26', 'INATC1_SEXE2_TACTR11', 'INATC1_SEXE2_TACTR12',
      'INATC1_SEXE2_TACTR21', 'INATC1_SEXE2_TACTR22', 'INATC1_SEXE2_TACTR24',
      'INATC1_SEXE2_TACTR26', 'INATC2_SEXE1_TACTR11', 'INATC2_SEXE1_TACTR12',
      'INATC2_SEXE1_TACTR21', 'INATC2_SEXE1_TACTR22', 'INATC2_SEXE1_TACTR24',
      'INATC2_SEXE1_TACTR26', 'INATC2_SEXE2_TACTR11', 'INATC2_SEXE2_TACTR12',
      'INATC2_SEXE2_TACTR21', 'INATC2_SEXE2_TACTR22', 'INATC2_SEXE2_TACTR24',
      'INATC2_SEXE2_TACTR26'],
      dtype='str')

```

Ces colonnes seront ensuite utilisées dans le pipeline ETL afin de construire les indicateurs agrégés nécessaires au calcul du taux de chômage communal.

Les contrôles réalisés sur la clé géographique CODGEO montrent l'absence de doublons dans le dataset, ainsi qu'aucune duplication des codes INSEE. La vérification de la longueur des identifiants confirme également une homogénéité sur 5 caractères pour l'ensemble des codes.

```

--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
34858

--- LONGUEUR DES CODES INSEE ---
CODGEO
5      34858
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0

```

```

# ANALYSE DES DOUBLONS

print("\n--- DOUBLONS ---")
print(df.duplicated().sum())

# ANALYSE DES CODES INSEE

if "CODGEO" in df.columns:

    print("\n--- NOMBRE DE CODES INSEE UNIQUES ---")
    print(df["CODGEO"].nunique())

    print("\n--- LONGUEUR DES CODES INSEE ---")
    print(df["CODGEO"].astype(str).str.len().value_counts())

    print("\n--- DOUBLONS SUR CODE INSEE ---")
    print(df.duplicated(subset=["CODGEO"]).sum())

```

Le dataset brut ne présente donc pas d'anomalie structurelle concernant les identifiants communaux.

EDA pré-cleaning du dataset - 03_Categorie_sociale_2022.csv

L'analyse exploratoire du dataset des catégories sociales a permis d'identifier la structure du fichier brut fourni par l'INSEE.

Le dataset contient : 34 858 lignes, 108 colonnes ainsi que des indicateurs démographiques et socio-professionnels répartis selon l'âge, la catégorie sociale et le statut d'activité.

```

--- DIMENSIONS DU DATASET ---
(34858, 108)

--- APERÇU DES DONNÉES ---
CODGEO REG DEP LIBGEO P22_POP ... C22_POP55P_STAT_GSEC14_24 C22_POP55P_STAT_GSEC15_25 C22_POP55P_STAT_GSEC16_26
0 01001 84 01 L'Abergement-Clémenciat 859 ... 14.7257142857143 9.81714285714286 24.5428571428572
1 01002 84 01 L'Abergement-de-Varey 273 ... 9.92727272727272 0 4.96363636363636
2 01004 84 01 Ambérieu-en-Bugey 15554 ... 350.103399674236 392.002492694368 247.714835981047
3 01005 84 01 Ambérieux-en-Dombes 1917 ... 51.2648356217207 34.0868488543894 11.2725747247054
4 01006 84 01 Ambléon 114 ... 5.18181818181818 0 0

[5 rows x 108 columns]

```

Les contrôles effectués sur la clé géographique CODGEO montrent : l'absence de doublons globaux dans le dataset, l'absence de doublons sur les codes INSEE, ainsi qu'une longueur homogène des codes INSEE sur 5 caractères.

```

--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
34858

--- LONGUEUR DES CODES INSEE ---
CODGEO
5    34858
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0

```

Le dataset brut ne présente donc pas d'anomalie structurelle sur les identifiants géographiques.

Plusieurs colonnes sont liées aux catégories socio-professionnelles, notamment les agriculteurs, les cadres, les employés et les ouvriers, répartis selon différentes tranches d'âge : 15–24 ans, 25–54 ans et 55 ans et plus.

```

--- NOMS DES COLONNES ---
Index(['CODGEO', 'REG', 'DEP', 'LIBGEO', 'P22_POP', 'P22_POP0014',
      'P22_POP1529', 'P22_POP3044', 'P22_POP4559', 'P22_POP6074',
      ...,
      'C22_POP2554_STAT_GSEC40', 'C22_POP55P', 'C22_POP55P_STAT_GSEC11_21',
      'C22_POP55P_STAT_GSEC12_22', 'C22_POP55P_STAT_GSEC13_23',
      'C22_POP55P_STAT_GSEC14_24', 'C22_POP55P_STAT_GSEC15_25',
      'C22_POP55P_STAT_GSEC16_26', 'C22_POP55P_STAT_GSEC32',
      'C22_POP55P_STAT_GSEC40'],
      dtype='str', length=108)

```

EDA pré-cleaning du dataset - 04_Densite_population_2022.csv

L'étude préalable du dataset de densité de population a permis de comprendre l'organisation des données démographiques communales fournies dans le fichier source.

Le fichier brut regroupe 35 010 communes pour un total de 39 colonnes contenant différentes informations administratives, territoriales et statistiques.

```

--- DIMENSIONS DU DATASET ---
(35010, 39)

--- APERÇU DES DONNÉES ---

```

	Unnamed: 0	code_insee		url_wikipedia	url_villedereve
0	0	01001	...	https://fr.wikipedia.org/wiki/fr:L'Abergement-...	https://villedereve.fr/ville/01001-l-abergemen...
1	1	01002	...	https://fr.wikipedia.org/wiki/fr:L'Abergement-...	https://villedereve.fr/ville/01002-l-abergemen...
2	2	01004	...	https://fr.wikipedia.org/wiki/fr:Ambérieu-en-B...	https://villedereve.fr/ville/01004-amberieu-en...
3	3	01005	...	https://fr.wikipedia.org/wiki/fr:Ambérieux-en-...	https://villedereve.fr/ville/01005-amberieux-e...
4	4	01006	...	https://fr.wikipedia.org/wiki/fr:Ambléon	https://villedereve.fr/ville/01006-ambleon

L'analyse a également montré que plusieurs colonnes présentes dans le dataset n'étaient pas nécessaires aux traitements du projet, notamment certaines informations descriptives, géographiques ou des liens externes.

```
--- NOMS DES COLONNES ---
Index(['Unnamed: 0', 'code_insee', 'nom_standard', 'nom_sans_prenom', 'nom_a',
      'nom_de', 'nom_sans_accent', 'nom_standard_majuscule', 'typecom',
      'typecom_texte', 'reg_code', 'reg_nom', 'dep_code', 'dep_nom',
      'canton_code', 'canton_nom', 'epci_code', 'epci_nom', 'academie_code',
      'academie_nom', 'code_postal', 'codes_postaux', 'zone_emploi',
      'code_insee_centre_zone_emploi', 'population', 'superficie_hectare',
      'superficie_km2', 'densite', 'altitude_moyenne', 'altitude_minimale',
      'altitude_maximale', 'latitude_mairie', 'longitude_mairie',
      'latitude_centre', 'longitude_centre', 'grille_densite', 'gentile',
      'url_wikipedia', 'url_villedereve'],
      dtype='str')
```

Les vérifications réalisées sur la variable code_insee confirment l'absence de doublons et une standardisation correcte des identifiants géographiques sur 5 caractères.

```
--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
35010

--- LONGUEUR DES CODES INSEE ---
code_insee
5      35010
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0

--- COLONNES NUMÉRIQUES PRÉSENTES ---
['population', 'superficie_km2', 'densite']
```

Les traitements se sont donc concentrés sur les variables utiles à l'analyse démographique : la population, la superficie en km² et la densité de population associées à chaque commune.

EDA pré-cleaning du dataset - 05_Demographie_2022.csv

L'analyse exploratoire initiale du fichier de démographie a permis d'examiner la structure générale des données communales avant les étapes de nettoyage et de transformation.

Le dataset brut comporte 38 214 lignes et 46 colonnes contenant des informations administratives ainsi que des données de population réparties par tranche d'âge et par sexe.

```
--- DIMENSIONS DU DATASET ---
(38214, 46)

--- APERÇU DES DONNÉES ---
  RR  DR  CR  STABLE  DR24  ...  ageq_rec18s2rpop2022  ageq_rec19s1rpop2022  ageq_rec19s2rpop2022  ageq_rec20s1rpop2022  ageq_rec20s2rpop2022
0  84  01  001      1    01  ...      4.90857142857143      0      0      4.90857142857143      4.90857142857143
1  84  01  002      1    01  ...      4.96363636363636      0      0      4.96363636363636      4.96363636363636
2  84  01  003      0    01  ...      NaN      NaN      NaN      NaN      NaN
3  84  01  004      1    01  ...     134.611519649174     30.4079005011264     133.75984250758      6.65046170611797     23.6130772440343
4  84  01  005      1    01  ...     17.4471114476045      0      0      0      5.90541204262588

[5 rows x 46 columns]
```

Cette phase d'exploration a également permis d'identifier les différentes colonnes techniques utilisées dans le fichier source, notamment les variables DR et CR servant à reconstruire le code INSEE des communes.

```
--- NOMS DES COLONNES ---
Index(['RR', 'DR', 'CR', 'STABLE', 'DR24', 'LIBELLE', 'ageq_rec01s1rpop2022',
      'ageq_rec01s2rpop2022', 'ageq_rec02s1rpop2022', 'ageq_rec02s2rpop2022',
      'ageq_rec03s1rpop2022', 'ageq_rec03s2rpop2022', 'ageq_rec04s1rpop2022',
      'ageq_rec04s2rpop2022', 'ageq_rec05s1rpop2022', 'ageq_rec05s2rpop2022',
      'ageq_rec06s1rpop2022', 'ageq_rec06s2rpop2022', 'ageq_rec07s1rpop2022',
      'ageq_rec07s2rpop2022', 'ageq_rec08s1rpop2022', 'ageq_rec08s2rpop2022',
      'ageq_rec09s1rpop2022', 'ageq_rec09s2rpop2022', 'ageq_rec10s1rpop2022',
      'ageq_rec10s2rpop2022', 'ageq_rec11s1rpop2022', 'ageq_rec11s2rpop2022',
      'ageq_rec12s1rpop2022', 'ageq_rec12s2rpop2022', 'ageq_rec13s1rpop2022',
      'ageq_rec13s2rpop2022', 'ageq_rec14s1rpop2022', 'ageq_rec14s2rpop2022',
      'ageq_rec15s1rpop2022', 'ageq_rec15s2rpop2022', 'ageq_rec16s1rpop2022',
      'ageq_rec16s2rpop2022', 'ageq_rec17s1rpop2022', 'ageq_rec17s2rpop2022',
      'ageq_rec18s1rpop2022', 'ageq_rec18s2rpop2022', 'ageq_rec19s1rpop2022',
      'ageq_rec19s2rpop2022', 'ageq_rec20s1rpop2022', 'ageq_rec20s2rpop2022'],
      dtype='str')
```

Les contrôles réalisés sur cette clé géographique montrent l'absence de doublons communaux ainsi qu'une cohérence globale du format des identifiants territoriaux.

```
--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
38214

--- LONGUEUR DES CODES INSEE ---
code_insee
5      38102
6       112
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0
```

Les contrôles réalisés sur cette clé géographique montrent l'absence de doublons communaux ainsi qu'une cohérence globale du format des identifiants territoriaux. L'analyse met toutefois en évidence la présence minoritaire de certains codes INSEE composés de 6 caractères, correspondant à des cas administratifs spécifiques présents dans les données INSEE.

EDA pré-cleaning du dataset - 06_Taux_immigration_2022.csv

L'analyse exploratoire du dataset met en évidence un fichier composé de 34 858 lignes et 26 colonnes, correspondant aux communes françaises référencées dans les données INSEE. Aucun doublon global ni doublon sur la clé géographique CODGEO n'a été détecté, garantissant l'unicité des enregistrements communaux.

```
--- DIMENSIONS DU DATASET ---
(34858, 26)

--- APERÇU DES DONNÉES ---
  CODGEO  LIBGEO  INATC1_SEXE1_TACTR11  INATC1_SEXE1_TACTR12  ...  INATC2_SEXE2_TACTR21  INATC2_SEXE2_TACTR22  INATC2_SEXE2_TACTR24  INATC2_SEXE2_TACTR25
0  01001  L'Abergement-Clémenciat          213              11  ...              0              0              0
1  01002  L'Abergement-de-Varey           71              1  ...              0              0              0
2  01004  Ambérieu-en-Bugey      3111.26859791787      327.844212949624  ...      68.2145639007716      31.7775811246847      133.247842801451      32.640512377227
3  01005  Ambérieux-en-Dombes      484.706702232599      21.8454536077272  ...      2.36171852836686              0      1.07568220668936      1.0266606265081
4  01006  Ambléon                26              2  ...              1              0              0
```

Le contrôle de la structure des identifiants territoriaux montre également que l'ensemble des codes INSEE possède une longueur normalisée de 5 caractères, assurant la cohérence des futures opérations de jointure avec les autres datasets du projet.

```
--- LONGUEUR DES CODES INSEE ---
code_insee
5    34858
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0
```

```
--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
34858
```

```
--- NOMS DES COLONNES ---
Index(['CODGEO', 'LIBGEO', 'INATC1_SEXE1_TACTR11', 'INATC1_SEXE1_TACTR12',
      'INATC1_SEXE1_TACTR21', 'INATC1_SEXE1_TACTR22', 'INATC1_SEXE1_TACTR24',
      'INATC1_SEXE1_TACTR26', 'INATC1_SEXE2_TACTR11', 'INATC1_SEXE2_TACTR12',
      'INATC1_SEXE2_TACTR21', 'INATC1_SEXE2_TACTR22', 'INATC1_SEXE2_TACTR24',
      'INATC1_SEXE2_TACTR26', 'INATC2_SEXE1_TACTR11', 'INATC2_SEXE1_TACTR12',
      'INATC2_SEXE1_TACTR21', 'INATC2_SEXE1_TACTR22', 'INATC2_SEXE1_TACTR24',
      'INATC2_SEXE1_TACTR26', 'INATC2_SEXE2_TACTR11', 'INATC2_SEXE2_TACTR12',
      'INATC2_SEXE2_TACTR21', 'INATC2_SEXE2_TACTR22', 'INATC2_SEXE2_TACTR24',
      'INATC2_SEXE2_TACTR26'],
      dtype='str')
```

L'exploration des colonnes révèle la présence de 24 variables numériques décrivant différentes catégories de population selon la nationalité, le sexe et le statut d'activité. Parmi ces variables, 12 colonnes concernent la population française et 12 colonnes la population étrangère, permettant une analyse comparative des répartitions démographiques et sociales à l'échelle communale.

EDA pré-cleaning du dataset - 07_ Création_associations_2022.csv

L'analyse exploratoire initiale du dataset des associations a permis d'étudier la structure générale des données avant les différentes étapes de nettoyage et de transformation.

Le fichier brut contient 34 980 lignes et 41 colonnes regroupant des informations administratives ainsi que de nombreuses variables décrivant les associations présentes sur les territoires communaux selon différents domaines d'activité.

```
--- DIMENSIONS DU DATASET ---
(34980, 41)
```

```
--- APERÇU DES DONNÉES ---
```

	INSEE	NOM	EPCI	DEP	REG	TOTASSO2024	ASSO2000	ASSO2010	ASSO2011	...	COND_ACT_ECO	ENV	AIDE_VIE_LOC	LOG	TOUR	SECU	ARME	REL	AUT_ASSO
0	1001	L'Abergement-Clémenciat	200069193	D1	R84	16	10	5	0	...	0	0	0	0	0	1	1	0	0
1	1002	L'Abergement-de-Varey	240100883	D1	R84	15	4	8	0	...	0	3	0	0	0	0	1	0	0
2	1004	Ambérieu-en-Bugey	240100883	D1	R84	318	138	67	6	...	27	16	1	2	1	5	4	6	0
3	1005	Ambérieux-en-Dombes	200042497	D1	R84	55	21	20	4	...	2	0	0	0	0	1	1	0	0
4	1006	Amblién	200040350	D1	R84	7	3	0	0	...	0	1	0	0	0	0	0	0	0

```
--- NOMS DES COLONNES ---
```

```
Index(['INSEE', 'NOM', 'EPCI', 'DEP', 'REG', 'TOTASSO2024', 'ASSO2000',
      'ASSO2010', 'ASSO2011', 'ASSO2012', 'ASSO2013', 'ASSO2014', 'ASSO2015',
      'ASSO2016', 'ASSO2017', 'ASSO2018', 'ASSO2019', 'ASSO2020', 'ASSO2021',
      'ASSO2022', 'ASSO2023', 'ASSO2024', 'ACT_POL_REF', 'DEF_DT_JUST',
      'INFO_COM', 'CULT_LOIS', 'SOCIO-CULT_AMIC', 'PRES_PAT', 'SPORTS_CHASSE',
      'EDUC_FORM_RECH', 'SANT_MED_SOC', 'CARITATIF', 'COND_ACT_ECO', 'ENV',
      'AIDE_VIE_LOC', 'LOG', 'TOUR', 'SECU', 'ARME', 'REL', 'AUT_ASSO'],
      dtype='str')
```

Les contrôles effectués sur la clé géographique INSEE montrent l'absence de doublons communaux ainsi qu'une homogénéité du format des identifiants territoriaux utilisés dans le dataset.

```

--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
34980

--- LONGUEUR DES CODES INSEE ---
code_insee
5    34980
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0

```

Cette phase d'exploration a également permis d'identifier les principales catégories associatives présentes dans les données, notamment les associations sportives, culturelles, sociales, ou encore éducatives, utilisées par la suite dans les traitements analytiques et le feature engineering.

```

--- COLONNES NUMÉRIQUES PRÉSENTES ---
['ASSO2022']

--- EXEMPLES DE VALEURS NUMÉRIQUES ---
      INSEE      NOM ASSO2022
0    1001  L'Abergement-Clémenciat    0
1    1002    L'Abergement-de-Varey    0
2    1004      Ambérieu-en-Bugey     7
3    1005      Ambérieux-en-Dombes    1
4    1006              Ambléon        0
5    1007              Ambronay        1

```

EDA pré-cleaning du dataset - 08_EDA_BRUT_Creation_entreprise_2022.csv

L'analyse exploratoire initiale du fichier de créations d'entreprises a permis d'examiner la structure générale des données communales avant les étapes de nettoyage et de transformation.

Le dataset brut comporte 34 877 lignes et 16 colonnes regroupant les créations d'entreprises par commune sur plusieurs années, de 2012 à 2025.

```

--- DIMENSIONS DU DATASET ---
(34877, 16)

--- APERÇU DES DONNÉES ---
code_insee  nom_brut  2012  2013  2014  2015  2016  2017  2018  2019  2020  2021  2022  2023  2024  2025
4    01001  L'Abergement-Clémenciat    5    4    5    3    6    5    7    6   10    7   17   16   11    8
5    01002    L'Abergement-de-Varey    5    1    3    0    1    3    3    4    3    5    3    3    5    2
6    01004      Ambérieu-en-Bugey  121   92  123  103  118  139  137  193  185  204  218  209  269  280
7    01005      Ambérieux-en-Dombes   16   12   11   15   11   19   17   19   26   33   32   22   33   35
8    01006              Ambléon     1    2    2    0    0    3    2    1    0    0    2    2    2    2

--- NOMS DES COLONNES ---
Index(['code_insee', 'nom_brut', '2012', '2013', '2014', '2015', '2016',
      '2017', '2018', '2019', '2020', '2021', '2022', '2023', '2024', '2025'],
      dtype='str')

```

Les contrôles réalisés sur la clé géographique code_insee montrent l'absence de doublons communaux ainsi qu'une cohérence globale des identifiants territoriaux. Une valeur atypique de longueur 63 caractères a toutefois été identifiée lors de l'analyse.

```

--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
34876

```

```

--- LONGUEUR DES CODES INSEE ---
code_insee
5.0      34875
63.0      1
Name: count, dtype: int64

--- DOUBLONS SUR CODE INSEE ---
0

```

Après vérification, cette ligne correspondait à une information technique résiduelle provenant de la source INSEE et non à une commune réelle :

```

--- VALEURS MANQUANTES SUR 2022 ---
2

                                code_insee nom_brut
34879                                NaN      NaN
34880 Source : Système d'information sur la démograp...      NaN

```

L'analyse a également permis d'identifier les différentes colonnes annuelles de créations d'entreprises présentes dans le fichier source. La variable correspondant à l'année 2022 a ensuite été retenue pour les traitements du projet et les indicateurs liés au dynamisme économique local.

```

--- COLONNES NUMÉRIQUES PRÉSENTES ---
['2012', '2013', '2014', '2015', '2016', '2017', '2018', '2019', '2020', '2021', '2022', '2023', '2024', '2025']

--- EXEMPLES DE VALEURS NUMÉRIQUES ---
code_insee      nom_brut  2012  2013  2014  2015  2016  2017  2018  2019  2020  2021  2022  2023  2024  2025
4      01001  L'Abergement-Clémenciat      5      4      5      3      6      5      7      6     10      7     17     16     11      8
5      01002  L'Abergement-de-Varey      5      1      3      0      1      3      3      4      3      5      3      3      5      2
6      01004  Ambérieu-en-Bugey     121     92    123    103    118    139    137    193    185    204    218    209    269    280
7      01005  Ambérieux-en-Dombes     16     12     11     15     11     19     17     19     26     33     32     22     33     35

```

EDA pré-cleaning du dataset - 09_EDA_BRUT_Criminalite_2022.csv

L'analyse exploratoire initiale du fichier de criminalité a permis d'examiner la structure générale des données territoriales avant les étapes de nettoyage et de transformation.

Le dataset brut contient 5 238 000 lignes et 13 colonnes regroupant différents indicateurs de criminalité communale sur plusieurs années, de 2016 à 2025. Les données sont organisées par commune, année et type d'infraction.

```

--- DIMENSIONS DU DATASET ---
(5238000, 13)

--- APERÇU DES DONNÉES ---
  CODGEO_2025  annee      indicateur unite_de_compte  ...  insee_log  insee_log_millesime  complement_info_nombre  complement_info_taux
0      01001    2016  Violences physiques intrafamiliales  Victime  ...      348      2016      NaN      NaN
1      01001    2016  Violences physiques hors cadre familial  Victime  ...      348      2016      1.362069      0.959839
2      01001    2016      Violences sexuelles  Victime  ...      348      2016      NaN      NaN
3      01001    2016      Vols avec armes  Infraction  ...      348      2016      NaN      NaN
4      01001    2016      Vols violents sans arme  Infraction  ...      348      2016      NaN      NaN

```

Les contrôles réalisés sur la clé géographique CODGEO_2025 montrent une standardisation correcte des identifiants territoriaux sur 5 caractères. L'analyse met également en évidence l'absence de doublons globaux dans le fichier source. Le nombre important de doublons observés sur les codes INSEE seuls est toutefois normal, car plusieurs indicateurs de criminalité sont enregistrés pour une même commune et une même année.

```

--- DOUBLONS ---
0

--- NOMBRE DE CODES INSEE UNIQUES ---
34920

--- LONGUEUR DES CODES INSEE ---
CODGEO_2025
5    5238000
Name: count, dtype: int64

```

```

--- DOUBLONS SUR CODE INSEE ---
5203080

```

```

--- ANNÉES DISPONIBLES ---

```

```

annee
2016    523800
2017    523800
2018    523800
2019    523800
2020    523800
2021    523800
2022    523800
2023    523800
2024    523800
2025    523800
Name: count, dtype: int64

```

L'exploration du dataset a permis d'identifier 15 catégories d'infractions différentes, notamment les violences physiques, violences sexuelles, cambriolages, vols de véhicules, dégradations volontaires ainsi que les infractions liées aux stupéfiants.

```

--- INDICATEURS DISPONIBLES ---
<ArrowStringArray>
[
    'Violences physiques intrafamiliales',
    'Violences physiques hors cadre familial',
    'Violences sexuelles',
    'Vols avec armes',
    'Vols violents sans arme',
    'Vols sans violence contre des personnes',
    'Cambriolages de logement',
    'Vols de véhicule',
    'Vols dans les véhicules',
    'Vols d'accessoires sur véhicules',
    'Destructions et dégradations volontaires',
    'Usage de stupéfiants',
    'Usage de stupéfiants (AFD)',
    'Trafic de stupéfiants',
    'Escroqueries et fraudes aux moyens de paiement']
Length: 15, dtype: str

```

L'analyse a également montré que certaines valeurs de criminalité étaient directement renseignées dans la variable `taux_pour_mille`, tandis que d'autres étaient présentes dans la variable `complement_info_taux`. Ces deux colonnes ont donc été étudiées afin de reconstruire un indicateur de taux unique exploitable dans les traitements du projet.

```

--- COLONNES NUMÉRIQUES PRÉSENTES ---
['taux_pour_mille', 'complement_info_taux']

--- EXEMPLES DE VALEURS NUMÉRIQUES ---

```

	CODGEO_2025	annee	indicateur	taux_pour_mille	complement_info_taux
0	01001	2016	Violences physiques intrafamiliales	0.0	NaN
1	01001	2016	Violences physiques hors cadre familial	NaN	0.959839
2	01001	2016	Violences sexuelles	0.0	NaN
3	01001	2016	Vols avec armes	0.0	NaN
4	01001	2016	Vols violents sans arme	0.0	NaN
5	01001	2016	Vols sans violence contre des personnes	NaN	2.217436
6	01001	2016	Cambriolages de logement	NaN	6.696478
7	01001	2016	Vols de véhicule	NaN	1.655149
8	01001	2016	Vols dans les véhicules	0.0	NaN
9	01001	2016	Vols d'accessoires sur véhicules	NaN	1.287312
10	01001	2016	Destructions et dégradations volontaires	NaN	3.481244
11	01001	2016	Usage de stupéfiants	0.0	NaN
12	01001	2016	Usage de stupéfiants (AFD)	0.0	NaN
13	01001	2016	Trafic de stupéfiants	0.0	NaN
14	01001	2016	Escroqueries et fraudes aux moyens de paiement	NaN	2.132496
15	01002	2016	Violences physiques intrafamiliales	0.0	NaN
16	01002	2016	Violences physiques hors cadre familial	0.0	NaN
17	01002	2016	Violences sexuelles	NaN	0.611168
18	01002	2016	Vols avec armes	0.0	NaN
19	01002	2016	Vols violents sans arme	0.0	NaN

```

--- DIMENSIONS TABLE DE PASSAGE ---
(36760, 47)

```

EDA pré-cleaning du dataset – 10_EDA_BRUT_Y_all_elections_2022.parquet

L'analyse exploratoire initiale du dataset des résultats électoraux 2022 a permis d'examiner la structure générale des données avant les étapes de transformation et de création de la variable cible Y.

Le fichier brut contient 836 184 lignes et 9 colonnes correspondant aux résultats du premier tour de l'élection présidentielle 2022 par bureau de vote et par candidat.

```

Columns: [id_election, code_departement, code_commune, code_bv, voix, ratio_voix_exprimes, nuance, nom, prenom]
Index: []
(836184, 9)

```

	id_election	code_departement	code_commune	code_bv	voix	ratio_voix_exprimes	nuance	nom	prenom
0	2022_pres_t1	01	01001	0001	3	0.58	None	ARTHAUD	Nathalie
1	2022_pres_t1	01	01002	0001	2	1.17	None	ARTHAUD	Nathalie
2	2022_pres_t1	01	01004	0001	4	0.48	None	ARTHAUD	Nathalie
3	2022_pres_t1	01	01004	0002	6	0.71	None	ARTHAUD	Nathalie
4	2022_pres_t1	01	01004	0003	8	0.84	None	ARTHAUD	Nathalie

Les contrôles réalisés montrent que :

- Le dataset contient uniquement l'élection 2022_pres_t1
- Aucune valeur manquante n'a été détectée sur les colonnes géographiques et sur les voix
- Aucun doublon global n'a été identifié
- Les types des variables numériques sont cohérents (voix en entier et ratio_voix_exprimes en flottant)
- Chaque candidat possède le même nombre d'occurrences, confirmant une structure homogène du dataset par bureau de vote

nom	
ARTHAUD	69682
ROUSSEL	69682
MACRON	69682
LASSALLE	69682
LE PEN	69682
ZEMMOUR	69682
MÉLENCHON	69682
HIDALGO	69682
JADOT	69682
PÉCRESSE	69682
POUTOU	69682
DUPONT-AIGNAN	69682

L'EDA a également permis d'identifier que les données étaient enregistrées à l'échelle des bureaux de vote et des candidats. Une phase d'agrégation a donc été nécessaire afin de reconstruire les scores politiques par commune et de créer la variable cible finale correspondant à la classe politique dominante par territoire.

B) Transformation des données

Sélection et renommage des colonnes utiles

Sélection et renommage des colonnes utiles - **Dataset 00_insee_code_referentiel.csv**

Le référentiel brut contenait plusieurs colonnes non nécessaires au projet. Seules les colonnes utiles aux traitements et aux jointures ont été conservées. Les colonnes ont également été renommées afin d'obtenir des noms homogènes et plus explicites dans l'ensemble du pipeline ETL :

```
# Étape 2. Transformation : sélection des colonnes

# Dictionnaire de correspondance entre les noms INSEE
# et les noms utilisés dans notre projet :
colonnes_a_garder = {
    'TYPECOM': 'type_commune',
    'COM': 'code_insee',
    'LIBELLE': 'nom_commune',
    'DEP': 'code_departement',
    'REG': 'code_region'
}

# On garde uniquement les colonnes présentes dans le fichier :
# cela évite une erreur si une colonne est absente :
cols_presentes = [col for col in colonnes_a_garder.keys() if col in df.columns]

# Sélection et renommage des colonnes :
df = df[cols_presentes].rename(columns=colonnes_a_garder)
```


Sélection et renommage des colonnes utiles - **Dataset 01_revenus_2022.csv**

Seules les colonnes nécessaires aux traitements et aux futures jointures ont été conservées. Les noms de colonnes ont également été harmonisés afin d'obtenir une nomenclature cohérente dans l'ensemble du pipeline ETL.

```
# Sélection des colonnes utiles
df = df_raw[["CODGEO", "Q221"]].rename(columns={
    "CODGEO": "code_insee_2021",
    "Q221": "revenu_median_commune"
})
```

Le fichier brut contient 732 colonnes, mais seules les colonnes nécessaires au projet ont été conservées : le code commune CODGEO et le revenu médian Q221. Elles ont été renommées pour obtenir des noms plus explicites et cohérents avec le reste du pipeline.

Sélection et renommage des colonnes utiles - **Dataset 02_Taux_chomage_2022.csv**

Le fichier brut INSEE contient plusieurs indicateurs liés à l'activité et au chômage. Seules les colonnes nécessaires au calcul du taux de chômage communal ont été conservées.

Les colonnes techniques fournies par l'INSEE ont également été renommées afin d'obtenir des noms plus explicites et homogènes dans le pipeline ETL.

```
# ÉTAPE 5 : SÉLECTION ET RENOMMAGE DES COLONNES

# Dictionnaire des colonnes utiles
colonnes_a_garder = {

    "CODGEO": "code_insee",

    "INATC1_SEXE1_TACTR11": "emploi_hommes_francais",
    "INATC1_SEXE2_TACTR11": "emploi_femmes_francais",
    "INATC2_SEXE1_TACTR11": "emploi_hommes_etrangers",
    "INATC2_SEXE2_TACTR11": "emploi_femmes_etrangers",

    "INATC1_SEXE1_TACTR12": "chomeur_hommes_francais",
    "INATC1_SEXE2_TACTR12": "chomeur_femmes_francais",
    "INATC2_SEXE1_TACTR12": "chomeur_hommes_etrangers",
    "INATC2_SEXE2_TACTR12": "chomeur_femmes_etrangers",

}
```

Sélection et renommage des colonnes utiles - **03_Categorie_sociale_2022.csv**

Le fichier brut contient plus d'une centaine de colonnes démographiques et socio-professionnelles. Seules les colonnes nécessaires aux analyses des catégories sociales ont été conservées dans le pipeline ETL.

Les catégories retenues concernent notamment les agriculteurs, les cadres, les employés et les ouvriers, répartis selon différentes tranches d'âge : 15–24 ans, 25–54 ans et 55 ans et plus.



```
# ÉTAPE 4 : SÉLECTION ET RENOMMAGE DES COLONNES

# Dictionnaire des colonnes utiles
mapping = {

    "CODGEO": "code_insee",

    # AGRICULTEURS
    "C22_POP1524_STAT_GSEC11_21": "agri_15_24",
    "C22_POP2554_STAT_GSEC11_21": "agri_25_54",
    "C22_POP55P_STAT_GSEC11_21": "agri_55p",

    # CADRES
    "C22_POP1524_STAT_GSEC13_23": "cadres_15_24",
    "C22_POP2554_STAT_GSEC13_23": "cadres_25_54",
    "C22_POP55P_STAT_GSEC13_23": "cadres_55p",

    # EMPLOYÉS
    "C22_POP1524_STAT_GSEC15_25": "employes_15_24",
    "C22_POP2554_STAT_GSEC15_25": "employes_25_54",
    "C22_POP55P_STAT_GSEC15_25": "employes_55p",

    # OUVRIERS
    "C22_POP1524_STAT_GSEC16_26": "ouvriers_15_24",
    "C22_POP2554_STAT_GSEC16_26": "ouvriers_25_54",
    "C22_POP55P_STAT_GSEC16_26": "ouvriers_55p",

}
```

Sélection et renommage des colonnes utiles - **04_Densite_population_2022.csv**

Le dataset brut contenait un grand nombre de colonnes descriptives non nécessaires aux traitements du projet (coordonnées géographiques, URLs, informations administratives, altitude, académies, etc.).

Seules les colonnes utiles à l'analyse de la population et de la densité ont été conservées, notamment le code INSEE, la population communale, la superficie en km² et la densité de population.

```
df = df.rename(columns={"nom_commune": "localisation"})

#dataset final
df_final = df[[
    "code_insee",
    "localisation",
    "population",
    "superficie_km2",
    "densite"
]].copy()

df_final["annee"] = year
```

Les colonnes ont ensuite été harmonisées afin de conserver une structure homogène avec les autres datasets du pipeline ETL.



Sélection et renommage des colonnes utiles - Dataset 05_Demographie_2022.csv

Seules les colonnes nécessaires aux traitements analytiques et aux futures jointures ont été conservées dans le dataset final. Cette sélection a permis d'alléger le fichier, de supprimer les informations non exploitées dans le projet et de standardiser la structure des données utilisées dans le pipeline ETL.

```
# Sélection des colonnes finales
df_final = df[
    [
        "code_insee",
        "localisation",
        "pct_jeunes",
        "pct_seniors",
        "age_median",
    ]
].copy()
```

```
# ÉTAPE 3 : CONSTRUCTION DU CODE INSEE

# Normalisation du code département
df["DR"] = df["DR"].astype(str).str.zfill(2)

# Normalisation du code commune
df["CR"] = df["CR"].astype(str).str.zfill(3)

# Construction du code INSEE complet
df["code_insee"] = df["DR"] + df["CR"]
```

La clé géographique code_insee a été reconstruite en combinant les colonnes DR (code département) et CR (code commune), après normalisation des formats avec ajout des zéros manquants.

Cette étape a permis d'uniformiser les identifiants territoriaux avant les opérations de jointure avec le référentiel communal.

Sélection et renommage des colonnes utiles - Dataset 06_Taux_immigration_2022.csv

Le fichier brut contenait un grand nombre de colonnes démographiques détaillées par sexe et catégorie d'activité. Seules les colonnes utiles au calcul du taux d'immigration ont été conservées.

La variable géographique CODGEO a également été renommée en code_insee afin d'harmoniser les clés de jointure avec le reste du pipeline de données.

```
# Renommage code commune
df_raw = df_raw.rename(columns={
    "CODGEO": "code_insee"
})
```

Les colonnes commençant par INATC1 correspondant à la population française et INATC2 correspondant à la population étrangère ont ensuite été sélectionnées automatiquement pour les traitements statistiques.

```
# Colonnes utiles :
# INATC1 = Français
# INATC2 = Étrangers
# Peu importe SEXE et TACTR, on prend tout
colonnes_francais = [
    col for col in df_raw.columns
    if col.startswith("INATC1_SEXE")
]

colonnes_etrangers = [
    col for col in df_raw.columns
    if col.startswith("INATC2_SEXE")
]
```

```
if not colonnes_francais or not colonnes_etrangers:
    print("Colonnes Français / Étrangers introuvables.")
    print("Colonnes français détectées :", colonnes_francais)
    print("Colonnes étrangers détectées :", colonnes_etrangers)
    print("Colonnes disponibles :", list(df_raw.columns))
    sys.exit(1)

df = df_raw[["code_insee"] + colonnes_francais + colonnes_etrangers].copy()
```

Sélection et renommage des colonnes utiles - **Dataset 07_Associations_2022.csv**

Le fichier brut contenait plusieurs colonnes descriptives dont certaines n'étaient pas nécessaires aux traitements du projet. Seules les variables utiles à l'analyse du nombre d'associations communales ont été conservées.

La colonne géographique INSEE a été renommée en code_insee afin d'harmoniser les clés de jointure avec le reste du pipeline ETL et le référentiel communal.

```
# 3. RENOMMAGE
df = df.rename(columns={
    "INSEE": "code_insee",
    "NOM": "nom_commune",
    "ASSO2022": "nb_associations"
})
```

La variable ASSO2022, correspondant au nombre total d'associations créées par commune en 2022, qu'elles soient sportives, culturelles, environnementales ou autres, a été renommée en nb_associations.

Sélection et renommage des colonnes utiles - **Dataset 08_Creation_entreprise_2022.csv**

Le fichier brut contenait des données de créations d'entreprises sur plusieurs années, de 2012 à 2025. Pour le projet, seule l'année 2022 a été retenue afin de rester cohérent avec le périmètre temporel des autres datasets.



```
# Renommage des colonnes utiles
df = df.rename(columns={
    0: "code_insee",
    1: "nom_brut",
    2: "2012",
    3: "2013",
    4: "2014",
    5: "2015",
    6: "2016",
    7: "2017",
    8: "2018",
    9: "2019",
    10: "2020",
    11: "2021",
    12: "2022",
    13: "2023",
    14: "2024",
    15: "2025"
})
```

Les colonnes utiles ont donc été renommées afin d'obtenir une structure plus claire : la première colonne a été renommée en code_insee, la deuxième en nom_brut, et la colonne correspondant à l'année 2022 a été exploitée pour créer la variable nb_creations_entreprises.

```
# Conversion de la variable 2022
df["nb_creations_entreprises"] = pd.to_numeric(df["2022"], errors="coerce")
```

Cette étape permet de conserver uniquement l'identifiant communal et l'indicateur économique utile au projet.

Sélection et renommage des colonnes utiles - **Dataset 09_Criminalite_2022.csv**

Le fichier brut de criminalité contenait plusieurs indicateurs d'infractions ainsi que des informations techniques liées aux millésimes INSEE. Pour le projet, seules les variables nécessaires à l'analyse de la criminalité communale ont été conservées : le code géographique, l'année, le type d'infraction et les taux associés.

Les données étant initialement basées sur les codes communaux 2025, une table de passage INSEE a été utilisée afin de récupérer le CODGEO_2022 et harmoniser les jointures avec le référentiel communal 2022 du projet.

```
# Sélection des colonnes utiles dans la table de passage
passage = passage[["CODGEO_2025", "CODGEO_2022"]].drop_duplicates()
```

Les indicateurs de criminalité retenus ont ensuite été filtrés afin de conserver uniquement les catégories pertinentes pour l'analyse, comme les violences, les cambriolages, les vols, les dégradations et les infractions liées aux stupéfiants.

```
# CRIMES GARDÉS
indicateurs_gardés = [
    "Violences physiques intrafamiliales",
    "Violences sexuelles",
    "Vols avec armes",
    "Vols violents sans arme",
    "Cambriolages de logement",
    "Vols de véhicule",
    "Destructions et dégradations volontaires",
    "Usage de stupéfiants",
    "Trafic de stupéfiants"
]

# FILTRE ANNÉE
df = df[
    (df["annee"] == year) &
    (df["indicateur"].isin(indicateurs_gardés))
].copy()
```

Enfin, les colonnes issues du pivot ont été renommées avec des noms explicites tels que `taux_violences_sexuelles`, `taux_cambriolages_logement` ou `taux_usage_stupefiants`, afin d'obtenir un dataset final plus lisible et directement exploitable pour les analyses statistiques et les traitements de Machine Learning.

```
# RENOMMAGE COLONNES
df_pivot = df_pivot.rename(columns={
    "Violences physiques intrafamiliales": "taux_violences_intrafamiliales",
    "Violences sexuelles": "taux_violences_sexuelles",
    "Vols avec armes": "taux_vols_avec_armes",
    "Vols violents sans arme": "taux_vols_violents_sans_arme",
    "Cambriolages de logement": "taux_cambriolages_logement",
    "Vols de véhicule": "taux_vols_vehicule",
    "Destructions et dégradations volontaires": "taux_degradations",
    "Usage de stupéfiants": "taux_usage_stupefiants",
    "Trafic de stupéfiants": "taux_trafic_stupefiants"
})
```

Sélection et renommage des colonnes utiles – **Dataset 10_Y_elections_2022.parquet**

Le dataset électoral brut était initialement fourni au format CSV avec une taille supérieure à 2 Go. Afin d'optimiser les performances de lecture et de traitement dans le pipeline ETL, une étape intermédiaire de conversion vers le format Parquet a été réalisée.

Le chargement du fichier CSV a été effectué par chunks de 500 000 lignes afin d'éviter une surcharge mémoire durant le traitement des données volumineuses.

```

for chunk in pd.read_csv(
    FILE_DATA,
    sep=";",
    usecols=usecols,
    chunksize=500000,
    engine="python",
    on_bad_lines="skip"
):
    filtered = chunk[chunk["id_election"] == "2022_pres_t1"]

    if not filtered.empty:
        chunks.append(filtered)
        print("Chunk trouvé :", filtered.shape)

df_final = pd.concat(chunks, ignore_index=True)

print(df_final.head())
print(df_final.shape)

df_final.to_parquet(OUTPUT, index=False)

```

Lors de cette transformation, seules les colonnes utiles au projet ont été conservées, notamment :

- L'identifiant de l'élection (id_election)
- Les codes géographiques (code_département, code_commune)
- Le bureau de vote (code_bv)
- Les informations candidats (nom, prenom)
- Le nombre de voix (voix)
- Le ratio des voix exprimées (ratio_voix_exprimées)
- Ainsi que la nuance politique (nuance)

Les données ont ensuite été filtrées afin de conserver uniquement les résultats correspondant au premier tour de l'élection présidentielle 2022 (2022_pres_t1).

Les résultats électoraux étant initialement présents à l'échelle des candidats et des bureaux de vote, une phase d'agrégation a été nécessaire afin de construire la variable cible utilisée dans le modèle de Machine Learning.

Les candidats ont d'abord été regroupés manuellement par grands blocs politiques :

```

# Association candidat → bloc politique
mapping_bloc = {
    "ARTHAUD": "extreme_gauche",
    "POUTOU": "extreme_gauche",

    "ROUSSEL": "gauche",
    "MELENCHON": "gauche",
    "HIDALGO": "gauche",
    "JADOT": "gauche",

```

```

    "MACRON": "centre",
    "LASSALLE": "centre",

    "PECRESSE": "droite",
    "DUPONT-AIGNAN": "droite",

    "LE PEN": "extreme_droite",
    "ZEMMOUR": "extreme_droite",
}

```

Les voix obtenues par chaque candidat ont ensuite été agrégées par commune et par bloc politique afin de calculer le score électoral de chaque courant politique à l'échelle communale.

```
# AGRÉGATION DES VOIX

# Somme des voix par commune et bloc politique
df_blocs = (
    df.groupby(
        ["code_insee", "bloc_politique"],
        as_index=False
    )["voix"]
    .sum()
)

# Calcul du total des voix exprimées par commune
df_blocs["total_exprimées_commune"] = (
    df_blocs.groupby("code_insee")["voix"]
    .transform("sum")
)
```

```
# Calcul du pourcentage de chaque bloc
df_blocs["score_bloc"] = np.where(

    df_blocs["total_exprimées_commune"] > 0,

    df_blocs["voix"] /
    df_blocs["total_exprimées_commune"] * 100,

    np.nan
)
```

Pour chaque commune, le bloc politique obtenant le score le plus élevé a été sélectionné comme classe politique dominante. Cette variable finale correspond à la cible Y utilisée pour l'entraînement du modèle de classification.



Traitement des valeurs manquantes


Pour le traitement des valeurs manquantes, nous avons réalisé un travail de contrôle et de vérification des données sur l'ensemble des datasets utilisés dans le projet. Pour cela, nous avons :

- Analysé les valeurs manquantes, les valeurs nulles (0) ainsi que les valeurs NaN présentes dans chaque dataset
- Utilisé Missingno de Python afin d'identifier les lignes contenant des données manquantes et de mesurer leur impact par rapport au volume total des données
- Déterminé si certaines valeurs pouvaient être rectifiées, complétées ou recalculées à l'aide d'autres informations disponibles dans les jeux de données
- Supprimé les lignes lorsqu'aucune correction ou estimation fiable n'était possible
- Établi une liste commune des lignes et communes à exclure, afin d'assurer la cohérence entre les jeux de données d'entraînement et de prédiction

Traitement des valeurs manquantes - **Dataset 00_insee_code_referentiel.csv**

Une analyse du référentiel communal a mis en évidence 2026 lignes sans code_departement ni code_region.

Avant traitement : 2026 lignes Sans Code_departement ni code_region



Les contrôles effectués ci-dessous ont montré que ces lignes concernaient exclusivement des communes de type :

- COMD : communes déléguées
- COMA : communes associées

Ces types de communes correspondent à des entités administratives rattachées à une commune principale. Dans le fichier brut fourni par l'INSEE, certaines de ces lignes ne comportaient donc pas directement les informations géographiques associées (code_departement et code_region).

Afin de vérifier que les valeurs manquantes ne concernaient pas d'autres catégories administratives, un contrôle a été effectué sur les types de communes impactés :

```
# Vérification des types de communes concernés
# On vérifie que seules les communes déléguées (COMD) et associées (COMA) sont impactées.
types_attendus = ["COMD", "COMA"]

df_types_anormaux = df_missing_geo[
    ~df_missing_geo["type_commune"].isin(types_attendus)
]

print("\n--- TYPES ANORMAUX ---")
print("Nombre :", len(df_types_anormaux))
```

```
--- COMMUNES SANS CODE_DEPARTEMENT OU CODE_REGION ---
Nombre de lignes concernées : 2026
```

	type_commune	code_insee	nom_commune	code_departement	code_region
57	COMD	01059	Brénaz	NaN	NaN
88	COMD	01091	Châtillon-en-Michaille	NaN	NaN
95	COMD	01097	Chavornay	NaN	NaN
117	COMD	01119	Corcelles	NaN	NaN
118	COMA	01120	Cordieux	NaN	NaN
120	COMD	01122	Cormaranche-en-Bugey	NaN	NaN
133	COMD	01137	Cuisiat	NaN	NaN
140	COMD	01144	Dommartin	NaN	NaN
150	COMD	01154	Étrez	NaN	NaN
165	COMD	01172	Germagnat	NaN	NaN
173	COMD	01182	Groslée	NaN	NaN
178	COMD	01186	Hostiaz	NaN	NaN
197	COMD	01205	Lancrans	NaN	NaN
210	COMD	01218	Lochieu	NaN	NaN
212	COMD	01221	Lompnieu	NaN	NaN
255	COMD	01271	Nattages	NaN	NaN
282	COMD	01300	Le Poizat	NaN	NaN
294	COMD	01312	Pressiat	NaN	NaN
304	COMA	01324	Rignat	NaN	NaN
319	COMD	01340	Saint-Bois	NaN	NaN

```
--- TYPES ANORMAUX ---
Nombre : 0
```

Le résultat Types anormaux = 0 confirme que seules les communes de type COMD et COMA présentent des valeurs manquantes sur les colonnes code_departement et code_region. Aucune commune principale (COM) n'est concernée par cette anomalie.



```

# Traitement des communes COMD / COMA
# Du fait que certaines communes déléguées et associées ne possèdent pas de département/région
# dans le référentiel brut de l'INSEE.
#
# Le département est reconstruit à partir des 2 premiers caractères du code INSEE.

mask_missing_geo = (
    df["type_commune"].isin(["COMD", "COMA"])
    &
    (
        df["code_departement"].isna() |
        df["code_region"].isna() |
        (df["code_departement"].astype(str).str.lower() == "nan") |
        (df["code_region"].astype(str).str.lower() == "nan")
    )
)

df.loc[mask_missing_geo, "code_departement"] = (
    df.loc[mask_missing_geo, "code_insee"]
    .astype(str)
    .str[:2]
)

```

Le code_departement a ensuite été recalculé à partir des deux premiers caractères du code_insee.

Une table de correspondance département → région a ensuite été générée automatiquement à partir des communes du référentiel possédant déjà des informations géographiques valides.

```

# Construction automatique du mapping
# département -> région
# à partir des communes déjà valides

mapping_regions = (
    df[
        df["code_region"].notna() &
        (df["code_region"].astype(str).str.lower() != "nan")
    ][
        ["code_departement",
         "code_region"]
    ]
    .drop_duplicates(subset=["code_departement"])
    .set_index("code_departement")["code_region"]
    .to_dict()
)


# Reconstruction de la région

df.loc[mask_missing_geo, "code_region"] = (
    df.loc[mask_missing_geo, "code_departement"]
    .map(mapping_regions)
)

```


Enfin, cette correspondance a permis de réattribuer automatiquement les code_region manquants aux communes concernées.

Après traitement :



Traitement des valeurs manquantes - Dataset 01_revenus_2022.csv

Après conversion numérique, certaines communes présentaient des revenus médians manquants.



```
--- CONTRÔLE AVANT JOINTURE ---  
Lignes brutes : 34929  
Codes communes 2021 uniques : 34929  
Codes communes 2022 uniques : 34929  
NaN revenu communes : 3604  
Pourcentage NaN revenu communes : 10.32 %
```

Afin de conserver un maximum de communes dans le dataset final, $\text{NaN}=3604 / 34929 \approx 0.1032$ donc environ 10% (secret statistique INSEE) une stratégie d'imputation a été mise en place.

Une colonne indicatrice a d'abord été créée afin de tracer les valeurs imputées :

- 1 = revenu imputé
- 0 = revenu d'origine

```
# ÉTAPE 5 : GESTION DES VALEURS MANQUANTES

# Création d'une colonne indicatrice :
# 1 = valeur imputée
# 0 = valeur existante
df["revenu_impute"] = df["revenu_median_commune"].isna().astype(int)
```

Les revenus médians départementaux ont ensuite été intégrés au pipeline ETL afin de remplacer les revenus communaux absents :

```
# ÉTAPE 8 : JOINTURE REVENUS DÉPARTEMENTAUX
df = pd.merge(df, df_dep, on="code_département", how="left")



print("\n--- CONTRÔLE JOINTURE DÉPARTEMENT ---")
print("Communes sans revenu département :", df["revenu_median_département"].isna().sum())
```

```
# ÉTAPE 9 : IMPUTATION DES VALEURS MANQUANTES
# Si le revenu communal est absent : on remplace par le revenu médian départemental
df["revenu_median_final"] = df["revenu_median_commune"].fillna(
    df["revenu_median_département"]
)

print("\n--- CONTRÔLE IMPUTATION ---")
print("NaN avant imputation :", df["revenu_median_commune"].isna().sum())
print("NaN après imputation :", df["revenu_median_final"].isna().sum())
print("Nbre revenus imputés :", df["revenu_impute"].sum())
```


```
--- CONTRÔLE IMPUTATION ---
NaN avant imputation : 3604
NaN après imputation : 0
Nbre revenus imputés : 3604
```

```
--- CONTRÔLE FINAL ---
Lignes finales : 34826
NaN revenu final : 0
Pourcentage NaN final : 0.0 %
code_insee      localisation code_departement code_region  revenu_median_commune  revenu_median_departement  revenu_median_final  revenu_impute
0      01001  L'Abergement-Clémenciat         01         84           25820.0             24780             25820.0             0
1      01002  L'Abergement-de-Varey            01         84           24480.0             24780             24480.0             0
2      01004  Ambérieu-en-Bugey                          01         84           21660.0             24780             21660.0             0
3      01005  Ambérieux-en-Dombes                       01         84           24610.0             24780             24610.0             0
```



Traitement des valeurs manquantes - Dataset 02_Taux_chomage_2022.csv

L'analyse du dataset final a mis en évidence 12 valeurs manquantes sur la variable `taux_chomage`, soit environ 0,03 % des données.



Le taux de chômage est calculé uniquement lorsque le nombre d'actifs (`actifs_total`) est strictement supérieur à 0. Lorsque la population active est nulle ou absente, le calcul du taux devient impossible ou non interprétable. Dans ces cas, la valeur est volontairement conservée en NaN.

```
# Calcul du taux de chômage
df["taux_chomage"] = np.where(
    df["actifs_total"] > 0,
    (df["chomeurs_total"] / df["actifs_total"]) * 100,
    np.nan)
```

Un contrôle spécifique a été ajouté dans le pipeline ETL afin d'identifier précisément les communes concernées par ces valeurs manquantes.

```
# Affichage des communes avec taux NaN
print("\n--- COMMUNES AVEC TAUX_CHOMAGE NaN ---")

print(df[df["taux_chomage"].isna()][
    "code_insee",
    "nom_commune",
    "taux_chomage",
    "emploi_total",
    "chomeurs_total",
    "actifs_total"
])
```

```

--- COMMUNES AVEC TAUX_CHOMAGE NaN ---

```

	code_insee	nom_commune	taux_chomage	emploi_total	chomeurs_total	actifs_total
4958	15031	Celles	NaN	NaN	NaN	NaN
4962	15035	Chalinargues	NaN	NaN	NaN	NaN
4972	15047	Chavagnac	NaN	NaN	NaN	NaN
5087	15171	Sainte-Anastasie	NaN	NaN	NaN	NaN
11348	31127	Caubous	NaN	0.0	0.0	0.0
18528	51470	Rouvroy-Ripont	NaN	0.0	0.0	0.0
19997	55039	Beaumont-en-Verdunois	NaN	0.0	0.0	0.0
20008	55050	Bezonnvaux	NaN	0.0	0.0	0.0
20083	55139	Cumières-le-Mort-Homme	NaN	0.0	0.0	0.0
20126	55189	Fleury-devant-Douaumont	NaN	0.0	0.0	0.0
20163	55239	Haumont-près-Samogneux	NaN	0.0	0.0	0.0
20222	55307	Louvemont-Côte-du-Poivre	NaN	0.0	0.0	0.0

Les vérifications effectuées montrent que ces 12 valeurs manquantes proviennent de deux situations distinctes :

- 4 communes sans données d'activité exploitables dans les données brutes
- 8 communes présentant une population active égale à zéro

```

--- CHECK NaN taux chômage ---
Nombre lignes NaN :
12

NaN actifs_total :
4

actifs_total = 0 :
8

```



Ces valeurs manquantes ne proviennent donc pas d'une erreur de traitement, mais de limites directement présentes dans les données sources fournies par l'INSEE.

Compte tenu du très faible volume concerné (0,03 % du dataset), aucune imputation n'a été réalisée afin d'éviter l'introduction de données artificielles dans le calcul du taux de chômage. Les lignes concernées ont été supprimées du dataset final.

Traitement des valeurs manquantes - Dataset 03_Categorie_sociale_2022.csv

L'analyse post-cleaning met en évidence 158 valeurs manquantes sur les colonnes de pourcentages socio-professionnels, soit environ 0,45 % du dataset final.

--- NA PAR COLONNE ---		--- POURCENTAGE DE NaN ---	
code_insee	0	code_insee	0.00
localisation	0	localisation	0.00
pourcentage_agri	158	pourcentage_agri	0.45
pourcentage_cadres	158	pourcentage_cadres	0.45
pourcentage_employes	158	pourcentage_employes	0.45
pourcentage_ouvriers	158	pourcentage_ouvriers	0.45
annee	0	annee	0.00
dtype: int64		dtype: float64	



Les contrôles effectués montrent que ces valeurs manquantes proviennent exclusivement de deux situations :

- 4 communes dont les données socio-professionnelles sont totalement absentes dans le fichier source INSEE
- 154 communes pour lesquelles le nombre total d'actifs est égal à 0

```

Nettoyage catégorie sociale
NaN total_actifs : 4
total_actifs = 0 : 154
   code_insee  agri_total  cadres_total  employes_total  ouvriers_total
4958    15031         NaN           NaN             NaN             NaN
4962    15035         NaN           NaN             NaN             NaN
4972    15047         NaN           NaN             NaN             NaN
5087    15171         NaN           NaN             NaN             NaN
pourcentage_agri    158
pourcentage_cadres    158
pourcentage_employes    158
pourcentage_ouvriers    158
dtype: int64

```

Dans ces cas, les pourcentages de catégories sociales ne peuvent pas être calculés de manière statistiquement cohérente. Les lignes concernées, représentant environ 0,43 % du dataset, ont donc été supprimées afin de ne pas introduire de valeurs artificielles ou estimées dans le dataset final.

Des contrôles complémentaires ont également été réalisés afin de vérifier l'origine exacte des valeurs manquantes. Les résultats montrent qu'il n'existe aucune commune pour laquelle le total_actifs serait supérieur à 0 mais les pourcentages de catégories sociales restent manquants (NaN).

La capture ci-dessous montre également que seules 4 communes possèdent des valeurs manquantes dans les colonnes brutes INSEE des différentes tranches d'âge, tandis que les 154 autres cas correspondent uniquement à des communes dont le nombre total d'actifs est égal à 0.

```
Nombre lignes NaN : 158

NaN total_actifs :
4

Total_actifs = 0 :
154

Autres cas :
Empty DataFrame
Columns: [code_insee, localisation, total_actifs]
Index: []

--- NaN colonnes brutes ---
agri_15_24      4
agri_25_54      4
agri_55p        4
cadres_15_24    4
cadres_25_54    4
cadres_55p      4
employes_15_24  4
employes_25_54  4
employes_55p    4
ouvriers_15_24  4
ouvriers_25_54  4
ouvriers_55p    4
dtype: int64
```

Aucune ligne avec des valeurs manquantes partielles n'a été détectée :

```
--- Lignes avec NaN partiels ---
Empty DataFrame
Columns: [code_insee, agri_15_24, agri_25_54, agri_55p, cadres_15_24, cadres_25_54, cadres_55p, employes_15_24, employes_25_54, employes_55p]
Index: []

Nombre lignes NaN partiels :
0
```

- Soit l'ensemble des données socio-professionnelles d'une commune est présent
- Soit l'ensemble des données de la commune est absent

Aucune configuration incohérente n'a été observée, comme par exemple certaines tranches d'âge renseignées alors que d'autres seraient absentes, ou certaines catégories sociales présentes sans les autres.

Ces contrôles confirment la cohérence globale du dataset ainsi que la fiabilité du pipeline de calcul et de transformation des données socio-professionnelles.


Traitement des valeurs manquantes - Dataset 04_Densité_population_2022.csv

Lors de la jointure avec le référentiel communal, 177 communes n'ont pas été retrouvées. Ces lignes ont été supprimées afin de conserver uniquement les communes disposant d'une correspondance valide avec le référentiel 2022.

```
df = pd.merge(df, df_ref, on="code_insee", how="left") #ajout du nom de commune
print("Communes non trouvées :", df["nom_commune"].isna().sum()) #debug pr identifier les codes INSEE qui ne match pas
df = df.dropna(subset=["nom_commune"]).copy()
df = df.rename(columns={"nom_commune": "localisation"})
```

```
Nettoyage densité population
Communes non trouvées : 177
```

Cette étape permet d'assurer l'homogénéité des identifiants géographiques entre les différents datasets utilisés dans le pipeline.



Traitement des valeurs manquantes - Dataset 05_Demographie_2022.csv

Après la jointure avec le référentiel communal, 1366 communes n'ont pas été retrouvées et ont été exclues du fichier final.

Une analyse complémentaire montre que 1233 de ces communes étaient également sans population exploitable, ce qui confirme qu'il s'agit majoritairement de communes non exploitables pour l'analyse démographique.

```
Lignes sauvegardées : 36848
Lignes après lecture : 38214
Communes non trouvées après merge : 1366
code_insee      0
localisation    0
pct_jeunes      2055
pct_seniors     2055
age_median      2055
annee           0
dtype: int64

--- COMPARAISON NON TROUVÉES / SANS POPULATION ---
Communes non trouvées : 1366
Communes sans population : 3288
Communes à la fois non trouvées ET sans population : 1233

--- COMMUNES SANS POPULATION MAIS TROUVÉES DANS LE RÉFÉRENTIEL ---
2055

--- COMMUNES NON TROUVÉES MAIS AVEC POPULATION ---
133
```


Le fichier final contient 36848 lignes, dont 2055 présentent des valeurs manquantes sur les variables pct_jeunes, pct_seniors et age_median. Ces 2055 lignes correspondent à des communes bien présentes dans le référentiel, mais dont la population totale est nulle dans les données sources. Elles ne permettent donc pas de calculer les indicateurs démographiques. Ces communes seront donc supprimées du dataset final afin de conserver uniquement des données exploitables pour les analyses et les traitements de Machine Learning.

Traitement des valeurs manquantes - Dataset 06_Taux_immigration_2022

Lors de la jointure avec le référentiel communal, 113 communes n'ont pas été retrouvées. Après vérification, ces lignes correspondent principalement aux communes des DOM-TOM, exclues du périmètre géographique retenu pour le projet. Ces communes ont donc été supprimées du dataset final.

```
Nettoyage taux d'immigration 2022
Communes non trouvées après merge : 113
code_insee
9849      27676
34746     97101
34747     97102
34748     97103
34749     97104
34750     97105
34751     97106
34752     97107
```

Après la suppression des doublons, un contrôle des valeurs manquantes a été réalisé. Cette analyse a mis en évidence la présence de 10 lignes sans valeur pour la variable `taux_immigration`, soit environ 0,03 % du dataset final (10 lignes sur 34 847).



Ces valeurs manquantes proviennent des communes dont la population totale était nulle ou absente dans les données sources, empêchant le calcul du taux d'immigration. Ce cas a été sécurisé directement dans le code grâce à une condition empêchant toute division par zéro :

```
df["taux_immigration"] = np.where(
    df["population_totale"] > 0, #si aucune donnée exploitable dans le fichier INSEE alors NaN
    (df["population_etrangere"] / df["population_totale"]) * 100,
    np.nan
)
```

Afin de comprendre précisément l'origine des valeurs manquantes, un contrôle complémentaire a été réalisé dans le code. Cette vérification a permis d'identifier que les 10 valeurs manquantes sur la variable `'taux_immigration'` proviennent de communes pour lesquelles le calcul est impossible.

```
# COMMUNES AVEC POPULATION TOTALE NULLE

df_population_nulle = df[
    df["population_totale"] == 0
].copy()

print("\n--- COMMUNES AVEC POPULATION TOTALE NULLE ---")
print(df_population_nulle.shape)

print(df_population_nulle[["code_insee", "population_francaise", "population_etrangere", "population_totale"]].head(50))
print(df_population_nulle[["code_insee", "population_francaise", "population_etrangere", "population_totale"]].head(50))

# COMMUNES AVEC TAUX D'IMMIGRATION NaN

df_taux_nan = df[df["taux_immigration"].isna()].copy()

print("\n--- COMMUNES AVEC TAUX IMMIGRATION NaN ---")
print(df_taux_nan.shape)

print(df_taux_nan[["code_insee", "population_francaise", "population_etrangere", "population_totale", "taux_immigration"]])
```

En effet, 6 communes présentent une population totale égale à 0, tandis que 4 communes possèdent une population totale absente (NaN) dans le fichier source INSEE. Dans ces conditions, le calcul du taux d'immigration ne peut pas être effectué sans générer une division par zéro ou une valeur incohérente.

```

--- COMMUNES AVEC TAUX IMMIGRATION NaN ---
(10, 29)

```

	code_insee	population_francaise	population_etrangere	population_totale	taux_immigration
4958	15031	NaN	NaN	NaN	NaN
4962	15035	NaN	NaN	NaN	NaN
4972	15047	NaN	NaN	NaN	NaN
5087	15171	NaN	NaN	NaN	NaN
19997	55039	0.0	0.0	0.0	NaN
20008	55050	0.0	0.0	0.0	NaN
20083	55139	0.0	0.0	0.0	NaN
20126	55189	0.0	0.0	0.0	NaN
20163	55239	0.0	0.0	0.0	NaN
20222	55307	0.0	0.0	0.0	NaN

Les 10 communes concernées ont ensuite été supprimées du dataset final afin de conserver uniquement des données exploitables pour les analyses statistiques et les traitements de Machine Learning.

Traitement des valeurs manquantes - Dataset 08_Creation_entreprise_2022.csv

L'analyse du dataset nettoyé montre l'absence de valeurs manquantes sur les variables conservées dans le fichier final. Les colonnes localisation, nb_creations_entreprises et annee présentent un taux de complétude de 100 %.

```

--- INFO DATASET ---
(34874, 3)
<class 'pandas.DataFrame'>
RangeIndex: 34874 entries, 0 to 34873
Data columns (total 3 columns):
#   Column                Non-Null Count  Dtype
---  -
0   localisation          34874 non-null  str
1   nb_creations_entreprises 34874 non-null  float64
2   annee                 34874 non-null  int64
dtypes: float64(1), int64(1), str(1)
memory usage: 1.2 MB
None

```

```

--- NA PAR COLONNE ---
localisation          0
nb_creations_entreprises 0
annee                 0
dtype: int64

--- POURCENTAGE DE NaN ---
localisation          0.0
nb_creations_entreprises 0.0
annee                 0.0
dtype: float64



--- STATISTIQUES ---
count    34874.000000
mean      30.450880
std       525.820167
min         0.000000
25%        2.000000
50%        5.000000
75%       13.000000
max      88925.000000
Name: nb_creations_entreprises, dtype: float64

```

Les lignes techniques et non exploitables identifiées lors de l'analyse préliminaire du fichier brut ont été supprimées durant les étapes de nettoyage, permettant d'obtenir un dataset final cohérent et directement exploitable pour les analyses statistiques et les traitements de Machine Learning.

Traitement des valeurs manquantes - Dataset 09_Criminalite_2022.csv

Le dataset de criminalité contient deux types de données : les données diffusées (diff) et les données non diffusées (ndiff). Lorsque les données sont non diffusées, certaines valeurs sensibles ne sont pas directement renseignées dans les colonnes principales nombre et taux_pour_mille, ce qui génère des valeurs manquantes.



Afin de conserver un maximum d'informations exploitables, le projet a retenu les taux de criminalité pour mille habitants plutôt que les nombres bruts d'infractions. Cette approche permet de comparer les communes entre elles sans favoriser artificiellement les grandes villes plus peuplées.

Deux versions du dataset ont été étudiées :

- Une version contenant uniquement les données diffusées (diff)
- Une version plus complète intégrant également les données non diffusées (ndiff)


Pour reconstruire un indicateur de criminalité exploitable malgré les valeurs manquantes, une stratégie de remplacement a été mise en place. Lorsque la variable `taux_pour_mille` était absente, la valeur de `complement_info_taux` a été utilisée automatiquement :


```
# TAUX FINAL
df["taux_final"] = df["taux_pour_mille"].fillna(df["complement_info_taux"])
```

Cette logique permet :

- D'utiliser directement `taux_pour_mille` lorsque la donnée est diffusée
- D'utiliser `complement_info_taux` lorsque les données détaillées sont masquées mais qu'un taux complémentaire reste disponible.

Cette méthode a permis de limiter très fortement les pertes de données tout en conservant des indicateurs cohérents pour les analyses statistiques et les traitements de Machine Learning.





Même après le remplacement de `taux_pour_mille` par `complement_info_taux`, quelques valeurs manquantes restent présentes.

Ces cas correspondent aux communes pour lesquelles aucun taux exploitable n'est disponible, ni dans la colonne principale ni dans la colonne complémentaire. Le nombre de valeurs concernées reste très faible par rapport au volume total du dataset, elles seront donc supprimées afin de conserver uniquement des taux exploitables.

Harmonisation

L'harmonisation des données a consisté à assurer la cohérence et la compatibilité entre les différents jeux de données afin de faciliter leur intégration dans le pipeline ETL. Pour cela, nous avons mis en œuvre plusieurs étapes d'harmonisation :

- La gestion et l'uniformisation des codes géographiques CODEGEO
- L'uniformisation des noms de colonnes et des structures des datasets
- La vérification de la cohérence des communes entre les différentes sources de données
- La fusion et l'alignement des jeux de données
- Le traitement et la gestion des données non diffusées ainsi que du secret statistique INSEE

Harmonisation - `dataset 00_insee_code_referentiel.csv`

```
# Suppression des espaces inutiles dans les champs texte
df["nom_commune"] = df["nom_commune"].astype(str).str.strip()
df["code_departement"] = df["code_departement"].astype(str).str.strip()
df["code_region"] = df["code_region"].astype(str).str.strip()
```

Les champs textuels ont été harmonisés par suppression des espaces inutiles afin d'éviter les erreurs de comparaison et améliorer la qualité des traitements ETL.

Harmonisation - Dataset 01_revenus_2022.csv

L'EDA a également mis en évidence une différence de millésime entre les datasets : les données de revenus étaient associées aux codes INSEE 2021, tandis que le référentiel communal principal du projet reposait sur les codes INSEE 2022.

Cette différence s'explique notamment par les évolutions administratives des communes entre 2021 et 2022 (fusions, suppressions ou créations de communes). Afin de garantir la cohérence des jointures et l'harmonisation des données territoriales, une table officielle de correspondance INSEE 2021 → 2022 a été utilisée durant le processus de traitement.

```
# Jointure avec la table de passage
df = df.merge(
    passage,
    left_on="code_insee_2021",
    right_on="CODGEO_2021",
    how="left"
)

# Si un nouveau code existe, on le récupère
# Sinon on garde l'ancien
df["code_insee"] = df["CODGEO_2022"].fillna(df["code_insee_2021"])
```

Harmonisation - Dataset 02_Taux_chomage_2022.csv + Dataset 03_Categorie_sociale_2022.csv

Les codes INSEE ont été harmonisés sur un format homogène afin de garantir des jointures fiables avec le référentiel communal.

```
# Normalisation du code INSEE
df["code_insee"] = (df["code_insee"].astype(str).str.zfill(5))
```

Les noms de colonnes du fichier Excel ont également été nettoyés afin de supprimer les espaces, les retours à la ligne et les caractères parasites.

```
# ÉTAPE 4 : NETTOYAGE DES NOMS DE COLONNES

df_raw.columns = (
    df_raw.columns
    .astype(str)
    .str.strip()
    .str.replace("\n", "", regex=False)
    .str.replace(" ", "", regex=False)
)
```

Normalisation

La normalisation des données a permis d'harmoniser les valeurs et les formats des divers datasets pour assurer leur adéquation avec les traitements analytiques et les algorithmes¹⁶ d'apprentissage automatique. Nous avons inclus dans cette phase :

- La normalisation des formats de données
- La standardisation des valeurs numériques
- Les formats CSV/SQL
- L'harmonisation des types de données
- La préparation des variables pour les analyses statistiques et le Machines Learning

Normalisation - **Traitements communs à l'ensemble des datasets :**

```
# Normalisation du code INSEE sur 5 caractères :  
df["code_insee"] = df["code_insee"].astype(str).str.zfill(5)
```

Le code_insee a été normalisé sur un format homogène afin de conserver les zéros en début de code et garantir la cohérence des futures jointures entre datasets.

Normalisation - **Dataset 01_revenus_2022_.csv**

L'analyse exploratoire des données a notamment mis en lumière la présence de la valeur « s » dans plusieurs colonnes du dataset. Ces valeurs correspondent à des données non diffusées par l'INSEE et requièrent un traitement spécifique lors des phases de nettoyage et d'harmonisation.

Ces constats ont été pris en compte tout au long du pipeline ETL afin d'éviter l'intégration de valeurs incohérentes dans le dataframe final utilisé pour le Machine Learning.

Un traitement de normalisation a donc été appliqué afin de :

- Convertir les revenus au format numérique
- Transformer automatiquement les valeurs non exploitables en NaN

```
# FONCTION DE NETTOYAGE NUMÉRIQUE  
def clean_numeric(series):  
    """  
    Nettoyage des colonnes numériques :  
    - suppression des espaces  
    - remplacement des virgules par des points  
    - conversion en float  
    """  
    return pd.to_numeric(  
        series.astype(str)  
        .str.strip()  
        .str.replace(r"\s+", "", regex=True)  
        .str.replace(",", ".", regex=False),  
        errors="coerce"  
    )
```

¹⁶ Cf Glossaire

Normalisation - Dataset_02_Taux_chomage_2022.csv

Les colonnes quantitatives ont été converties dans un format numérique exploitable pour les calculs statistiques.

Les traitements appliqués permettent de supprimer les espaces inutiles, d'uniformiser les séparateurs décimaux, de convertir les valeurs au format numérique et de transformer les valeurs invalides en NaN.

```
# ÉTAPE 7 : CONVERSION DES COLONNES NUMÉRIQUES

for col in colonnes_emploi + colonnes_chomeur:

    # Nettoyage des formats numériques
    df[col] = (
        df[col]
        .astype(str)
        .str.replace(r"\s+", "", regex=True)
        .str.replace(",", ".", regex=False)
    )

    # Conversion en float
    df[col] = pd.to_numeric(
        df[col],
        errors="coerce"
    )
```

Normalisation - Dataset 03_Categorie_sociale_2022.csv

Les colonnes quantitatives ont été converties dans un format numérique exploitable pour les traitements statistiques et le Machine Learning.

```
# ÉTAPE 5 : CONVERSION DES COLONNES NUMÉRIQUES

for col in df.columns:

    if col != "code_insee":

        # Conversion en numérique
        df[col] = pd.to_numeric(
            df[col],
            errors="coerce"
        )
```

Le paramètre `errors="coerce"` permet de convertir automatiquement les valeurs non numériques en valeurs manquantes (NaN).

Suppression des doublons

Nous avons effectué des contrôles de qualité et de fiabilité des données pour identifier les éventuels doublons au sein de jeux de données.

Cette démarche a permis de prévenir les incohérences et les biais dans les analyses statistiques ainsi que les modèles de Machine Learning.

Suppression des doublons - Dataset 00_insee_code_referentiel.csv

Les doublons ont été supprimés à partir de la clé code_insee, chaque commune devant être représentée une seule fois dans le référentiel final.

```
# Étape 7 : Suppression des doublons :  
  
# Suppression des doublons sur le code INSEE car chaque commune doit être unique dans le référentiel  
df = df.drop_duplicates(subset=["code_insee"])
```

Suppression des doublons – Dataset 01_revenus_2022.py

L'EDA pré-cleaning montre qu'il n'y a pas de doublons dans le fichier revenu communal : 0 doublon global et 0 doublon sur CODGEO.

```
# ANALYSE DES DOUBLONS  
  
# Vérification des doublons complets dans le dataset  
print("\n--- DOUBLONS ---")  
print(df.duplicated().sum())  
  
# ANALYSE DES CODES INSEE  
  
# Vérifications sur la clé principale de notre dataset : le code INSEE  
if "COM" in df.columns:  
    # Nombre de codes INSEE uniques  
    print("\n--- NOMBRE DE CODES INSEE UNIQUES ---")  
    print(df["COM"].nunique())
```

```
--- DOUBLONS ---  
0  
  
--- NOMBRE DE CODES INSEE UNIQUES ---  
34929
```

En revanche, des contrôles de déduplication ont été appliqués sur les différents référentiels utilisés pour les jointures (référentiel communes, table de passage INSEE, revenus départementaux) afin de garantir l'unicité des clés géographiques et sécuriser les correspondances entre datasets.

```
# Suppression des doublons éventuels  
df_ref = df_ref.drop_duplicates(subset=["code_insee"])
```

```
# Suppression des doublons  
df_dep = df_dep.drop_duplicates(subset=["code_departement"])
```

```
# Conservation des colonnes utiles uniquement  
passage = passage[["CODGEO_2021", "CODGEO_2022"]].drop_duplicates()
```

Suppression des doublons - Dataset 02_Taux_chomage_2022 + 03_Categorie_sociale_2022

Les contrôles effectués sur la clé géographique CODGEO montrent aucun doublon global dans le dataset, aucun doublon sur les codes INSEE, une longueur homogène des codes INSEE sur 5 caractères.

```
# ANALYSE DES DOUBLONS

print("\n--- DOUBLONS ---")
print(df.duplicated().sum())
```

```
# ANALYSE DES CODES INSEE
```

```
if "CODGEO" in df.columns:
```

```
    print("\n--- NOMBRE DE CODES INSEE UNIQUES ---")
    print(df["CODGEO"].nunique())
```

```
    print("\n--- LONGUEUR DES CODES INSEE ---")
    print(df["CODGEO"].astype(str).str.len().value_counts())
```

```
    print("\n--- DOUBLONS SUR CODE INSEE ---")
    print(df.duplicated(subset=["CODGEO"]).sum())
```

```
--- DOUBLONS ---
```

```
0
```

```
--- NOMBRE DE CODES INSEE UNIQUES ---
```

```
34858
```

```
--- LONGUEUR DES CODES INSEE ---
```

```
CODGEO
```

```
5    34858
```

```
Name: count, dtype: int64
```

```
--- DOUBLONS SUR CODE INSEE ---
```

```
0
```

Le dataset brut ne présente donc pas d'anomalie structurelle sur les identifiants communaux. Aucune suppression de doublon n'a été nécessaire sur le fichier principal.

Statistiques descriptives

Lors de l'analyse exploratoire des données (EDA), nous avons calculé plusieurs statistiques descriptives afin de mieux comprendre la structure des jeux de données, d'en vérifier la cohérence et de détecter d'éventuelles anomalies avant l'entraînement des modèles de Machine Learning.

Cette phase a permis d'analyser :

- La distribution des variables
- Les tendances générales des données
- Les valeurs minimales et maximales
- Les moyennes et médianes
- Les quartiles
- Les valeurs aberrantes¹⁷ (outliers)
- Les corrélations potentielles entre les différents indicateurs

Statistiques descriptives - 01_revenus_2022.py

Les statistiques descriptives permettent de résumer la distribution des revenus médians communaux après nettoyage :

```
--- STATISTIQUES ---
count    34826.000000
mean     23093.726813
std      3046.524896
min      12260.000000
25%      21160.000000
50%      22660.000000
75%      24450.000000
max      55340.000000
Name: revenu_median_final, dtype: float64
```

- Revenu médian moyen : 23 094 €
- Médiane nationale : 22 660 €
- Minimum observé : 12 260 €
- Maximum observé : 55 340 €

Les quartiles calculés (Q1 et Q3) ont ensuite été utilisés pour construire les classes de revenus (pauvre, moyen, riche) exploitées dans les analyses et modèles Machine Learning.

Analyse des distributions

Nous avons réalisé des histogrammes et visualisations exploratoires pour examiner la répartition des variables intégrées au projet.

Ces représentations graphiques permettent de :


- Mettre en évidence des regroupements de valeurs
- Détecter les asymétries au sein des distributions
- Repérer les valeurs aberrantes (outliers)
- Vérifier la cohérence globale des données avant leur utilisation dans les modèles de Machine Learning

Analyse des distributions - 01_revenus_2022.py

L'histogramme des revenus médians montre une distribution concentrée principalement entre 20 000 € et 30 000 € de revenu médian annuel.

La majorité des communes françaises présentent ainsi des revenus relativement proches de la moyenne nationale, avec une concentration importante autour de 22 000 € et 25 000 €.

Le dataset présente également quelques communes avec des revenus nettement plus élevés, visibles dans la partie droite de la distribution.




Analyse des distributions - 02_Taux_chomage_2022.py

L'histogramme du taux de chômage montre une distribution principalement concentrée entre 5 % et 15 % de chômage pour la majorité des communes françaises.

La distribution présente une asymétrie vers la droite avec quelques communes affichant des taux particulièrement élevés. Ces valeurs extrêmes restent toutefois marginales par rapport à l'ensemble du dataset.


Cette distribution est cohérente avec les écarts socio-économiques observés entre les communes françaises et confirme la présence de quelques micro-communes présentant des situations statistiques atypiques.




Analyse des distributions – 03_Categorie_sociale_2022.csv

L'analyse des distributions met en évidence des comportements différents selon les catégories socioprofessionnelles étudiées.



Le pourcentage d'agriculteurs présente une distribution fortement asymétrique vers la droite. La majorité des communes possède une faible proportion d'agriculteurs, tandis qu'un nombre plus restreint de communes rurales présente des valeurs nettement plus élevées.



Les pourcentages de cadres présentent également une asymétrie positive avec certaines communes affichant une forte représentation des catégories socio-professionnelles supérieures.



À l'inverse, les variables concernant les employés et les ouvriers présentent des distributions plus centrées, avec des valeurs majoritairement regroupées autour des moyennes observées.



Globalement, les distributions observées restent cohérentes avec les différences socio-économiques et territoriales entre les communes françaises.

Détection des valeurs aberrantes (outliers)

Nous avons été particulièrement attentifs à la détection des valeurs aberrantes (outliers). Certaines communes présentent en effet des caractéristiques extrêmes susceptibles d'affecter de manière significative les analyses statistiques ainsi que les performances des modèles.

L'examen des histogrammes et des indicateurs statistiques nous a permis d'identifier ces valeurs atypiques afin de :


- Valider leur plausibilité
- Déterminer si elles correspondaient à des anomalies
- Ou confirmer qu'elles reflétaient des situations réelles propres à certains territoires

Détection des valeurs aberrantes - 01_revenus_2022.csv

Le boxplot met en évidence plusieurs valeurs atypiques correspondant à des communes présentant des revenus médians particulièrement élevés.


Ces valeurs n'ont pas été supprimées car elles correspondent à des données réelles et cohérentes économiquement.

Leur conservation permet de préserver la variabilité réelle des revenus entre communes françaises.



Détection des valeurs aberrantes – 02_Taux_chomage_2022.csv

L'analyse de la distribution du taux de chômage met en évidence quelques valeurs extrêmes, notamment des communes présentant des taux de chômage supérieurs à 70%.



Les contrôles effectués montrent que ces cas correspondent à des micro-communes disposant d'un très faible nombre d'actifs :

- Commune 04107 : 3 chômeurs pour 3 actifs
- Commune 05066 : 1,75 chômeur pour 1,75 actif

Les valeurs décimales observées proviennent directement des données statistiques pondérées fournies par l'INSEE et n'ont donc pas été modifiées dans le pipeline ETL.

Le taux de chômage étant calculé à partir du rapport entre le nombre de chômeurs et le nombre d'actifs, ces résultats restent mathématiquement cohérents malgré la très faible taille de la population active de certaines micro-communes.

```
# DEBUG TAUX > 70
```

```
print("\n--- LIGNES AVEC TAUX_CHOMAGE > 70 ---")
```

```
print(df[df["taux_chomage"] > 70][["code_insee",  
    "emploi_total",  
    "chomeurs_total",  
    "actifs_total",  
    "taux_chomage"]])
```

```
--- LIGNES AVEC TAUX_CHOMAGE = 100 ---  
code_insee  emploi_total  chomeurs_total  actifs_total  taux_chomage  
1587      04107          0.0            3.00          3.00          100.0  
1759      05066          0.0            1.75          1.75          100.0  
  
--- LIGNES AVEC TAUX_CHOMAGE > 70 ---  
code_insee  emploi_total  chomeurs_total  actifs_total  taux_chomage  
1587      04107          0.0            3.00          3.00          100.0  
1759      05066          0.0            1.75          1.75          100.0
```

Ces valeurs élevées ne proviennent donc pas d'une erreur de calcul, mais d'un effet statistique lié à la très faible taille de la population active de certaines communes.


Ces observations ont été conservées dans le dataset final car elles correspondent à des données réelles présentes dans les fichiers sources de l'INSEE. Leur suppression aurait entraîné une perte d'information sur certaines communes rurales à très faible population active.

Analyse des corrélations

Nous avons étudié les corrélations entre variables dans le but de mettre en évidence les relations potentielles entre certains indicateurs et les comportements électoraux.

Cette démarche nous a permis :

- D'évaluer la pertinence des variables utilisées
- De détecter les dépendances existantes entre différents indicateurs
- De mieux comprendre les facteurs influençant les prédictions des modèles de Machine Learning



L'analyse des corrélations a permis d'identifier plusieurs relations pertinentes entre les variables avant la phase de modélisation Machine Learning.

Par exemple, une très forte corrélation est observée entre la population et le nombre de créations d'entreprises (0.97), ainsi qu'entre la population et le nombre d'associations (0.72). Ces résultats montrent que les communes les plus peuplées disposent généralement d'un tissu économique et associatif plus développé.

Les variables démographiques présentent également des relations importantes. L'âge médian est fortement corrélé négativement avec la proportion de jeunes (-0.79) et positivement avec la proportion de seniors (0.76). Ces corrélations permettent de mieux caractériser les profils démographiques des communes intégrées au modèle.

Sur le plan socio-économique, le revenu médian présente une corrélation positive avec le pourcentage de cadres (0.50) et une corrélation négative avec le taux de chômage (-0.38) ainsi qu'avec le pourcentage d'ouvriers (-0.23). Ces relations traduisent des écarts économiques et sociaux cohérents entre les territoires.

Concernant la criminalité, certaines corrélations apparaissent entre les variables urbaines et les indicateurs de délinquance. Par exemple, la densité de population est corrélée avec les vols violents sans arme (0.59) et les vols avec armes (0.43), ce qui suggère une concentration plus importante de certains faits de délinquance dans les zones urbaines denses.

Cette analyse a également permis d'identifier certaines variables fortement corrélées entre elles pouvant introduire de la redondance dans les modèles prédictifs. Elle constitue donc une étape importante de compréhension et de préparation des données avant l'entraînement des algorithmes de Machine Learning.

C) Feature engineering

Dans le cadre du feature engineering, plusieurs transformations ont été mises en œuvre afin de générer de nouvelles variables plus pertinentes aux modèles de Machine Learning.

Feature engineering - Catégorisation des revenus médians 2022

La première étape a porté sur l'ensemble de données des revenus médians communaux (01_revenus_2022). À partir des statistiques descriptives de ce jeu de données, nous avons examiné la distribution des revenus médians par commune. Afin de simplifier certaines analyses et de faciliter l'exploitation des données par les modèles de Machine Learning, nous avons créé trois classes de revenus :

- pauvre
- moyen
- riche

Cette catégorisation s'appuie sur les quartiles statistiques du jeu de données, à savoir le premier quartile (Q1) et le troisième quartile (Q3) :

- Les communes dont le revenu médian est inférieur au premier quartile ont été classées dans la catégorie « pauvre ».
- Les communes situées entre Q1 et Q3 ont été classées dans la catégorie « moyen », tandis que celles dépassant le troisième quartile ont été classées dans la catégorie « riche »

```
# ÉTAPE 11 : CRÉATION DES CLASSES DE REVENUS

# Calcul des quartiles nationaux
q1_revenu = df_final["revenu_médian_final"].quantile(0.25)
q3_revenu = df_final["revenu_médian_final"].quantile(0.75)

print("\n--- SEUILS CLASSES REVENUS ---")
print("Q1 national communes :", round(q1_revenu, 2))
print("Q3 national communes :", round(q3_revenu, 2))

# Fonction de classification
def classer_revenu(x):
    if pd.isna(x):
        return "inconnu"
    elif x < q1_revenu:
        return "pauvre"
    elif x > q3_revenu:
        return "riche"
    else:
        return "moyen"
```

```
--- SEUILS CLASSES REVENUS ---  
Q1 national communes : 21160.0  
Q3 national communes : 24450.0
```

Cette approche permet de mieux représenter les disparités socio-économiques interterritoriales et d'étudier leur impact sur les comportements électoraux.

Contrairement à d'autres transformations expérimentales, ces variables ont été conservées dans le dataframe final, car elles ont apporté une information pertinente aux modèles de Machine Learning.

Feature engineering - Construction de la variable cible et transformations électorales 2022

La deuxième étape de feature engineering a été menée à partir de l'ensemble de données issu des résultats du premier tour de l'élection présidentielle française de 2022 (Dataset [Election présidentielle des 10 et 24 avril 2022 - Résultats définitifs du 1er tour](#)).

Dans un premier temps, nous avons construit plusieurs variables dérivées à partir du dataset des résultats du premier tour des élections présidentielles afin d'enrichir le dataframe d'apprentissage.

Les traitements réalisés comprenaient :

- La préservation des codes communaux afin d'assurer la concordance avec le référentiel de l'INSEE
- La conservation des noms des candidats et des suffrages obtenus
- Le regroupement des candidats par blocs politiques
- Le calcul des pourcentages de voix recueillis par chaque bloc politique à l'échelle communale

Ces transformations nous ont permis de générer plusieurs variables électorales et temporelles, visant à mieux représenter les dynamiques politiques locales au sein des modèles de Machine Learning. Nous avons ensuite intégré ces variables au dataframe d'apprentissage afin d'évaluer leur impact sur les performances des modèles.

Par la suite, ce premier jeu de données électorales a été remplacé par une source de données plus exhaustive et plus adaptée à la construction de la variable cible (Y).

Après plusieurs phases de tests et d'évaluation, nous avons remarqué que certaines variables temporelles électorales introduisaient du bruit dans les modèles de Machine Learning et réduisaient, dans certains cas, leur capacité de généralisation.

Ces variables ont donc été retirées du dataframe final, afin de ne conserver que les indicateurs les plus pertinents pour l'apprentissage.

Grâce à cette phase de feature engineering, nous avons pu :

- Enrichir les données initiales
- Tester différentes représentations des comportements électoraux
- Évaluer l'impact réel des transformations sur les performances des modèles
- Optimiser le dataframe final utilisé pour le Machine Learning

Feature engineering - Calcul et construction du taux de chômage communal 2022

Les indicateurs agrégés ont ensuite été calculés à partir des différentes catégories d'emploi et de chômage présentes dans le fichier source, notamment les emplois et chômeurs hommes/femmes français ainsi que les emplois et chômeurs hommes/femmes étrangers.

```
# ÉTAPE 8 : CALCULS DES INDICATEURS

# Somme des personnes en emploi
df["emploi_total"] = df[colonnes_emploi].sum(axis=1, min_count=1)

# Somme des chômeurs
df["chomeurs_total"] = df[colonnes_chomeur].sum(axis=1, min_count=1)

# Calcul de la population active
df["actifs_total"] = (df["emploi_total"] + df["chomeurs_total"])

# Calcul du taux de chômage
df["taux_chomage"] = np.where(
    df["actifs_total"] > 0,
    (df["chomeurs_total"] / df["actifs_total"]) * 100,
    np.nan)
```

Les calculs réalisés permettent d'obtenir le nombre total d'emplois, le nombre total de chômeurs, le nombre total d'actifs ainsi que le taux de chômage communal.

Ce taux constitue une variable dérivée construite spécifiquement pour les besoins du modèle de Machine Learning. L'objectif est de fournir au modèle un indicateur synthétique et directement exploitable plutôt que les données brutes détaillées par catégorie.

Feature engineering – calcul de la répartition socioprofessionnelle 2022 (% agriculteurs, cadres, employés, ouvriers)

À partir des données brutes réparties par tranche d'âge, plusieurs variables dérivées ont été construites afin d'obtenir une vision synthétique de la composition socioprofessionnelle de chaque commune.

Dans un premier temps, les effectifs des différentes tranches d'âge ont été agrégés pour calculer le nombre total d'agriculteurs, de cadres, d'employés et d'ouvriers.

```
# ÉTAPE 6 : CALCUL DES TOTAUX PAR CATÉGORIE

# Calcul du total agriculteurs
df["agri_total"] = (df[["agri_15_24", "agri_25_54", "agri_55p"]].sum(axis=1, min_count=1))

# Calcul du total cadres
df["cadres_total"] = (df[["cadres_15_24", "cadres_25_54", "cadres_55p"]].sum(axis=1, min_count=1))

# Calcul du total employés
df["employes_total"] = (df[["employes_15_24", "employes_25_54", "employes_55p"]].sum(axis=1, min_count=1))

# Calcul du total ouvriers
df["ouvriers_total"] = (df[["ouvriers_15_24", "ouvriers_25_54", "ouvriers_55p"]].sum(axis=1, min_count=1))
```

Un total global d'actifs a ensuite été calculé en additionnant ces différentes catégories socioprofessionnelles.

```
# ÉTAPE 7 : CALCUL DU TOTAL D'ACTIFS

df["total_actifs"] = (df["agri_total"] + df["cadres_total"] + df["employes_total"] + df["ouvriers_total"])
```

Enfin, des variables de pourcentage ont été générées afin de mesurer la part de chaque catégorie dans la population active communale :

```
# ÉTAPE 8 : CALCUL DES POURCENTAGES

# Pourcentage agriculteurs
df["pourcentage_agri"] = np.where(df["total_actifs"] > 0, (df["agri_total"] / df["total_actifs"]) * 100, np.nan)

# Pourcentage cadres
df["pourcentage_cadres"] = np.where(df["total_actifs"] > 0, (df["cadres_total"] / df["total_actifs"]) * 100, np.nan)

# Pourcentage employés
df["pourcentage_employes"] = np.where(df["total_actifs"] > 0, (df["employes_total"] / df["total_actifs"]) * 100, np.nan)

# Pourcentage ouvriers
df["pourcentage_ouvriers"] = np.where(df["total_actifs"] > 0, (df["ouvriers_total"] / df["total_actifs"]) * 100, np.nan)
```

Les calculs de pourcentage ont été sécurisés afin d'éviter les divisions par zéro lorsque le nombre total d'actifs était nul.

Ces nouvelles variables permettent de transformer les données brutes en indicateurs exploitables pour l'analyse statistique et les futurs modèles de machine learning.

Feature engineering – Estimation référentiel commune 20 24

Synthèse de la qualité du dataframe 2024

À partir du fichier de passage INSEE, un référentiel de correspondance entre les communes 2022 et 2024 a été construit afin de suivre correctement les évolutions territoriales. Le traitement a consisté à sélectionner les codes INSEE 2022, les codes INSEE 2024 ainsi que les noms des communes, puis à appliquer plusieurs opérations de nettoyage : harmonisation des codes au format officiel sur 5 caractères, nettoyage des champs texte, mise en majuscules des noms de communes et suppression des doublons.

Un filtrage supplémentaire a été appliqué pour exclure les arrondissements municipaux de Paris, Lyon et Marseille. Le résultat final est un fichier propre et homogène permettant d'effectuer des analyses fiables sur les communes entre 2022 et 2024.

```
# Nettoyage
df["CODGEO_2022"] = df["CODGEO_2022"].astype(str).str.strip().str.zfill(5)
df["CODGEO_2024"] = df["CODGEO_2024"].astype(str).str.strip().str.zfill(5)
df["col_nom"] = df["col_nom"].astype(str).str.strip().str.upper()

# -----
# Suppression des Arrondissements
# -----
masque_arrondissements = (
    df["CODGEO_2024"].str.startswith("751") |
    df["CODGEO_2024"].str.startswith("132") |
    df["CODGEO_2024"].str.startswith("693")
)
nb_arrondissements = masque_arrondissements.sum()
df = df[~masque_arrondissements] # On ne garde que ce qui n'est PAS un arrondissement
# On retire les doublons
df = df.drop_duplicates()
```

```
C:\Users\Vo-ca\Desktop\mshr_data_final\visi_li_mshr_data> python .\cleaning_scripts_2024\00_referentiel_commune_22_24.py
Création du Référentiel communes 2022-2024
Chargement des données...

=====
RAPPORT DE QUALITÉ DES DONNÉES
=====
(Fichier brut) : 36760
Arrondissements supprimés : 45
(Référentiel) : 34959

-----
Nouvelles Communes (issues de fusions) : 19
Anciens villages absorbés par fusion : 42
-----
Valeurs manquantes ou zéros (NaN) : 0
TAUX DE PERFECTION : 100.00 %
=====
Référentiel est 100% propre,
```


Feature engineering - Calcul de la densité de population 2024

Pour constituer le jeu de données 2024, nous avons effectué plusieurs traitements à partir des jeux de données INSEE des décès, des naissances ainsi que des données communales de population et de superficie. Seules les communes et l'année 2024 ont été conservées, les autres niveaux géographiques et années étant éliminés.

Les colonnes pertinentes ont été extraites, normalisées (codes INSEE) et converties en numériques. Après gestion des valeurs manquantes et contrôle des incohérences, ces données ont été fusionnées avec la population pour calculer la densité de population communale, utilisée dans le pipeline ETL et les traitements de Machine Learning.

```
PS C:\Users\hiz-ca\Desktop\mspr_data_final\veisi_i1_mspr_data> python .\cleaning_scripts_2024\01.1_decès_2024.py
Nettoyage fichier DÉCÈS
Lecture du fichier brut INSEE...
Filtrage de l'année 2024 et de l'échelle communale...
Application du référentiel géographique 2024...

=====
DÉCÈS 2024
=====
Lignes brutes totales (toutes années/régions) : 710,821
Lignes isolées (Communes en 2024) : 34,871
Communes finales après Référentiel : 34,867
Fusions gérées automatiquement : 19
Valeurs manquantes (NaN) corrigées en 0 : 0
Total des décès calculés : 641,538
Taux de perfection (Communes avec décès > 0) : 87.84 %

=====
Aperçu (Top 3) :
=====
code_insee_2024  nom_commune_2024  nb_decès  année
0  01001  L'ABERGEMENT-CLÉVENCIAT  4  2024
1  01002  L'ABERGEMENT-DE-VAREY  4  2024
2  01004  AMBÈRTEU-EN-BUGEY  119  2024

PS C:\Users\hiz-ca\Desktop\mspr_data_final\veisi_i1_mspr_data> python .\cleaning_scripts_2024\01.1_naissances_2024.py
Nettoyage fichier NAISSANCES
Lecture du fichier brut INSEE...
Filtrage de l'année 2024 et de l'échelle communale...
Application du référentiel géographique 2024...

=====
NAISSANCES 2024
=====
Lignes brutes totales : 710,821
Lignes isolées (COM en 2024) : 34,871
Communes finales consolidées : 34,867
Fusions gérées : 19
Valeurs manquantes corrigées : 0
Total naissances calculées : 660,154
Taux perfection (> 0 naiss.) : 84.08 %

=====
Aperçu (Top 3) :
=====
code_insee_2024  nom_commune_2024  nb_naissances  année
0  01001  L'ABERGEMENT-CLÉVENCIAT  8  2024
1  01002  L'ABERGEMENT-DE-VAREY  1  2024
2  01004  AMBÈRTEU-EN-BUGEY  175  2024

PS C:\Users\hiz-ca\Desktop\mspr_data_final\veisi_i1_mspr_data> []
```

Résultat final de la densité obtenue

```
# 4. RECALCUL DE LA DENSITÉ ET TAUX DE PERFECTION
# =====
print("Recalcul des densités...")
df_final["densite"] = df_final.apply(
    lambda row: round(row["population"] / row["superficie_km2"], 2) if row["superficie_km2"] > 0 else 0,
    axis=1
)

comptage_fusions = df_mapped.drop_duplicates(subset=["code_insee_2024"]).groupby("code_insee_2024").size()
nb_communes_fusionnees = len(comptage_fusions[comptage_fusions > 1])

lignes_fin = len(df_final)

# =====
# CALCUL DU TAUX DE PERFECTION (Précision)
# =====
# Une ligne parfaite a une population > 0 ET une superficie > 0
lignes_imparfaites = ((df_final["population"] == 0) | (df_final["superficie_km2"] == 0)).sum()
taux_parfait = ((lignes_fin - lignes_imparfaites) / lignes_fin) * 100 if lignes_fin > 0 else 0

PS C:\Users\hiz-ca\Desktop\mspr_data_final\veisi_i1_mspr_data> python .\cleaning_scripts_2024\01.1_population_densite_2024.py
Nettoyage fichier POPULATION & DENSITÉ
Lecture du fichier brut...
Application du référentiel géographique 2024...
Recalcul des densités...

=====
POPULATION & DENSITÉ
=====
Lignes brutes totales : 34,990
Communes finales consolidées : 34,992
Fusions gérées : 19
Valeurs manquantes (NaN) : 0
Valeurs égales à 0 au départ : 18
Total Population France : 67,450,094
TAUX DE PERFECTION (Précision) : 99.95 %

=====
Aperçu (Top 3) :
=====
code_insee_2024  nom_commune_2024  population  superficie_km2  densite  année
0  01001  L'ABERGEMENT-CLÉVENCIAT  886  16  50.38  2024
1  01002  L'ABERGEMENT-DE-VAREY  262  9  29.11  2024
2  01004  AMBÈRTEU-EN-BUGEY  14288  24  595.33  2024

PS C:\Users\hiz-ca\Desktop\mspr_data_final\veisi_i1_mspr_data> []
```

Feature engineering - Calcul de la criminalité 2024

Pour constituer le jeu de données 2024, nous avons effectué plusieurs traitements à partir du jeu de données INSEE de criminalité. Les données ont d'abord été filtrées pour ne conserver que l'année 2024 et les principaux indicateurs de criminalité communale. Les colonnes pertinentes ont été extraites, nettoyées et harmonisées via la normalisation des codes INSEE, la conversion des données numériques, le remplacement des séparateurs décimaux et le traitement des valeurs manquantes. Pour limiter les pertes dues au secret statistique, un taux final unique a été reconstruit en fusionnant les colonnes taux_pour_mille et complement_info_taux.

```
# 5. GESTION DU TAUX FINAL
# =====
# Récupération des données masquées (ndiff)
df["taux_final"] = df["taux_pour_mille"].fillna(df["complement_info_taux"])

df["taux_final"] = df["taux_final"].astype(str).str.replace(",", ".")
df["taux_final"] = pd.to_numeric(df["taux_final"], errors="coerce")

# =====
# 6. PIVOT DES DONNÉES
# =====
print("Pivot de la table...")
df_pivot = df.pivot_table(
    index=["code_insee_final", "année"],
    columns="indicateur",
    values="taux_final",
    aggfunc="mean" # Moyenne du taux si des communes ont fusionné
).reset_index()

# 7. RENOMMAGE
# =====
df_pivot = df_pivot.rename(columns={
    "code_insee_final": "code_insee_2024",
    "Violences physiques intrafamiliales": "taux_violences_intrafamiliales",
    "Violences sexuelles": "taux_violences_sexuelles",
    "Vols avec armes": "taux_vols_avec_armes",
    "Vols violents sans arme": "taux_vols_violents_sans_arme",
    "Cambriolages de logement": "taux_cambriolages_logement",
    "Vols de véhicule": "taux_volsvehicule",
    "Destructions et dégradations volontaires": "taux_degradations",
    "Usage de stupéfiants": "taux_usage_stupefiants",
    "Trafic de stupéfiants": "taux_trafic_stupefiants"
})

df_pivot = df_pivot.merge(ref[["code_insee_2024", "nom_commune_2024"]].drop_duplicates(), on="code_insee_2024", how="left")

cols = df_pivot.columns.tolist()
cols.insert(1, cols.pop(cols.index("nom_commune_2024")))
df_pivot = df_pivot[cols]
```

Enfin, les données ont été agrégées en tableau large, avec une ligne par commune et une colonne par indicateur de criminalité.

Résultat final de la criminalité par commune

```
RAPPORT : CRIMINALITÉ 2024
Fichier créé : 02_criminalite_diff_ndiff_2024_cleaned.csv

Shape finale : (34863, 12)

NaN count par indicateur (Certaines communes n'ont pas de données pour certains crimes) :
code_insee_2024      0
nom_commune_2024    0
annee               0
taux_cambriolages_logement  2
taux_degradations   1
taux_trafic_stupefiants  2
taux_usage_stupefiants  2
taux_violences_intrafamiliales  2
taux_violences_sexuelles  2
taux_vols_avec_armes  2
taux_vols_vehicule   0
taux_vols_violents_sans_arme  2
dtype: int64

Pourcentage de NaN (%) :
code_insee_2024      0.00
nom_commune_2024    0.00
annee               0.00
taux_cambriolages_logement  0.01
taux_degradations   0.00
taux_trafic_stupefiants  0.01
taux_usage_stupefiants  0.01
taux_violences_intrafamiliales  0.01
taux_violences_sexuelles  0.01
taux_vols_avec_armes  0.01
taux_vols_vehicule   0.00
taux_vols_violents_sans_arme  0.01
dtype: float64

Codes sources non retrouvés dans notre référentiel : 0

HEAD (Aperçu) :
code_insee_2024      nom_commune_2024 annee  taux_cambriolages_logement  ...  taux_violences_sexuelles  taux
0      01001  L'ABERGEMENT-CLÉMENTIAT  2024      7.967921  ...      1.378545
```

Feature engineering - Calcul de la démographie 2024

Pour constituer le jeu de données 2024, nous avons effectué plusieurs traitements à partir des données INSEE 2022 sur les tranches d'âge communales, du référentiel géographique 2022–2024 ainsi que des données réelles de population 2024.

Les données ont été nettoyées et harmonisées via la normalisation des codes INSEE, la gestion des fusions communales et la conversion des valeurs numériques. Une projection démographique a estimé l'évolution des tranches d'âge entre 2022 et 2024 avec des coefficients basés sur les tendances INSEE. Les proportions obtenues ont été appliquées à la population réelle 2024 pour produire des indicateurs communaux cohérents. Enfin, des variables comme le pourcentage de jeunes, de seniors et l'âge médian ont été calculées pour le pipeline ETL et les traitements de Machine Learning.

Résultat final de la population

```
# 5. CROISEMENT AVEC LA VRAIE POPULATION 2024
# =====
print("Calcul des indicateurs finaux sur la population 2024...")

df_final = pd.merge(df_agg, df_pop[['code_insee_2024', 'population']], on='code_insee_2024', how='inner')

# On applique les proportions aux vrais volumes 2024
final_tranches_cols = []
for col in age_cols:
    new_col = f'{col}_2024'
    final_tranches_cols.append(new_col)
    df_final[new_col] = (df_final['population'] * df_final[f'prop_{col}']).fillna(0)

# Groupements : Jeunes (< 25 ans = les 5 premières tranches) et Seniors (>= 65 ans = les 7 dernières)
jeunes_cols = final_tranches_cols[:5]
seniors_cols = final_tranches_cols[5:]

df_final['jeunes'] = df_final[jeunes_cols].sum(axis=1)
df_final['seniors'] = df_final[seniors_cols].sum(axis=1)

df_final['pct_jeunes'] = np.where(df_final['population'] > 0, (df_final['jeunes'] / df_final['population']) * 100, np.nan)
df_final['pct_seniors'] = np.where(df_final['population'] > 0, (df_final['seniors'] / df_final['population']) * 100, np.nan)

# Age médian
df_final['age_median'] = df_final.apply(lambda row: calcul_age_median(row, final_tranches_cols, midpoints), axis=1)
```

```
Mapping géographique et gestion des fusions...
Calcul des indicateurs finaux sur la population 2024...

=====
RAPPORT : DÉMOGRAPHIE & ÂGE 2024
=====
Fichier créé : 03_tranches_age_2024_clean.csv
Communes traitées : 34,802
Moyenne nationale pct_jeunes : 24.82 %
Moyenne nationale pct_seniors : 24.57 %
Médiane de l'âge médian FR : 47.5 ans
=====

Aperçu :
code_insee_2024      nom commune_2024  pct_jeunes  pct_seniors  age_median  annee
0      01001  L'ABERGEMENT-CLÉMENTIAT      26.94      17.59      47.5  2024
1      01002  L'ABERGEMENT-DE-VAREY      28.45      24.16      42.5  2024
2      01004  AMBÉRIEU-EN-BUGEY      30.94      18.99      37.5  2024
PS C:\Users\hz-ca\Desktop\mspr_data\final\veisi_i1\mspr_data> []
```

Feature engineering - Calcul des revenus médians 2024

Pour constituer le jeu de données 2024, nous avons effectué plusieurs traitements à partir des données INSEE 2023. Seul l'indicateur MED_SL (revenu médian du niveau de vie) a été conservé après filtrage. Les communes ont été harmonisées avec le référentiel géographique 2024 pour intégrer les fusions et évolutions territoriales. Les données ont été nettoyées et agrégées par commune via normalisation des codes INSEE, conversion numérique et gestion des valeurs manquantes. Une projection 2023→2024 a été appliquée avec un coefficient national de +3,2 % basé sur les tendances salariales INSEE.

Le dataset final fournit un indicateur économique homogène, exploitable dans le pipeline ETL et les traitements de Machine Learning.

```
# 4. ALIGNEMENT RÉFÉRENTIEL ET FUSIONS
# =====
print("Alignement sur la zone d'étude et gestion des fusions...")

df_mapped = pd.merge(df_ref, df_rev, left_on="code_insee_2024", right_on="GEO", how="inner")

if df_mapped.empty:
    df_mapped = pd.merge(df_ref, df_rev, left_on="code_insee_2022", right_on="GEO", how="inner")

df_agg = df_mapped.groupby(["code_insee_2024", "nom_commune_2024"])[["OBS_VALUE"].mean().reset_index()

comptage_fusions = df_mapped.drop_duplicates(subset=["code_insee_2022"]).groupby("code_insee_2024").size()
nb_communes_fusionnees = len(comptage_fusions[comptage_fusions > 1])

# 5. PROJECTION 2024 ET IMPUTATION
# =====
print("Application du taux d'évolution de +(TAUX_EVOLUTION_2024 - 1)*100 :if %...")

df_agg["revenu_estime_2024"] = (df_agg["OBS_VALUE"] * TAUX_EVOLUTION_2024).round(2)

mediane_nationale_2024 = df_agg["revenu_estime_2024"].median()
df_agg["revenu_estime_2024"] = df_agg["revenu_estime_2024"].fillna(mediane_nationale_2024)

lignes_fin = len(df_agg)
```

```
PS C:\Users\hz-ca\Desktop\mspr_data_final\veisi_11_mspr_data> python .\cleaning_s
Estimation des Revenus
Chargement du référentiel et des données brutes INSEE...
Isolation de l'indicateur MED 51...
Alignement sur la zone d'étude et gestion des fusions...
Application du taux d'évolution de +3.2%...

=====
RAPPORT : REVENUS 2024
=====
Lignes brutes totales (fichier INSEE) : 1,123,173
Communes finales consolidées : 34,761
Fusions gérées (Moyenne des revenus) : 19
Données masquées INSEE (NaN) gérées : 3976
Revenu Médian National Est. 2024 : 26,604.96 €

=====
Aperçu (Top 3) :
=====
code_insee_2024 nom_commune_2024 revenu_estime_2024 annee
0 01001 L'ABERGEMENT-CLÉMENTIAT 29174.64 2024
1 01002 L'ABERGEMENT-DE-VAREY 29040.48 2024
2 01004 AMBÉRIEU-EN-BUGEV 25996.92 2024
PS C:\Users\hz-ca\Desktop\mspr_data_final\veisi_11_mspr_data>
```

Feature engineering - Calcul du nombre de créations d'associations 2024

Pour constituer le jeu de données 2024, nous avons construit un indicateur de dynamisme associatif communal via plusieurs traitements. Les données de data.gouv.fr ont été nettoyées et harmonisées via la normalisation des codes INSEE sur 5 caractères, la conversion des valeurs numériques et la gestion des valeurs manquantes. Elles ont ensuite été appariées au référentiel géographique 2024 pour intégrer les évolutions territoriales et fusions communales. Deux indicateurs principaux ont été utilisés : le nombre total d'associations actives (TOTASSO2024) et les créations de 2024 (ASSO2024).

Nous avons calculé le taux de création associative et la densité associative par population communale. Le dataset final donne une mesure homogène du dynamisme associatif, exploitable dans le pipeline ETL et les traitements de Machine Learning.

Résultat final pour la création d'Associations

```
# 3. ALIGNEMENT SUR LE RÉFÉRENTIEL GÉOGRAPHIQUE
# =====
print("Alignement géographique et gestion des fusions...")

df_mapped = pd.merge(df_ref, df_rev["INSEE", "TOTASSO2024", "ASSO2024"], left_on="code_insee_2024", right_on="INSEE", how="left")

# Gestion des fusions
df_mapped["nom"] = df_mapped["TOTASSO2024"].fillna("")
df_mapped["nom"] = df_mapped["nom"].str.strip()

if df_mapped.empty:
    df_mapped = pd.merge(df_ref, df_rev["INSEE", "TOTASSO2024", "ASSO2024"], left_on="code_insee_2022", right_on="INSEE", how="inner")
    df_mapped["nom"] = df_mapped["nom"].str.strip()

df_agg = df_mapped.groupby(["code_insee_2024", "nom_commune_2024"])[["TOTASSO2024", "ASSO2024"].sum().reset_index()

df_agg["TOTASSO2024"] = df_agg["TOTASSO2024"].fillna(0).astype(int)
df_agg["ASSO2024"] = df_agg["ASSO2024"].fillna(0).astype(int)

# 4. FEATURE ENGINEERING (CRÉATION)
# =====
print("Calcul des indicateurs de dynamisme (Taux & Densité)...")

# 1. Le Taux de création %
df_final["taux_creation_pct"] = np.where(
    df_final["TOTASSO2024"] > 0,
    (df_final["ASSO2024"] / df_final["TOTASSO2024"]) * 100,
    0
).round(2)

# 2. La Densité associative (Associations pour 1000 habitants)
df_final["densite_asso_1000_hab"] = np.where(
    df_final["population"] > 0,
    (df_final["TOTASSO2024"] / df_final["population"]) * 1000,
    0
).round(1)
```

```
Alignement géographique et gestion des fusions...
Calcul des indicateurs de dynamisme (Taux & Densité)...

=====
RAPPORT : TISSU ASSOCIATIF 2024
=====
Communes traitées : 34,956
Total Associations en France : 1,509,809
Nouvelles Créations (2024) : 35,299
Taux de création moyen : 2.30 %
Densité moyenne (/1000 hab) : 31.4
Valeurs manquantes (NaN) : 0

=====
Aperçu :
=====
code_insee_2024 nom_commune_2024 nb_associations_total nb_creations_2024 taux_creation_pct densite_asso_1000_hab annee
0 01001 L'ABERGEMENT-CLÉMENTIAT 16 0 0.00 19.9 2024
1 01002 L'ABERGEMENT-DE-VAREY 15 0 0.00 57.3 2024
2 01004 AMBÉRIEU-EN-BUGEV 318 9 2.83 22.3 2024
PS C:\Users\hz-ca\Desktop\mspr_data_final\veisi_11_mspr_data>
```

Feature engineering - Calcul du chômage 2024

Pour constituer le jeu de données 2024, nous avons nettoyé et harmonisé les données (normalisation des codes INSEE, conversion numérique, gestion des valeurs manquantes), puis nous les avons alignées sur le référentiel géographique 2024 afin de prendre en compte les évolutions territoriales et les fusions de communes. Le calcul du taux de chômage repose sur deux indicateurs principaux : le nombre estimé de chômeurs et la population active (15-64 ans). Cette dernière a été projetée à partir des données démographiques 2022 via des coefficients d'évolution INSEE.

Le taux de chômage communal a ensuite été calculé selon la formule suivante : Taux de chômage (%) = (Nombre de chômeurs / Population 15–64 ans) × 100. Le dataset final fournit un indicateur homogène et cohérent, adapté au pipeline ETL et aux traitements de Machine Learning.

Résultat final pour le taux de chômage

```
# 4. CALCUL DU VRAI TAUX DE CHÔMAGE 2024
# =====
print("Croisement final : Chômeurs / Population 15-64 ans...")

df_final = pd.merge(df_ref["code_insee_2024", "nom_commune_2024"], df_pop["code_insee_2024", "population"], on="code_insee_2024", how="left")
df_final = pd.merge(df_final, df_agg, on="code_insee_2024", how="left")
df_final = pd.merge(df_final, df_chom_final, on="code_insee_2024", how="left")

# Imputation chômeurs (median)
mediane_chom = df_final["nb_chomeurs_2024"].median()
df_final["nb_chomeurs_2024"] = df_final["nb_chomeurs_2024"].fillna(mediane_chom).round(0).astype(int)

# Imputation population 15-64 (si commune non trouvée, on estime à 60% de la pop totale)
masque_pop_nan = df_final["pop_15_64_2022"].isna() | (df_final["pop_15_64_2022"] == 0)
df_final.loc[masque_pop_nan, "pop_15_64_2022"] = df_final.loc[masque_pop_nan, "population"] * 0.60

# Sécurisation mathématique
df_final["pop_15_64_2022"] = df_final["pop_15_64_2022"].round(0).astype(int)

# LE CALCUL FINAL
df_final["taux_chomage_15_64"] = np.where(
    df_final["pop_15_64_2022"] > 0,
    (df_final["nb_chomeurs_2024"] / df_final["pop_15_64_2022"]) * 100,
    np.nan
)

# Nettoyage des valeurs aberrantes (petits villages)
df_final.loc[df_final["taux_chomage_15_64"] > 60, "taux_chomage_15_64"] = np.nan
mediane_taux = df_final["taux_chomage_15_64"].median()
df_final["taux_chomage_15_64"] = df_final["taux_chomage_15_64"].fillna(mediane_taux).round(2)
```

```
PS C:\Users\haz-ca\Desktop\WSPR_data_version_v2\elisi_11_mspr_data> python ".\5. cleaning_scripts_2024\05_chomage24.py"
Pipeline 2024 : Le VRAI Taux de Chômage (Basé sur les 15-64 ans)
Chargement du référentiel et de la population 2024...
Isolément de la population en âge de travailler (15-64 ans)...
Extraction des Demandeurs d'Emploi réels (Fichier DARES 2024)...
Croisement final : Chômeurs / Population 15-64 ans...

=====
RAPPORT : VRAI TAUX DE CHÔMAGE 2024 (CATÉGORIE A ESTIMÉE)
=====
Communes traitées      : 34,932
Total Chômeurs (Est.)  : 3,085,898
-----
POP. ÂGE TRAVAILLER (15-64): 41,718,978
TAUX MOYEN DES COMMUNES : 5.82 %
TAUX DE CHÔMAGE NATIONAL : 7.21 %
=====
```

Feature engineering - Calcul du nombre de créations d'entreprises 2024

La méthodologie pour le calcul des créations d'entreprises suit une logique analogue à celle du calcul du nombre de création d'associations 2024 de nettoyage, harmonisation géographique, agrégation communale et calcul d'indicateurs harmonisés.

Résultat final pour la création d'Entreprises

```
# 3. ALIGNEMENT SUR LE RÉFÉRENTIEL (FUSIONS)
# =====
print("Alignement géographique et gestion des fusions...")

df_mapped = pd.merge(df_ref, df_entreprises, left_on="code_insee_2024", right_on="GEO", how="left")

masque_nan = df_mapped["OBS_VALUE"].isna()
df_fallback = pd.merge(df_ref, df_entreprises, left_on="code_insee_2022", right_on="GEO", how="inner")
df_mapped.update(df_fallback[["code_insee_2024", "OBS_VALUE"]])

# Agrégation (On additionne les créations en cas de fusion de communes)
df_agg = df_mapped.groupby(["code_insee_2024", "nom_commune_2024"])["OBS_VALUE"].sum().reset_index()
df_agg["OBS_VALUE"] = df_agg["OBS_VALUE"].fillna(0).astype(int)

# 4. FEATURE ENGINEERING (DENSITÉ ENTREPRENEURIALE)
# =====
print("Calcul du dynamisme entrepreneurial (Taux pour 1000 hab)...")

df_final = pd.merge(df_agg, df_pop[["code_insee_2024", "population"]], on="code_insee_2024", how="inner")

df_final["taux_creation_entreprises_1000_hab"] = np.where(
    df_final["population"] > 0,
    (df_final["OBS_VALUE"] / df_final["population"]) * 1000,
    0
).round(2)
```

```
PS C:\Users\haz-ca\Desktop\WSPR_data_version_v2\elisi_11_mspr_data> python ".\5. cleaning_scripts_2024\05_creations_entreprises_2024.py"
Créations d'Entreprises
Chargement du référentiel, de la population et du tissu économique...
Filtrage des créations totales par commune en 2024...
Alignement géographique et gestion des fusions...
Calcul du dynamisme entrepreneurial (Taux pour 1000 hab)...

=====
RAPPORT : CRÉATIONS D'ENTREPRISES 2024
=====
Communes traitées      : 34,947
Total Créations (2024) : 2,751,114
-----
Taux moyen (/1000 hab) : 25.65
Valeurs manquantes (NaN) : 0
=====

 Aperçu :
code_insee_2024  nom_commune_2024  nb_creations_entreprises_2024  taux_creation_entreprises_1000_hab  annee
0             01001  L'ABERGEMENT-CLÉMENTIAT                22              27.39  2024
1             01002  L'ABERGEMENT-DE-VAREY                19              30.17  2024
2             01004  AMBRIEU-DU-BOIS                538              37.65  2024

PS C:\Users\haz-ca\Desktop\WSPR_data_version_v2\elisi_11_mspr_data>
```

D) Validation et cohérence des données

Nous avons effectué une phase de validation des données à la fin du processus de traitement afin de vérifier la cohérence globale des datasets avant leur utilisation dans les modèles de Machine Learning.

Les contrôles effectués durant cette validation portent sur :

- La structure des données
- L'intégrité des identifiants et la cohérence des communes
- La vérification des types de données
- L'absence de doublons et d'anomalies significatives
- La compatibilité entre les datasets d'entraînement et de prédiction

Analyse des valeurs manquantes après fusion des datasets avec la variable cible Y

Après les différentes jointures entre les variables explicatives (X) et la variable cible (Y), plusieurs valeurs manquantes (NaN) ont été identifiées dans certaines variables du dataframe final.



```

PS C:\Users\amamazouz\OneDrive - EDIPOLES\Bureau\MSPR DA
Classes politiques :
['centre' 'droite' 'extreme_droite' 'gauche']

NaN après remplissage :
taux_chomage          94
population            0
superficie_km2       0
densite              1
pct_jeunes           30
pct_seniors          30
age_median           30
taux_immigration     92
nb_associations      24
nb_creations_entreprises 92
taux_cambriolages_logement 0
taux_degradations   0
taux_trafic_stupefiants 0
taux_usage_stupefiants 0
taux_violences_intrafamiliales 0
taux_violences_sexuelles 0
taux_vols_avec_armes 0
taux_vols_vehicule   0
taux_vols_violents_sans_arme 0
pourcentage_agri     240
pourcentage_cadres   240
pourcentage_employes 240
pourcentage_ouvriers 240
revenu_median_final  0
dtype: int64

Train : (24364, 24)

```

L'objectif de cette analyse était de déterminer :

- L'origine réelle des valeurs manquantes
- Si elles provenaient d'erreurs de traitement
- Leur impact réel sur le Machine Learning
- Ainsi que la pertinence d'une éventuelle stratégie d'imputation via clustering (K-Means)

Cas du dataset chômage

Le dataset final présente 94 valeurs manquantes sur la variable `taux_chomage`. Après analyse, ces valeurs ne proviennent pas d'une erreur de calcul ou d'un problème de transformation mais de deux situations distinctes :

- 4 communes dont les données brutes sont totalement absentes
- 8 communes dont la population active est égale à 0

Comme vu précédemment, le calcul du taux de chômage étant conditionné à l'existence d'actifs dans la commune, ces cas sont volontairement conservés en NaN.

Une analyse complémentaire a ensuite été réalisée afin de vérifier combien de communes concernées étaient réellement présentes dans le dataset final utilisé pour le Machine Learning.


```

--- CHECK Y / chomage ---
Dans Y mais absent du X : 92
Dans X mais absent du Y : 30
Exemples absents du X : ['16147', '2
230', '23023', '02311']
NaN internes présents dans Y : 2
Après chomage : (34807, 9)
NaN après chomage :
taux_chomage    94

```

Les résultats montrent que :

- 92 communes absentes du dataset chômage n'existent pas dans les variables explicatives finales
- Ces communes représentent seulement environ 0,26 % des données (92 / 34 807)
- **Seules 2 communes possèdent des valeurs manquantes potentiellement imputables**

Dans ce contexte, l'utilisation d'une imputation avancée par K-Means n'a pas été jugée pertinente.

Cas du dataset catégories socioprofessionnelles

```

Nettoyage catégorie sociale
NaN total_actifs : 4
total_actifs = 0 : 154
   code_insee  agri_total  cadres_total  employes_total  ouvriers_total
4958    15031         NaN          NaN          NaN          NaN
4962    15035         NaN          NaN          NaN          NaN
4972    15047         NaN          NaN          NaN          NaN
5087    15171         NaN          NaN          NaN          NaN
pourcentage_agri      158
pourcentage_cadres    158
pourcentage_employes  158
pourcentage_ouvriers  158
dtype: int64

```

L'analyse du dataset montre que les **158 valeurs manquantes internes** proviennent uniquement de deux cas :

- **4 communes** avec des données INSEE totalement absentes
- **154 communes** dont le nombre total d'actifs est égal à 0

Le calcul des pourcentages socioprofessionnels étant basé sur total_actifs, il est logique que ces communes restent en NaN lorsque total_actifs est nul ou absent.

Lors de la fusion avec le dataframe final, **240 valeurs manquantes** ont été observées sur les variables socioprofessionnelles.

Ces 240 lignes se décomposent ainsi :

- 92 communes présentes dans Y mais absentes du dataset X catégories sociales
- 148 communes présentes à la fois dans X et Y mais avec des NaN internes

```
--- CHECK Y / categorie_sociale ---  
Dans Y mais absent du X : 92  
Dans X mais absent du Y : 30  
Exemples absents du X : ['70264', '2802  
330', '09255', '79180']  
NaN internes présents dans Y : 148
```

Les **92 communes absentes de X** ne peuvent pas être reconstruites proprement, car aucune donnée source n'est disponible pour elles. Même une méthode comme K-Means ne permettrait pas de recréer une information fiable dans ce cas.

En revanche, les **148 communes avec NaN internes** pourraient théoriquement faire l'objet d'une imputation intelligente, car elles sont bien présentes dans le périmètre du modèle.

Une imputation par clustering, par exemple avec K-Means, aurait pu être envisagée afin de regrouper les communes selon des profils similaires et remplacer les valeurs manquantes par celles de communes comparables.

Cependant, cette méthode n'est pertinente que si la commune est :

- Présente dans Y
- Présente dans X
- Mais possède uniquement quelques valeurs internes manquantes

À ce stade, l'imputation par K-Means reste donc une piste possible uniquement pour les **148 communes réellement exploitables**, mais pas pour les 92 communes absentes du dataset source.

Choix final concernant l'imputation

Après analyse, aucune stratégie d'imputation n'a été appliquée sur les valeurs manquantes identifiées dans les différents datasets.

Ce choix a été fait volontairement pour plusieurs raisons :

- Une partie importante des NaN correspond à des communes totalement absentes des datasets sources
- Certaines communes possèdent un nombre d'actifs égal à 0, rendant les calculs statistiquement impossibles
- Le volume de lignes réellement imposables reste relativement faible à l'échelle du dataset global
- Une imputation artificielle par clustering (K-Means) risquait d'introduire du bruit ou des biais dans les données utilisées pour le Machine Learning.

Les valeurs manquantes ont donc été conservées telles quelles durant la phase d'analyse, puis les lignes contenant encore des NaN ont été supprimées du dataset final avant l'entraînement du modèle.

Cette approche permet de garantir un jeu de données cohérent, entièrement exploitable par les algorithmes de classification et basé uniquement sur des données statistiquement fiables.

```
Pourcentage de NaN par colonne :
taux_chomage          0.0
population            0.0
superficie_km2       0.0
densite              0.0
pct_jeunes           0.0
pct_seniors          0.0
age_median           0.0
taux_immigration     0.0
nb_associations      0.0
nb_creations_entreprises 0.0
taux_cambriolages_logement 0.0
taux_degradations    0.0
taux_trafic_stupefiants 0.0
taux_usage_stupefiants 0.0
taux_violences_intrafamiliales 0.0
taux_violences_sexuelles 0.0
taux_vols_avec_armes 0.0
taux_vols_vehicule   0.0
taux_vols_violents_sans_arme 0.0
pourcentage_agri     0.0
pourcentage_cadres   0.0
pourcentage_employes 0.0
pourcentage_ouvriers 0.0
revenu_median_final  0.0
classe_revenu_moyen  0.0
classe_revenu_pauvre 0.0
classe_revenu_riche  0.0
dtype: float64
```


Importance des variables dans les modèles de Machine Learning

Nous avons complété l'étude exploratoire des données (EDA) par l'étude de l'importance des variables dans les différents modèles de Machine Learning entraînés dans le cadre du projet.

Cette analyse nous a permis de déterminer les variables exerçant la plus grande influence sur les prédictions électorales produites par ces modèles.

Random forest

Importance des variables :

	variable	importance
1	population	0.119665
3	densite	0.062742
7	taux_immigration	0.062205
9	nb_creations_entreprises	0.062016
0	taux_chomage	0.060911
23	revenu_median_final	0.053041
22	pourcentage_ouvriers	0.051485
10	taux_cambriolages_logement	0.050273
20	pourcentage_cadres	0.049770
4	pct_jeunes	0.048246
5	pct_seniors	0.045261
11	taux_degradations	0.044955
2	superficie_km2	0.042547
21	pourcentage_employes	0.040426
19	pourcentage_agri	0.039761
17	taux_vols_vehicule	0.031970
14	taux_violences_intrafamiliales	0.031405
15	taux_violences_sexuelles	0.020008
6	age_median	0.019367
13	taux_usage_stupefiants	0.017936
8	nb_associations	0.013572
12	taux_trafic_stupefiants	0.010496
18	taux_vols_violents_sans_arme	0.007422
26	classe_revenu_riche	0.004166
24	classe_revenu_moyen	0.004139
25	classe_revenu_pauvre	0.003586
16	taux_vols_avec_armes	0.002628

XGBoost

Importance des variables :

	variable	importance
17	taux_vols_vehicule	0.086672
22	pourcentage_ouvriers	0.081379
11	taux_degradations	0.057105
10	taux_cambriolages_logement	0.052040
20	pourcentage_cadres	0.048377
23	revenu_median_final	0.047803
7	taux_immigration	0.047476
0	taux_chomage	0.046306
8	nb_associations	0.045293
14	taux_violences_intrafamiliales	0.039704
18	taux_vols_violents_sans_arme	0.039665
1	population	0.038146
3	densite	0.034366
5	pct_seniors	0.033660
15	taux_violences_sexuelles	0.030565
6	age_median	0.030117
4	pct_jeunes	0.028167
9	nb_creations_entreprises	0.027746
13	taux_usage_stupefiants	0.027708
2	superficie_km2	0.027474
24	classe_revenu_moyen	0.026681
19	pourcentage_agri	0.026603
21	pourcentage_employes	0.025081
12	taux_trafic_stupefiants	0.021173
16	taux_vols_avec_armes	0.017027
25	classe_revenu_pauvre	0.013669
26	classe_revenu_riche	0.000000

Logistic regression

Importance approximative des variables :

	variable	importance
3	densite	6.298330
17	taux_vols_vehicule	2.216956
26	classe_revenu_riche	1.255525
18	taux_vols_violents_sans_arme	1.230044
10	taux_cambriolages_logement	0.749886
1	population	0.746725
23	revenu_median_final	0.684570
25	classe_revenu_pauvre	0.631210
24	classe_revenu_moyen	0.542845
16	taux_vols_avec_armes	0.420332
8	nb_associations	0.409587
0	taux_chomage	0.307923
4	pct_jeunes	0.287613
11	taux_degradations	0.278486
7	taux_immigration	0.243110
20	pourcentage_cadres	0.235649
9	nb_creations_entreprises	0.221854
19	pourcentage_agri	0.216242
2	superficie_km2	0.186749
14	taux_violences_intrafamiliales	0.170144
22	pourcentage_ouvriers	0.159080
15	taux_violences_sexuelles	0.140486
5	pct_seniors	0.133468
12	taux_trafic_stupefiants	0.104273
6	age_median	0.042544
21	pourcentage_employes	0.035805
13	taux_usage_stupefiants	0.019692

Neural network :

Contrairement aux modèles comme la régression logistique, les Random Forest ou Extra Trees, le Neural Network (réseau de neurones) ne permettent pas d'obtenir directement une mesure claire et interprétable de l'importance des variables.

Le fonctionnement du modèle repose sur plusieurs couches de calculs et des connexions internes complexes. De ce fait, les variables influencent les résultats de façon indirecte, ce qui rend leur interprétation difficile.

Dans le cadre de ce projet, nous ne pouvons donc pas présenter l'importance des variables pour le modèle Neural Network car cette fonctionnalité n'est pas directement disponible avec l'implémentation utilisée.

Par ailleurs, les résultats obtenus par ce modèle demeurent inférieurs aux autres modèles testés, avec une accuracy¹⁸ d'environ 65 %. Cette précision plus faible compromet davantage la pertinence d'une analyse approfondie de l'influence des variables, dans la mesure où les prédictions sont moins fiables et moins stables.

Des méthodes avancées telles que SHAP, LIME ou Permutation Feature Importance permettent toutefois d'analyser l'influence des variables au sein des réseaux de neurones. Néanmoins, leur mise en œuvre dépassait le cadre technique et temporel du POC.

Les résultats obtenus pour les quatre modèles de Machine Learning soulignent l'impact de certains indicateurs :

- Socio-économiques
- Démographiques
- Territoriaux
- Criminels

¹⁸ Précision – Cf Glossaire

Les scores d'importance calculés pour chaque modèle nous ont permis de comparer le comportement des différents algorithmes de Machine Learning utilisés dans le projet.

Debogage

Deux scripts distincts ont été développés pour la génération du dataset d'entraînement.

Le premier correspond à une version de travail dédiée aux phases de débogage et de validation des données. Ce script, dérivé de la version initiale, a permis de réaliser différents contrôles sur le dataset d'entraînement, notamment l'identification des incohérences, des valeurs manquantes, nulles ou NaN. Ces vérifications étaient effectuées soit indépendamment, soit en complément des scripts de Machine Learning, afin de faciliter la détection et la correction des anomalies présentes dans les données.

Une fois la phase de validation terminée avec succès, une seconde version du script a été retenue pour l'intégration dans le pipeline final. Cette version, plus claire, lisible et entièrement commentée, ne conserve que les étapes nécessaires à la génération du dataset d'entraînement. Elle est utilisée dans le processus ETL ainsi que dans le script de déploiement automatisé du pipeline de traitement des données et de Machine Learning.



VIII. Modélisation Machine Learning

A) Types de modèle

Afin de choisir les modèles d'apprentissage les plus pertinents pour notre problématique de classification électorale, nous avons étudiés les aspects méthodologiques suivants :

- La complexité d'implémentation : évalue la difficulté de mise en œuvre, de paramétrage et d'entraînement du modèle.
- La performance tabulaire : mesure la capacité du modèle à traiter efficacement des données structurées sous forme de tableaux.
- L'explicabilité : représente la capacité du modèle à expliquer et justifier ses prédictions.
- Les données non linéaires : correspond à l'aptitude du modèle à capturer des relations complexes entre les variables.
- La robustesse bruit/valeurs aberrantes (outliers) : mesure la résistance du modèle face aux données bruitées, atypiques ou incomplètes.
- La généralisation : représente la capacité du modèle à conserver de bonnes performances sur de nouvelles données non vues pendant l'entraînement.

Tableau comparatif des modèles de Machine Learning

Modèle de ML	Complexité implémentation	Performance tabulaire	Explicabilité	Données non linéaires	Robustesse bruit/outliers	Généralisation	Caractéristiques
Random Forest	Faible	Très bonne	Modérée	Très bonne	Élevée	Élevée	Très adapté aux données tabulaires et aux relations non linéaires. Limite naturellement le surapprentissage.
Extra Trees	Faible	Très bonne	Modérée	Très bonne	Très élevée	Très élevée	Variante plus aléatoire du Random Forest offrant une excellente généralisation et une forte robustesse au bruit.
XGBoost	Élevée	Excellente	Modérée	Excellente	Élevée	Bonne	Modèle de boosting très performant pour capturer des relations complexes entre variables.
Logistic Regression	Très simple	Moyenne	Élevée	Faible	Moyenne	Bonne	Modèle linéaire simple et interprétable utilisé comme baseline de comparaison.
SVM	Moyenne	Bonne	Faible	Bonne	Moyenne	Bonne	Utilise des frontières de décision avancées pour séparer efficacement des classes complexes.
Neural network	Élevée	Très forte	Très faible	Excellente	Moyenne	Variable	Modélise des relations très complexes mais nécessite davantage de données et de calculs.
KNN	Simple	Moyenne	Moyenne	Bonne	Faible	Moyenne	Modèle basé sur la proximité entre observations. Simple à comprendre mais sensible au bruit, aux valeurs aberrantes et aux datasets contenant beaucoup de variables.



À la suite de cette analyse comparative, nous avons sélectionné les modèles **Random Forest** et **XGBoost** pour leur forte pertinence sur des données tabulaires socio-économiques et leur capacité à modéliser des relations non linéaires complexes.

La **régression logistique** a été retenue comme modèle de référence (baseline) interprétable, permettant de mesurer les écarts de performances des approches plus avancées.

Enfin, nous avons inclus un **neural network**¹⁹ (réseau de neurones) dans l'étude afin d'évaluer les performances d'une approche Deep Learning²⁰ appliquée à notre problématique de classification électorale

B) Paramètres d'entraînement

Train / Test split

Afin d'évaluer correctement les performances des modèles de Machine Learning, nous avons choisi de séparer le jeu de données d'entraînement en deux ensembles distincts :

- 70% des données pour l'entraînement (train)
- 30% des données pour les tests et l'évaluation du modèle (test split)

```
Train : (24196, 27)
Test : (10370, 27)
```

Cette partition permet d'entraîner le modèle sur un sous-ensemble des données, puis d'évaluer sa capacité à généraliser sur des observations inédites.

Ce découpage permet notamment :

- D'éviter le surapprentissage²¹ (overfitting)
- D'estimer les performances réelles des modèles
- De quantifier la capacité de généralisation
- De comparer différents modèles de Machine Learning dans un cadre homogène

La répartition des données est effectuée à l'aide de la fonction ``train_test_split`` de Scikit-learn, avec un paramètre ``random_state`` fixe, afin de garantir la reproductibilité des résultats.

Paramètres

Plusieurs paramètres ont été définis afin d'assurer la stabilité et la cohérence des entraînements :

- ``test_size=0.3`` afin de consacrer 30 % des données à la phase de test
- ``random_state=42`` afin d'obtenir des résultats reproductibles
- Optimisation des hyperparamètres en fonction des modèles utilisés (Random Forest, XGBoost, Logistic Regression, Neural Network)

¹⁹ Réseau de neurones – Cf Glossaire

²⁰ Apprentissage approfondi – Cf Glossaire

²¹ Surapprentissage – Cf Glossaire

Ces réglages permettent d'assurer une comparaison cohérente des performances entre les différents modèles de Machine Learning testés.

Features

Les variables explicatives (features) correspondent aux critères socio-économiques, démographiques, territoriaux et criminologiques utilisés par les modèles afin de prédire la classe politique dominante d'une commune.

Parmi les principales variables retenues figurent :

- Les revenus médians
- Le taux de chômage
- Les catégories socioprofessionnelles
- La densité de population
- La structure démographique
- L'immigration
- La criminalité
- Les créations d'associations
- Les créations d'entreprises

Le nombre de variables a été réduit et ajusté de manière progressive entre les différentes versions du projet (V1 → V2) afin :

- De limiter le bruit dans les données
- D'améliorer la qualité de l'apprentissage
- De réduire les corrélations superflues
- D'optimiser les performances globales des modèles

Target

La variable cible²² (target) employée pour l'apprentissage supervisé correspond à la colonne `classe\_politique`. Cette variable désigne le bloc politique prédominant, obtenu à partir des résultats électoraux du premier tour de l'élection présidentielle française de 2022.

Les catégories politiques retenues sont les suivantes :

- Extrême droite
- Droite
- Centre
- Gauche
- Extrême gauche

Cette approche permet de transformer la problématique électorale en problème de classification supervisée multiclassées.

IX. Évaluation des modèles

A) Vérifications et tests des modèles

Pour évaluer les performances des différents modèles de ML, nous avons analysé plusieurs métriques de classification :

- Accuracy
- Precision
- Recall
- F1-score₂₃ pondéré

Les modèles ont été entraînés et testés sur le même ensemble de données afin de comparer leur aptitude à prédire correctement le bloc politique prédominant d'une commune.

Random forest

```
=====
Modèle entraîné : Random Forest
=====

Accuracy : 70.82 %
F1-score pondéré : 67.59 %

Rapport de classification :
      precision    recall  f1-score   support

   centre         0.67       0.45       0.54       2870
    droite         0.00       0.00       0.00         7
extreme_droite     0.72       0.92       0.81      6287
    gauche         0.67       0.20       0.31      1206

   accuracy                    0.71      10370
  macro avg         0.51       0.39       0.42      10370
 weighted avg         0.70       0.71       0.68      10370
```

Le modèle Random Forest affiche une précision globale (accuracy) de 70,82 % et un F1-score pondéré de 67,59 %.

Les performances globales sont satisfaisantes, en particulier pour la catégorie « extrême droite », qui constitue la classe majoritaire de l'échantillon. En revanche, les résultats demeurent moins élevés pour certaines catégories sous-représentées, à savoir la classe « droite » et la classe « gauche ». Cette limitation provient essentiellement du déséquilibre présent dans les données d'apprentissage, issues des résultats des élections de 2022.

XGBoost

```
=====
Modèle entraîné : XGBoost
=====

Accuracy : 72.75 %
F1-score pondéré : 70.67 %

Rapport de classification :
      precision    recall  f1-score   support

   centre         0.66       0.53       0.59       2870
    droite         0.00       0.00       0.00         7
extreme_droite     0.75       0.90       0.82      6287
    gauche         0.65       0.28       0.39      1206

   accuracy                    0.73      10370
  macro avg         0.52       0.43       0.45      10370
 weighted avg         0.71       0.73       0.71      10370
```

Parmi l'ensemble des modèles évalués, XGBoost affiche les performances les plus élevées, avec une précision de 72,75 % et un F1-score pondéré de 70,67 %.

Ce modèle se distingue par une capacité de généralisation supérieure, des scores globaux optimaux et une stabilité accrue sur l'ensemble des catégories politiques. XGBoost excelle notamment dans la distinction des communes associées au centre, à la gauche et à l'extrême droite.

Toutefois, à l'instar des autres modèles, la prédiction de la classe « droite » demeure problématique en raison du nombre très restreint de communes appartenant à cette catégorie dans les résultats électoraux de 2022.

Logistic regression

```
=====
Modèle entraîné : Logistic Regression
=====

Accuracy : 54.99 %
F1-score pondéré : 58.58 %

Rapport de classification :
```

	precision	recall	f1-score	support
centre	0.48	0.46	0.47	2870
droite	0.00	0.29	0.01	7
extreme_droite	0.78	0.61	0.68	6287
gauche	0.29	0.47	0.36	1206
accuracy			0.55	10370
macro avg	0.39	0.46	0.38	10370
weighted avg	0.64	0.55	0.59	10370

La régression logistique affiche une exactitude (accuracy) de 54,99 % et un F1-score pondéré de 58,58 %. Ces résultats sont nettement inférieurs à ceux obtenus par les modèles fondés sur les arbres de décision. Ce modèle linéaire peine à modéliser les interactions complexes entre les variables socio-économiques, démographiques et électorales employées dans le cadre de ce projet.

Neural network

```
=====
Modèle entraîné : Neural Network
=====

Accuracy : 65.79 %
F1-score pondéré : 63.92 %

Rapport de classification :
```

	precision	recall	f1-score	support
centre	0.54	0.43	0.48	2870
droite	0.00	0.00	0.00	7
extreme_droite	0.72	0.84	0.77	6287
gauche	0.45	0.26	0.33	1206
accuracy			0.66	10370
macro avg	0.43	0.38	0.40	10370
weighted avg	0.64	0.66	0.64	10370

Importance des variables non disponible pour ce modèle.

Le modèle de réseau de neurones affiche une précision (accuracy) de 65,79 % et un F1-score pondéré de 63,92 %. Ces résultats demeurent inférieurs à ceux obtenus avec XGBoost et Random Forest.

Bien que le réseau de neurones parvienne à dégager certaines tendances générales, les performances indiquent une capacité de généralisation réduite sur l'ensemble du jeu de données.


Par ailleurs, contrairement aux modèles fondés sur des arbres de décision ou à la régression logistique, le réseau de neurones ne fournit pas directement une importance interprétable des variables.

Son architecture, qui repose sur plusieurs couches de calculs internes complexes, rend l'interprétation de l'influence des variables particulièrement ardue. L'accuracy (précision) limitée de ce modèle réduit également la pertinence d'une analyse détaillée de l'influence des variables dans le cadre de cette preuve de concept (POC).

B) Choix du meilleur modèle

Nous avons retenu le modèle XGBoost pour les phases de prédiction du projet.


Comparaison des performances des modèles



Cette décision repose sur plusieurs critères :

- La précision globale la plus élevée (72,75 %)
- Le F1-score pondéré optimal
- La robustesse générale supérieure
- La capacité de généralisation renforcée
- La meilleure gestion des interactions complexes entre variables

Matrice de confusion du meilleur modèle



Le modèle constitue ainsi le compromis le plus favorable entre performance, stabilité et pouvoir prédictif. En dépit de ces résultats prometteurs, certaines limitations subsistent pour les classes politiques sous-représentées, en particulier la « droite » et l' « extrême gauche ».

Ces limitations découlent directement de la distribution des résultats électoraux de 2022 utilisée pour l'entraînement.

X. Visualisation

Nous avons intégré les résultats des prédictions dans des visualisations et des analyses décisionnelles via Power BI.


Ces représentations permettent :

- D'examiner la distribution géographique des prévisions politiques
- De mettre en évidence les tendances électorales prédominantes
- D'analyser les relations entre les variables socio-économiques et les résultats anticipés
- De comparer les performances respectives des différents algorithmes de Machine Learning
- D'interpréter les probabilités et les degrés de confiance associés aux prédictions

Les résultats sont restitués à l'aide :

- De cartes interactives
- D'histogrammes
- De graphiques de densité
- De tableaux de bord décisionnels

A) Dashboard



Ce tableau de bord Power BI compile les principaux indicateurs socio-économiques, démographiques, territoriaux et politiques mobilisés dans le cadre du projet Electio-Analytics. Il offre une visualisation des données issues du pipeline ETL ainsi que des tendances politiques anticipées par les modèles d'apprentissage automatique à l'échelon communal.

Indicateurs principaux : Les cartes KPI présentent une synthèse des variables clés du projet : criminalité, population jeune et senior, chômage, revenu médian, densité, population totale et nombre de communes analysées.


Carte interactive des communes : La carte permet de visualiser les communes françaises étudiées dans le projet, tout en permettant des analyses territoriales via des filtres par département et commune.

Jauge — Indice de criminalité : Cette jauge reflète le niveau moyen de criminalité, établi à partir des divers indicateurs criminels pris en compte dans le cadre du projet.

Revenu moyen par taille de commune : Ce graphique compare le revenu médian selon la taille des communes dans le but d'examiner les disparités socio-économiques entre territoires.

Répartition des communes par tendance politique : Le diagramme circulaire montre la répartition des communes en fonction du bloc politique dominant selon les prédictions du modèle.

Revenus, chômage et tendances politiques : Le nuage de points présente les interactions entre le revenu médian, le taux de chômage et l'orientation politique prédite pour chaque commune. Cette représentation graphique facilite l'identification de certaines corrélations entre les indicateurs socio-économiques et les tendances électorales.



Ce tableau de bord Power BI analyse les indicateurs de criminalité au niveau communal et examine leurs corrélations avec les variables socio-économiques et politiques issues du projet Electio-Analytics. Les visualisations mettent en évidence les communes aux taux de criminalité les plus élevés, ainsi que des tendances liées au chômage, à la taille des communes et aux orientations politiques dominantes.


Indicateurs principaux : Les cartes KPI présentent plusieurs indicateurs globaux : le nombre de communes jugées critiques, le total de communes analysées, ainsi que l'indice moyen de criminalité.

Moyenne de criminalité par commune : Ce diagramme à barres affiche les communes présentant les indices de criminalité moyens les plus élevés. Il offre une identification rapide des zones géographiques les plus touchées par les indicateurs criminels analysés.

Criminalité moyenne selon le taux de chômage : Ce diagramme établit une corrélation entre le taux de chômage et l'indice moyen de criminalité. Il met en évidence des liens potentiels entre les difficultés socio-économiques et l'ampleur de la délinquance au sein des communes françaises.

Criminalité par tendance politique et taille de commune : Ce graphique présente une comparaison de l'indice moyen de criminalité en fonction de deux critères : l'affiliation politique dominante des territoires et la taille des communes. L'analyse vise à mettre en évidence les disparités géographiques et politiques révélées par les données disponibles.

Top 10 des communes par intensité de criminalité : Ce graphique détaille les communes affichant les taux de criminalité les plus élevés, selon cinq catégories : cambriolages, dégradations, trafic de stupéfiants, violences sexuelles et vols avec armes. Il met en évidence les types de délinquance prédominants pour chaque localité étudiée.



Ce tableau de bord examine la structure démographique des communes françaises en 2024 à l'aide d'indicateurs clés : population jeune, population senior, densité et âge médian. Les visualisations mettent en lumière les corrélations entre démographie, densité territoriale et orientations politiques dominantes au niveau communal.


Indicateurs principaux : Les cartes KPI présentent plusieurs indicateurs globaux : le pourcentage moyen de jeunes, celui de seniors, la densité moyenne, ainsi que le nombre total de communes analysées.

Distribution de la population par âge médian : Ce graphique présente la distribution des communes en fonction de leur âge médian. Il donne un aperçu de la composition démographique générale de la population française et met en évidence la concentration des communes autour des tranches d'âge médianes.

Corrélation entre densité, revenus et orientations politiques : Ce graphique établit une corrélation entre trois indicateurs : la densité de population, le revenu moyen et les orientations politiques dominantes. Il met en évidence des disparités territoriales et socio-économiques en fonction des préférences politiques constatées.

Répartition jeunes vs seniors par orientation politique : Ce graphique compare la proportion moyenne de jeunes et de seniors au sein des principaux blocs politiques. L’objectif consiste à examiner les disparités démographiques observées entre les différentes orientations politiques considérées.

Pourcentage de jeunes et de seniors par commune : Ce graphique établit une comparaison des parts respectives de jeunes et de seniors au sein de plusieurs grandes municipalités françaises. Il met en lumière les disparités démographiques existant entre les différentes zones urbaines examinées.



Ce tableau de bord examine, pour 2024, plusieurs indicateurs économiques et socio-professionnels des communes françaises : chômage, revenus, catégories socioprofessionnelles et dynamisme économique. Les visualisations mettent en lumière les disparités territoriales et certaines tendances liées aux orientations politiques dominantes.

Indicateurs principaux : Les cartes KPI présentent les indicateurs globaux suivants : nombre total de communes analysées, population totale, taux moyen de création d’entreprises, taux moyen de chômage, et revenu médian moyen.


Taux de chômage par département : Ce diagramme expose les départements affichant les proportions de chômage les plus importantes. Il permet de repérer les zones les plus touchées par les difficultés d’ordre économique et social.

Comparaison des catégories socio-professionnelles : Ce diagramme compare la distribution des grandes catégories socio-professionnelles au sein de plusieurs communes : agriculteurs, cadres, ouvriers, employés.

Il permet de mettre en évidence les disparités socio-économiques existant entre les territoires examinés.

Communes aux revenus les plus élevés : Ce diagramme met en avant les communes dont les revenus médians sont les plus hauts. Il facilite l’identification des territoires les plus avantagés sur le plan économique dans l’ensemble de données étudié.

Communes aux revenus les plus faibles : Ce diagramme présente les communes dotées des revenus médians les plus bas. Il sert à analyser les écarts économiques constatés entre les différentes communes françaises.



Ce tableau de bord analyse la répartition des tendances politiques dominantes au niveau communal en France pour 2024. Les visualisations présentent le nombre de communes affiliées à chaque bloc politique, leur poids démographique, et certaines caractéristiques territoriales telles que la densité de population.

Indicateurs principaux : Les cartes KPI présentent plusieurs indicateurs globaux : le bloc politique majoritaire à l'échelle nationale, la population totale analysée, la densité moyenne et le nombre total de communes étudiées.

Tableau récapitulatif des tendances politiques : Ce tableau indique, pour chaque bloc politique, le nombre de communes, la population totale et la densité moyenne, offrant une vue d'ensemble des caractéristiques territoriales propres à chaque tendance.


Volume de communes par force politique : Ce graphique présente la répartition des communes par bloc politique, mettant en évidence les tendances politiques dominantes dans les prédictions issues des modèles de Machine Learning.

Répartition de la population par tendance politique : Ce diagramme en anneau présente la distribution démographique par blocs politiques dominants, mettant en évidence le poids relatif de chaque orientation politique à l'échelle nationale.

Densité moyenne par parti politique : Ce graphique établit une comparaison de la densité moyenne des communes en fonction de leur orientation politique dominante. Il permet ainsi d'examiner les disparités territoriales entre les communes urbaines, périurbaines et rurales, en lien avec les tendances politiques qui y sont observées.

B) Cartes

Cartographie nationale des tendances politiques prédites




Cette carte présente, à l'échelle nationale, la répartition géographique des tendances politiques dominantes par commune, selon les prédictions du modèle de Machine Learning. Chaque couleur correspond à un bloc politique : centre, gauche, droite ou extrême droite.

Cette visualisation offre une vue d'ensemble des comportements électoraux prédits en France, mettant en évidence des concentrations géographiques spécifiques selon les tendances politiques observées.

L'objectif principal de cette représentation est de :

- Visualiser la distribution territoriale des prédictions
- Identifier les grandes dynamiques politiques à l'échelle nationale
- Faciliter l'analyse spatiale des comportements électoraux communaux

Zoom cartographique des prédictions communales



Cette carte correspond à un zoom de la cartographie précédente, permettant d'examiner avec une plus grande précision la répartition des tendances politiques à l'échelle communale. Ce niveau de détail permet une meilleure distinction des différentes couleurs associées aux blocs politiques, tout en offrant une visualisation plus nette des contrastes territoriaux entre communes voisines, zones urbaines et espaces ruraux.

Cette représentation met en évidence la granularité communale du projet et la capacité du modèle à générer des prédictions localisées à une échelle fine sur l'ensemble du territoire français.



XI. Gouvernance, sécurité et RGPD

Dans le cadre du projet Electio-Analytics, nous avons porté une attention particulière à la gouvernance, à la sécurisation et à la conformité des données utilisées tout au long du pipeline ETL et des traitements de Machine Learning.

Gouvernance des données

Les jeux de données utilisés dans ce projet proviennent de sources publiques officielles, telles que l'INSEE et data.gouv.fr. Afin d'assurer la traçabilité, la reproductibilité et la cohérence des opérations effectuées, nous avons documenté l'ensemble des sources.

Les datasets ont été structurés selon une architecture organisée :

- Séparation des données brutes ("raw") et des données nettoyées
- Distinction entre les jeux d'entraînement (2022) et ceux de prédiction (2024)
- Stockage structuré des données au sein d'une base SQLite
- Centralisation des scripts ETL et de Machine Learning au sein d'un pipeline automatisé

Les différentes transformations appliquées aux données sont réalisées via des scripts Python commentés et versionnés, ce qui nous a permis d'assurer un suivi rigoureux des traitements exécutés.

Qualité et intégrité des données

Afin de garantir la qualité des données exploitées, nous avons déployé plusieurs contrôles :

- Détection et suppression des doublons
- Traitement des valeurs manquantes, nulles et NaN
- Standardisation des formats et des typages de données
- Normalisation des colonnes
- Harmonisation des codes INSEE
- Vérification des jointures entre datasets
- Correction des incohérences relevées lors des phases de debug et d'analyse exploratoire des données (EDA)

Nous avons porté une attention particulière :

- Aux communes présentant un faible nombre d'habitants
- Aux faibles volumes de réponses
- Aux valeurs aberrantes susceptibles d'affecter les traitements statistiques et les modèles de Machine Learning

Ces vérifications nous ont permis d'améliorer la fiabilité des jeux de données utilisés et de réduire les incohérences dans les analyses.

Conformité RGPD et secret statistique

Les données exploitées dans le cadre de ce projet proviennent exclusivement de bases de données publiques en libre accès (Open Data). Ces sources appliquent des mécanismes d'anonymisation et de protection des données, notamment via le secret statistique.

Dans le dataset "Revenus médians", certaines valeurs sont remplacées par la mention "s". Cette notation correspond à des informations volontairement non diffusées afin de prévenir tout risque d'identification directe ou indirecte des personnes concernées.

Ces absences concernent principalement des communes caractérisées par :

- Un faible nombre d'habitants
- Un nombre restreint de déclarations
- Des revenus significativement atypiques

Ce processus de protection vise à empêcher tout recoupement d'informations susceptibles de conduire à l'identification de personnes physiques.

Nous n'utilisons aucune donnée permettant d'identifier directement ou indirectement une personne physique dans notre projet :

- Aucun nom
- Aucun prénom
- Aucune adresse
- Aucun numéro de sécurité sociale
- Aucune plaque d'immatriculation
- Aucune donnée personnelle nominative

Les données utilisées sont agrégées à l'échelle communale et ne permettent pas l'identification d'un individu, même en cas de croisement avec d'autres variables.

Notre projet respecte ainsi les principes généraux du RGPD :

- Minimisation des données
- Limitation des traitements aux seuls objectifs du projet
- Utilisation de données anonymisées ou agrégées
- Absence de profilage individuel

Concernant les droits relatifs aux données à caractère personnel²⁴ (DCP), les individus concernés peuvent exercer leurs droits directement auprès des organismes publics mettant à disposition les jeux de données, notamment afin :

- D'obtenir un droit d'accès
- De demander une rectification
- De demander le retrait
- De demander une limitation du traitement
- De demander la portabilité des données
- De s'opposer au traitement
- De demander un déréférencement
- De demander une suppression des données

Sécurisation des données

Les jeux de données téléchargés sont exclusivement exploités à des fins d'analyse et de pédagogie dans le cadre du projet Electio-Analytics.

Pendant toute la durée du projet, nous avons téléchargé les jeux de données bruts depuis les sources officielles (INSEE, data.gouv.fr, etc.) puis les avons stockés dans un Google Drive privé partagé accessible uniquement aux membres autorisés du groupe via leur adresse mail.

²⁴ Données à caractère personnel – Cf Glossaire

Les datasets après nettoyage et transformation respectent les mêmes principes de sécurisation et de restriction d'accès.

Les personnes susceptibles d'avoir accès à certaines parties des datasets sont :

- Les membres du groupe de travail
- Le coach MSPR
- Les intervenants ou experts consultés dans le cadre du suivi du projet

Ces accès sont strictement limités au cadre pédagogique et professionnel du POC. Aucun dataset n'est publié sur le dépôt GitHub du projet. Un fichier `.gitignore` a été configuré pour empêcher l'envoi accidentel des jeux de données bruts et des fichiers temporaires.

Les informations hébergées sur le dépôt GitHub se limitent strictement à des données préalablement traitées, standardisées et rendues anonymes, de sorte qu'aucune identification directe ou indirecte d'une personne physique n'est possible.

Seuls les scripts Python (nettoyage, transformation, ETL et Machine Learning) sont versionnés sur GitHub, afin d'assurer :

- La traçabilité des modifications
- La continuité du projet
- La reproductibilité du pipeline
- La sauvegarde des traitements effectués

Limites et éthique du Machine Learning

Les résultats générés par les modèles de Machine Learning reposent sur des corrélations statistiques entre diverses variables socio-économiques, démographiques et territoriales.

Les prédictions réalisées :

- Ne permettent pas d'expliquer individuellement les comportements électoraux
- Peuvent être affectées par des biais inhérents aux jeux de données utilisés
- Doivent être interprétées et considérées comme des estimations analytiques dans le cadre d'un Proof of Concept (POC)

Notre projet s'inscrit dans une approche expérimentale et pédagogique, visant à analyser les corrélations entre divers critères territoriaux et les tendances électorales observées.

Nous effacerons les datasets employés de tous les supports de stockage des membres du groupe à l'issue du projet MSPR. Seuls les jurys habilités pourront consulter temporairement les datasets nettoyés dans le cadre de l'évaluation finale du projet.

XII. Limites du projet

Qualité des données

Le projet s'appuie sur l'exploitation de jeux de données en libre accès, principalement issus de l'INSEE et de data.gouv.fr. Bien que ces sources soient globalement fiables, certaines limitations relatives à la qualité des données ont été mises en évidence.

Plusieurs datasets présentent :

- Des données manquantes
- Des informations protégées par le secret statistique
- Des disparités dans les formats
- Ou des incohérences entre différentes années et référentiels géographiques

Nous avons rencontré des difficultés avec certains jeux de données liés aux DOM-TOM, ainsi qu'avec le dataset de criminalité basée sur le référentiel géographique GEO2025, nécessitant des traitements d'harmonisation complexes.

Volume et représentativité des données

Le volume important de données manipulées à l'échelle communale représente une contrainte technique importante en termes de nettoyage, de traitement et de fusion des datasets. Par ailleurs, la distribution des classes politiques dans les résultats du premier tour de l'élection présidentielle de 2022 introduit certaines limites dans l'apprentissage des modèles de Machine Learning.

L'étiquette « extrême gauche » n'a pas pu être correctement apprise par les modèles, aucune commune française n'ayant été remportée par ce bloc lors du premier tour de l'élection présidentielle de 2022.

De façon analogue, la classe « droite » demeure sous-représentée dans l'ensemble d'apprentissage, ce qui réduit la capacité de généralisation et de prédiction des modèles pour cette catégorie politique.

Hypothèses et temporalité des données

Le postulat de ce projet est que les corrélations établies entre les indicateurs socio-économiques, territoriaux et électoraux restent partiellement représentatives des comportements politiques actuels.

Néanmoins, les dynamiques politiques évoluent dans le temps :

- Certains candidats changent de positionnement politique
- Certaines tendances électorales connaissent des évolutions
- Les comportements électoraux peuvent être affectés par des événements récents non intégrés aux jeux de données exploités

Par conséquent, les prédictions réalisées à partir des résultats de 2022 doivent être interprétées avec prudence, en particulier dans le cadre d'un POC.

Biais et limites du Machine Learning

Comme tout projet de Machine Learning, le projet Electio-Analytics est susceptible de présenter plusieurs types de biais liés :

- Aux données d'entraînement
- Au déséquilibre des classes
- Au choix des variables explicatives
- Aux limites des modèles utilisés

Certaines variables peuvent également présenter des corrélations entre elles, ce qui peut affecter les résultats des modèles et l'interprétation des prédictions.

L'étude des corrélations a révélé que certaines variables exercent une influence prépondérante sur les prédictions des modèles de Machine Learning, tandis que d'autres indicateurs apportent une contribution informationnelle limitée, voire introduisent du bruit dans le processus d'apprentissage. Ces observations soulignent l'importance de la sélection des variables explicatives dans le cadre d'un projet de Machine Learning appliqué à l'analyse des comportements électoraux.

Il convient donc de considérer les résultats obtenus comme des estimations statistiques, et non comme des certitudes électorales.



XIII. Recommandations

Améliorations

Plusieurs axes d'amélioration ont été mis en évidence afin d'améliorer la qualité des données et les performances des modèles de Machine Learning.

Une amélioration majeure consisterait à inclure des cycles électoraux supplémentaires, à savoir :

- 2017
- 2012
- Voire des années antérieures

Cette approche permettrait :

- D'accroître le volume des données d'entraînement
- D'améliorer la représentativité des différentes classes politiques
- D'affiner l'apprentissage des comportements électoraux propres à certaines catégories sous-représentées
- D'améliorer la capacité de généralisation des modèles

L'intégration de données historiques offrirait également une meilleure représentation de l'étiquette « extrême gauche », absente des communes gagnantes en 2022, ainsi que de l'étiquette « droite », actuellement sous-représentée dans le jeu de données d'entraînement.

Dans le cadre de nos investigations supplémentaires, nous avons procédé à l'identification des communes où les candidats Philippe Poutou et Nathalie Arthaud ont enregistré leurs meilleurs résultats au premier tour de l'élection présidentielle de 2022.

Ces recherches nous ont permis de confirmer les limites de représentativité associées à l'étiquette « extrême gauche » au sein de notre jeu de données d'entraînement.

Pour Philippe Poutou, la commune de Lichans-Sunhar (Pyrénées-Atlantiques) affiche le score relatif le plus élevé, avec 21,57 % des suffrages exprimés. Cependant, malgré cette performance notable à l'échelon local, cette circonscription est remportée par un autre bloc politique, ce qui explique l'absence de communes classées sous l'étiquette « extrême gauche » dans notre classification finale.

En ce qui concerne Nathalie Arthaud, ses meilleurs résultats sont principalement observés dans certains territoires ultramarins. À Wallis-et-Futuna, elle atteint 1,83 % des suffrages exprimés lors du premier tour de l'élection présidentielle de 2022.

Ces analyses confirment que les candidats associés à l'extrême gauche demeurent très faiblement représentés dans les résultats électoraux communaux de 2022, ce qui entrave significativement la capacité des modèles de Machine Learning à apprendre correctement cette catégorie politique.

Un second axe d'amélioration notable porterait sur l'historisation des données de criminalité. Le jeu de données actuel repose sur un référentiel géographique récent (GEO2025), ce qui complique les correspondances avec les référentiels plus anciens utilisés dans d'autres datasets.

Cela souligne la nécessité d'inclure plusieurs cycles électoraux supplémentaires (2017, 2012, voire antérieurs) afin d'améliorer la représentativité des différentes classes politiques et de renforcer la robustesse globale des modèles.

Un travail d'historisation et de reconstitution des communes permettrait d'améliorer la cohérence temporelle des données et de faciliter l'intégration de données historiques supplémentaires.

Les analyses de corrélation, couplées à l'évaluation de l'importance des attributs, ont démontré que certains indicateurs exercent une influence prépondérante sur les prédictions des modèles de Machine Learning. Les variables d'ordre socio-économique, démographique et territorial se révèlent déterminantes dans le processus d'apprentissage, tandis que d'autres apportent une information utile marginale, voire introduisent un bruit nuisible aux prévisions.

Ces constats mettent en évidence l'importance du choix des variables explicatives et ouvrent la voie à plusieurs axes d'amélioration du projet. L'introduction de nouveaux indicateurs, tels que le niveau d'études, les données foncières, le taux d'inflation, l'évolution économique locale ou encore des données électorales complémentaires, s'avère particulièrement pertinente.

Parmi ces pistes, l'intégration du taux d'inflation sur plusieurs années pourrait améliorer la qualité des prédictions. L'inflation influence en effet significativement les revenus médians, le chômage, le pouvoir d'achat et certaines dynamiques économiques et sociales locales. L'ajout de données d'inflation historiques permettrait ainsi de renforcer les relations inter-variables et de mieux représenter l'évolution du contexte économique dans les comportements électoraux.

Enfin, des optimisations plus poussées des modèles pourraient être envisagées :

- Ajustement des hyperparamètres
- Validation croisée approfondie
- Équilibrage des classes
- Réduction des biais
- Intégration de nouvelles architectures de Machine Learning

Passage en production

Dans le cadre d'un passage en production, plusieurs évolutions techniques et fonctionnelles seraient nécessaires.

Tout d'abord, une refonte du système de gestion de base de données s'impose. SQLite a été choisi pour le POC en raison de sa simplicité, de sa légèreté et de sa rapidité de mise en œuvre. Cependant, dans un contexte professionnel exigeant des accès simultanés multi-utilisateurs, des performances optimisées et une sécurité accrue, il conviendrait d'adopter un SGBD plus adapté, tel que PostgreSQL.

Le pipeline de données gagnerait à être industrialisé avec :

- Une automatisation poussée des traitements ETL
- Une orchestration des pipelines
- Un système de supervision
- Des contrôles qualité automatisés
- Une gestion des erreurs renforcée

Concernant le Machine Learning, l'entraînement des modèles devrait s'appuyer sur plusieurs cycles électoraux, permettant ainsi d'améliorer la robustesse des prédictions et de réduire les biais potentiels liés à une seule élection de référence.

Le passage en production pourrait également inclure :

- Une historisation complète des datasets
- Un versionnement des données et des modèles
- Des mises à jour automatiques des datasets open data

- Une API dédiée aux prédictions
- Une interface web pour la consultation des résultats

Enfin, des mécanismes de sécurité supplémentaires devraient être implémentés :

- Gestion des accès utilisateurs
- Sécurisation des bases de données
- Sauvegardes automatisées
- Journalisation des opérations
- Supervision continue des services



XIV. Conclusion

Dans le cadre de la MSPR Big Data et Analyse de données, nous avons développé le Proof of Concept (POC) Electio-Analytics, visant à prédire le bloc politique majoritaire au premier tour d'une élection présidentielle française si elle avait lieu aujourd'hui.

Nous avons mis en place une architecture complète de traitement et d'analyse de données, reposant sur une logique ETL (Extract, Transform, Load) et plusieurs modèles de Machine Learning supervisé. Le projet s'est appuyé sur l'exploitation de nombreux jeux de données publics (INSEE, data.gouv.fr) couvrant des indicateurs démographiques, économiques, territoriaux, sociaux et criminels.

Le nettoyage, l'harmonisation et la transformation des données réalisés à l'échelle communale, incluant la gestion des valeurs manquantes, l'harmonisation des codes INSEE, la normalisation des formats, la gestion des fusions de communes et l'estimation d'indicateurs 2024 non disponibles publiquement ont représenté une part importante du travail.

Nous avons développé avec Python et Pandas un pipeline nous permettant d'automatiser les étapes de la collecte à l'entraînement des modèles et à la génération des prédictions. Nous avons centralisé les données nettoyées dans une base SQLite pour garantir cohérence, traçabilité et reproductibilité.

Nous avons ensuite comparé plusieurs modèles supervisés (Random Forest, XGBoost, Logistic Regression, Neural Network). XGBoost s'est révélé le plus performant, avec les meilleurs scores d'accuracy et de F1-score pondéré. L'évaluation a également mis en lumière des corrélations entre variables explicatives et tendances électorales.

Le projet a mobilisé de nombreuses compétences techniques et organisationnelles : conception d'un pipeline ETL, manipulation et analyse de données volumineuses, nettoyage et transformation de jeux de données, modélisation relationnelle, utilisation de Python, Pandas et Scikit-learn, création de visualisations avec Power BI et Python et travail collaboratif via GitHub.

Malgré les résultats obtenus, ce POC présente des limites liées à la qualité et la disponibilité des données, au déséquilibre des classes politiques et à l'évolution du contexte politique. Les prédictions doivent donc être considérées comme des estimations statistiques et non comme des certitudes.

Enfin, des pistes d'amélioration futures incluent l'intégration de nouveaux indicateurs économiques et temporels, l'ajout de datasets historiques, un meilleur rééquilibrage des classes et le recours à des architectures Big Data avancées pour une mise en production.

Ce projet POC Electio-Analytics constitue ainsi une première base fonctionnelle démontrant la faisabilité d'une analyse prédictive électorale via des données publiques et des techniques de Machine Learning.

XV. Réponses aux questions

➤ *Parmi les données que vous avez sélectionnées, laquelle est la plus corrélée aux résultats des élections ?*

L'analyse du projet Electio-Analytics met en évidence des corrélations significatives entre les résultats du premier tour de l'élection présidentielle de 2022 et plusieurs variables socio-économiques, démographiques et territoriales.

Les variables les plus corrélées aux comportements électoraux sont principalement : Le revenu médian, le taux de chômage, la densité de population, la criminalité, la structure démographique (âge médian, proportion de jeunes et de seniors), ainsi que des facteurs de dynamisme économique et associatif.

L'exploration des données (EDA) et les modèles de Machine Learning démontrent une influence prépondérante de certaines variables.

Les facteurs économiques, comme le revenu médian et le chômage, sont fortement corrélés aux comportements électoraux des blocs « centre » et « extrême droite ». Les variables démographiques et territoriales, telles que la densité et l'âge médian, permettent également de distinguer certains comportements entre zones urbaines, périurbaines et rurales.

L'analyse des corrélations montre que certaines variables apportent peu d'information utile ou introduisent du bruit dans l'apprentissage, soulignant l'importance de la sélection des variables explicatives dans un projet de Machine Learning appliqué à l'analyse des comportements électoraux.

Enfin, une amélioration possible du projet serait l'intégration d'un indicateur d'inflation sur plusieurs années, afin d'étudier son impact potentiel sur le pouvoir d'achat, les revenus, le chômage et les tendances électorales.

➤ *Définissez le principe d'un apprentissage supervisé.*

L'apprentissage supervisé est une technique de Machine Learning où un algorithme exploite un ensemble de données comprenant des variables d'entrée (features ou explicatives) et une variable cible connue à prédire.

Dans le projet Electio-Analytics, les variables d'entrée sont des indicateurs socio-économiques, démographiques et territoriaux des communes françaises (revenu médian, chômage, criminalité, densité de population), tandis que la variable cible est le bloc politique vainqueur au premier tour des présidentielles 2022.

Le processus consiste à entraîner plusieurs modèles de Machine Learning sur des données historiques pour apprendre les relations entre les variables explicatives et les résultats électoraux. Le modèle entraîné peut ensuite effectuer des prédictions sur de nouvelles données, notamment le dataset de prédiction 2024.

Dans le cadre du projet, nous avons choisi d'utiliser les modèles supervisés de classification suivants : Random Forest, XGBoost, Régression Logistique (logistic regression) et Réseau de neurones (neural network). Par la suite, ces modèles ont été comparés pour sélectionner le plus performant dans la prédiction électorale.

➤ **Comment définissez-vous le degré de précision (accuracy) de votre modèle ?**

L'accuracy mesure le pourcentage de prédictions correctes réalisé par un modèle de Machine Learning sur l'ensemble des prédictions effectuées.

Sa formule est la suivante :

$$\text{Accuracy} = \frac{\text{Nombre de bonnes prédictions}}{\text{Nombre total de prédictions}}$$

Cette métrique permet d'évaluer globalement les performances d'un modèle de classification.

Dans le cadre du projet Electio-Analytics, plusieurs métriques d'évaluation ont été employées : accuracy, F1-score pondéré, précision et recall²⁵.

En effet, l'accuracy seule peut être trompeuse lorsque les classes sont déséquilibrées. Dans notre projet, certains blocs politiques étaient moins représentés, notamment la classe « droite ». Le F1-score pondéré a donc été utilisé en complément afin de mieux mesurer la capacité du modèle à gérer ce déséquilibre entre les classes politiques.

Après comparaison des différents modèles de Machine Learning, le modèle XGBoost a obtenu les meilleures performances avec une accuracy de 72,75 % et un F1-score pondéré de 70,67 %. Ces résultats ont conduit à sélectionner XGBoost comme modèle principal pour la prédiction électorale.



²⁵ Cf Glossaire

XVI. Liste des compétences mises en valeur par le projet

Ce projet met en évidence les compétences suivantes du référentiel :

Piloter l'informatique décisionnel d'un SI (Big Data & BI)
Compétences
Collecter les besoins en données des directions métiers de l'entreprise afin d'avoir une vision structurée de l'ensemble des données du système d'information et partager la stratégie Data globale avec le comité de direction.
Définir une architecture business intelligence à partir des orientations stratégiques arrêtées avec le comité de direction afin de mettre à disposition des utilisateurs métiers les données structurées d'un S.I.
Définir une stratégie big data (de la collecte aux traitements des données) à partir des orientations stratégiques arrêtées avec le comité de direction afin d'aider l'entreprise à mieux comprendre ses clients et à créer de nouveaux services.
Proposer des modèles statistiques et de data science (machine Learning) à mettre en pratique aux directions métiers afin de détecter des nouveaux services, anticiper des besoins et résoudre des problématiques métiers de l'entreprise.
Organiser les sources de données sous forme de résultats exploitables (data visualisation) pour alimenter les outils décisionnels et visualiser les résultats de façon compréhensible permettant d'aider les directions métiers à la prise de décision.
Définir les données de référence de l'entreprise à partir des données utilisées pour créer un référentiel de données afin d'assurer la mise à disposition de données cohérentes aux directions métiers.
Créer un entrepôt unique à partir du référentiel de données établi pour centraliser les informations stratégiques de l'entreprise et répondre rapidement aux besoins métiers.
Assurer la qualité des données en utilisant les outils de gestion de la qualité de données pour garantir l'exactitude, la cohérence, la synchronisation et la traçabilité des données afin de satisfaire les besoins d'accessibilité des utilisateurs métiers.
Appliquer les procédures de sécurité établies par le / la RSSI de l'entreprise afin d'assurer la confidentialité et la sécurité des données et garantir une mise en conformité avec les obligations légales du RGPD.

Remerciements

Nous remercions nos familles, nos amis pour leur soutien, ainsi que nos formateurs Frédéric ASSIÉ et Mourad ELCHYIAKI qui nous ont accompagné pendant ce parcours.

Nous adressons également nos remerciements particuliers à Thibault CLÉMENT pour son aide précieuse et pour la passion de l'analyse de données qu'il a su nous transmettre durant cette MSPR.



Références/Sources

A) Datasets d'entraînement et de prédiction

- ◆ data.gouv.fr
- ◆ insee.fr

B) Tutoriels et documentations

- ◆ Documentation sur le Machine Learning : [Qu'est-ce que le machine learning ? - Michael Chen](#)
- ◆ Documentation [Python](#)
- ◆ [IBM – Machine Learning Metrics](#)
- ◆ [Microsoft Learn – Classification Metrics](#)
- ◆ Documentation [Scikit-learn](#)
- ◆ Articles :
 - [Data Cleaning for Machine Learning](#) – alan_mazan
 - [What Is a Machine Learning \(ML\) Model? Full Guide](#) - Snowflake
 - [Présidentielle 2022 : la carte interactive de tous les résultats](#)
- ◆ Tutoriels Youtube :
 - [Missingno Python Library | Visualising Missing Values in Data Prior to Machine Learning](#) - Andy McDonald
 - [Data Cleaning in Pandas | Python Pandas Tutorials](#) - Alex The Analyst



Glossaire

Acronyme/mot	Signification	Définition
Accuracy	Exactitude	Métrique de classification représentant le pourcentage total de prédictions correctes réalisées par le modèle par rapport à l'ensemble des données testées. L'accuracy permet d'évaluer la performance globale d'un modèle de Machine Learning.
Algorithme	-	Méthode mathématique et informatique permettant à un système d'apprendre à partir de données afin d'identifier des modèles, effectuer des prédictions ou prendre des décisions automatiquement. L'algorithme analyse les données d'entraînement, ajuste ses paramètres progressivement et construit un modèle capable de généraliser ses résultats sur de nouvelles données. Chaque algorithme est conçu pour répondre à un type de problème spécifique, comme la classification, la régression ou le clustering.
Apprentissage supervisé	-	L'apprentissage supervisé est une méthode de machine learning dans laquelle un algorithme est entraîné à partir de données étiquetées. Chaque donnée d'entrée est associée à une sortie attendue, ce qui permet au modèle d'apprendre à prédire correctement des résultats sur de nouvelles données. Cette approche est principalement utilisée pour des tâches de classification et de régression.
Classification	-	La classification est une méthode de machine learning supervisé qui consiste à attribuer une catégorie ou une classe à une donnée en fonction de ses caractéristiques. Le modèle apprend à partir de données étiquetées afin de prédire la bonne catégorie pour de nouvelles données. Par exemple, un système peut classer des courriels en « spam » ou « non spam ».
Data warehouse	Entrepôt de données	Base de données centralisée conçue pour le stockage, l'intégration et l'analyse de grandes quantités de données provenant de sources hétérogènes, afin de soutenir la prise de décision stratégique.
DCP	Données à Caractère Personnel	Toute information permettant d'identifier de façon directe ou indirecte un individu.
Deep Learning	Apprentissage profond	Sous-domaine du Machine Learning qui utilise des réseaux de neurones artificiels composés de nombreuses couches pour résoudre des tâches complexes. Inspirés du fonctionnement du cerveau humain, ces algorithmes apprennent à extraire des caractéristiques et à créer des représentations hiérarchiques directement à partir de données brutes, sans nécessiter d'extraction manuelle des fonctionnalités par des humains.
DOM-TOM	Départements d'Outre-Mer et Territoires d'Outre-Mer	Ensemble des territoires français situés hors de l'Europe continentale. Bien que le terme correct soit désormais France d'outre-mer ou DROM-COM, DOM-TOM reste l'expression la plus couramment utilisée dans le langage courant pour désigner ces territoires ultramarins.
ETL	Extract, Transform, Load ou Extraction, Transformation, Chargement	Processus d'intégration de données qui permet de collecter des informations brutes provenant de sources multiples et hétérogènes, de les nettoyer et de les structurer, puis de les charger dans un entrepôt de données ou un lac de données cible.
ELT	Extract, Load, Transform ou Extraction,	Processus d'intégration de données qui consiste à extraire des données depuis plusieurs sources, à les charger directement dans un entrepôt ou lac de données, puis à effectuer les transformations et traitements au sein de l'infrastructure de stockage cible.

	Chargement, Transformation	
Feature	Variable explicative	Variable utilisée par le modèle de Machine Learning pour effectuer une prédiction. Les features représentent les caractéristiques ou critères décrivant les données d'entrée. Dans le projet Electio-Analytics, les features correspondent par exemple aux revenus médians, au taux de chômage, à la densité de population ou encore aux données de criminalité.
F1-Score	F1-Score	Métrique combinant la précision (Precision) et le rappel (Recall) dans un score unique. Le F1-Score permet d'évaluer l'équilibre entre la capacité du modèle à faire des prédictions correctes et sa capacité à retrouver correctement les classes attendues.
INSEE	Institut National de la Statistique et des Études Économiques	Organisme public français créé en 1946, placé sous la tutelle du ministère de l'Économie et des Finances. Il a pour mission principale de collecter, produire, analyser et diffuser des informations sur l'économie et la société françaises.
Machine Learning (ML)	Apprentissage automatique	Branche de l'intelligence artificielle qui permet à des systèmes informatiques d'apprendre à partir de grands volumes de données afin de reconnaître des modèles, faire des prédictions ou automatiser des décisions, sans être explicitement programmés pour chaque tâche.
MCD	Modèle Conceptuel de Données	Représente la version métier des données et permet d'identifier les différentes entités manipulées ainsi que les relations existantes entre elles.
MLD	Modèle Logique de Données	Représentation logique des données d'un système d'information, dérivée du MCD. Il s'agit d'une étape intermédiaire entre l'analyse des besoins métier et la création physique de la base de données.
MPD	Modèle Physique de Données	Représente la traduction technique du MCD dans la base de données réelle utilisée par le projet.
Outliers	Valeurs aberrantes	Points de données qui diffèrent significativement des autres observations dans un ensemble de données, apparaissant comme des valeurs extrêmement élevées ou basses. Ils peuvent résulter d'erreurs de mesure, de saisie, de variabilité expérimentale, ou indiquer des événements rares et réels.
POC	Proof Of Concept ou Preuve de Concept	Méthode qui vise à démontrer la faisabilité et la viabilité d'un projet, d'une idée ou d'une technologie avant son déploiement complet. Il s'agit d'une étape préliminaire, souvent utilisée dans les méthodes agiles ou par les startups, qui consiste à réaliser un modèle simplifié ou un test pour valider les hypothèses techniques, commerciales ou économiques.
Accuracy	Précision	Métrique indiquant la proportion de prédictions positives correctes parmi l'ensemble des prédictions positives réalisées par le modèle. Une précision élevée signifie que le modèle génère peu de faux positifs.
Recall	Rappel	Métrique mesurant la capacité du modèle à retrouver correctement les données appartenant réellement à une classe donnée. Un recall élevé signifie que le modèle génère peu de faux négatifs.
Régression	-	La régression est une méthode de machine learning utilisée pour prédire une valeur numérique continue à partir de données existantes. Elle modélise la relation entre une variable à prédire et une ou plusieurs variables explicatives. Par exemple, elle peut être utilisée pour estimer le prix d'une maison selon sa surface et sa localisation.
RGPD	Règlement Général sur la Protection des Données	Règlement européen n° 2016/679 du 27 avril 2016, qui constitue le cadre juridique de référence pour la protection des données personnelles dans l'Union européenne.

		Entré en vigueur le 25 mai 2018, ce texte s'applique directement dans tous les États membres sans nécessiter de transposition nationale. Son objectif principal est de renforcer les droits des citoyens sur leurs données personnelles et d'harmoniser les règles pour les entreprises, en encadrant strictement la collecte, le traitement et le stockage des informations relatives aux personnes physiques identifiées ou identifiables.
Surapprentissage	Overfitting	Le surapprentissage désigne une situation où un modèle apprend trop précisément les données d'entraînement, y compris leurs erreurs ou particularités. Le modèle devient alors très performant sur les données utilisées pour l'entraînement, mais moins efficace sur de nouvelles données, car il généralise mal.
Target	Cible	Correspond à la variable que le modèle de Machine Learning cherche à prédire. Dans le cadre du projet Electio-Analytics, la target est la variable classe_politique, représentant le bloc politique dominant d'une commune.

